



Universidade de Brasília – UnB
Campus Gama – FGA
Programa de Pós-Graduação em Engenharia Biomédica

**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA E
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

ANA PAULA SANDES DE SOUZA

Orientador: DR. GERARDO ANTONIO IDROBO PIZO



UNB – UNIVERSIDADE DE BRASÍLIA

FGA – FACULDADE GAMA



**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

ANA PAULA SANDES DE SOUZA

ORIENTADOR: DR. GERARDO ANTONIO IDROBO PIZO

**DISSERTAÇÃO DE MESTRADO EM
ENGENHARIA BIOMÉDICA**

PUBLICAÇÃO: 011A/2022

BRASÍLIA/DF, AGOSTO DE 2022

UNB – UNIVERSIDADE DE BRASÍLIA

FGA – FACULDADE GAMA

PROGRAMA DE PÓS-GRADUAÇÃO

**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

ANA PAULA SANDES DE SOUZA

DISSERTAÇÃO DE MESTRADO SUBMETIDA AO PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA BIOMÉDICA DA UNIVERSIDADE DE BRASÍLIA, COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE MESTRE EM ENGENHARIA BIOMÉDICA

APROVADA POR:

Dr. Gerardo Antonio Idrobo Pizo

(Orientador)

DR^a. Marília Miranda Forte Gomes

(Examinador interno)

Dr. Membro Externo

(Examinador externo)

FICHA CATALOGRÁFICA

SOUZA, ANA

Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso [Distrito Federal], 2019.

44p., 210 × 297 mm (FGA/UnB Gama, Mestrado em Engenharia Biomédica, 2022).

Dissertação de Mestrado em Engenharia Biomédica, Faculdade UnB Gama, Programa de Pós-Graduação em Engenharia Biomédica.

1. Neurociência Computacional

2. Eletroencefalograma

3. Rastreamento Ocular

4. Sincronização de Sinais

I. FGA UnB/UnB.

II. Título (série)

REFERÊNCIA

SOUZA, ANA (2022). Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso. Dissertação de mestrado em engenharia biomédica, Publicação 011A/2022, Programa de Pós-Graduação, Faculdade UnB Gama, Universidade de Brasília, Brasília, DF, 44p.

CESSÃO DE DIREITOS

AUTOR: Ana Paula Sandes de Souza

TÍTULO: Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso

GRAU: Mestre

ANO: 2022

É concedida à Universidade de Brasília permissão para reproduzir cópias desta dissertação de mestrado e para emprestar ou vender tais cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte desta dissertação de mestrado pode ser reproduzida sem a autorização por escrito do autor.

anapaulasandes.s@gmail.com

Brasília, DF – Brasil

RESUMO

O eletroencefalograma (EEG) e o rastreamento ocular (ET - *Eye Tracking*) são formas não-invasivas de se observar o comportamento do sistema nervoso através da coleta da atividade neural e posicionamento ocular ao longo do tempo. Desta forma, são importantes ferramentas na construção de bases de dados fisiológicos. Bases de dados com mais de um tipo de dado fisiológico conferem vantagens a respeito do uso em algoritmos classificatórios, apresentando uma maior acurácia do que algoritmos treinados com datasets unimodais. Apesar das vantagens de uso, o acesso a estes datasets ainda é restrito devido ao custo dos equipamentos e a complexidade da sincronização entre diferentes sensores. O presente estudo tem por objetivo apresentar uma ferramenta construída a partir de equipamentos comerciais que tem como *output* um dataset multimodal de EEG e ET coletados simultaneamente. É esperado que a ferramenta promova acessibilidade a datasets multimodais ao gerar uma coleta com equipamentos de baixo custo (relativo a equipamentos clínicos) e incentive o desenvolvimento de diferentes áreas de pesquisa que possam se beneficiar do acesso facilitado da coleta de dados fisiológicos. A ferramenta será avaliada a respeito de sua capacidade de sincronização de EEG e ET, e o dataset multimodal será utilizado para treinar algoritmos classificatórios no software Orange em um estudo de caso com apresentação de estímulos emocionais durante o momento de coleta. A performance dos algoritmos será utilizada para argumentar sobre a possível aplicabilidade da ferramenta em estudos futuros.

Palavras-chave: EEG; ET; Sincronização; Base de Dados Fisiológicos;

ABSTRACT

Electroencephalogram (EEG) and Eye Tracking (ET) are non-invasive methods of observing the nervous system behavior by monitoring neural activity and ocular positioning over time. They are important tools in the construction of physiological databases. Databases with more than one type of physiological data confer advantages in classification algorithms, presenting a greater accuracy than algorithms trained with unimodal datasets. However, access to these datasets is still restricted due to the equipment cost and synchronization complexity between different sensors. The present study aims to present a tool built from commercially available devices whose output is a multimodal dataset of EEG and ET collected simultaneously. The tool is expected to promote accessibility to multimodal datasets by generating a database from low-cost equipment (in comparison to clinical equipment) and encourage the development of different areas of research that can benefit from easier access to physiological data acquisition. The tool will be evaluated regarding its ability to synchronize EEG and ET, and the multimodal dataset will be evaluated in a case study with the participant being submitted to emotional stimuli to be classified by the trained algorithms in Orange software. The algorithms performance will be used to discuss about the tool applicability in future studies.

Keywords: EEG; ET; Synchronization; Physiological Dataset;

SUMÁRIO

1	Introdução	1
1.1	Contextualização de Problema	1
1.2	Objetivos	2
1.2.1	Objetivos Específicos	3
1.3	Justificativa	3
1.4	[REFAZER] Organização do Documento	3
2	Eletricidade Cerebral	5
2.1	Correntes Elétricas	5
2.2	Neurônios	5
2.2.1	Impulsos Nervosos e Potencial de Ação	6
2.3	Eletroencefalograma	7
2.3.1	Tipos de Eletrodos para Captura de EEG	8
2.3.2	Sistema Internacional 10/20 de Posicionamento de Eletrodos	8
3	Rastreamento Ocular	9
3.1	Anatomia Ocular	9
3.2	Equipamentos de Rastreamento	10
3.3	Eletrooculograma	10
3.3.1	Artefatos em EEG por Movimentação Ocular	12
4	Séries Temporais	13
5	Sincronização	19
5.1	Frequência de Coleta	19

5.1.1	Frequência Nyquist	19
5.2	Sincronização com Timecode	19
5.3	Sincronização com Piscadas	20
5.3.1	Identificação no Sinal do EEG	20
5.3.2	Identificação no Sinal de ET	21
5.4	Métodos para Sincronização	21
5.4.1	Códigos para Sincronização	22
5.5	Correlação EEG e ET	22
6	Acesso a Datasets Fisiológicos	25
6.1	Aquisição de Dados Fisiológicos	25
7	Aplicação de Datasets Fisiológicos	27
7.1	Avaliação de Algoritmos	27
8	Materiais e Métodos	31
8.1	Proposta de Ferramenta	31
8.2	Mindwave Mobile II	31
8.3	Gazepoint GP3	32
8.3.1	Especificações GP3	32
8.3.2	Calibração GP3	32
8.3.3	Dados Capturados pelo GP3	33
8.3.4	Avaliação da Qualidade dos Dados	33
8.4	Montagem	33
8.4.1	35
8.5	Observações Sobre Quadros e Tabelas	36
9	Resultados e Discussões	38
10	Conclusão	39
	Lista de Referências	39

Apêndice A	41
Apêndice B	42
Anexo A	43
Anexo B	44

LISTA DE TABELAS

8.1	Parâmetros utilizados na implementação do método de detecção de bordas proposto, em cada configuração considerada.	36
9.1	Fatores de qualidades medidos em função do número de amostras, nos testes de reconstrução realizados.	38
9.2	Outro exemplo de tabela.	38

LISTA DE QUADROS

- 8.1 Exemplo de um quadro (retirado de [1]): *Variáveis explicativas que representam características socioeconômicas dos idosos*. Fonte: [1] 37

LISTA DE FIGURAS

1.1	Exemplo de um acelerador linear utilizado no Hospital Universitário de Brasília.	2
2.1	Impulsos nervosos conduzidos em neurônios	6
2.2	Impulsos nervosos conduzidos em neurônios	7

LISTA DE NOMENCLATURAS E ABREVIACES

1 INTRODUÇÃO

Existe uma importante vantagem advinda do uso de bases fisiológicas chamadas multimodais, ou de mais de um tipo de dado fisiológico em algoritmos supervisionados: a possibilidade de conferir um maior poder classificatório em relação aos datasets unimodais (Kang et al., 2020; Thapaliya et al., 2019). Sobre os benefícios já alcançados com estes datasets, é possível citar: melhora de diagnóstico de transtornos neurológicos, como depressão e autismo (Kang et al., 2020; Thapaliya et al., 2019; Wu et al., 2021), maior poder de classificação de emoções (Guo et al., 2019; Zheng et al., 2019; Lu et al., 2015; Zheng et al., 2014), e uma maior compreensão da ativação de mecanismos nervosos durante atividades de rotina, como leitura (Hollenstein et al., 2018). Um modelo específico de dataset fisiológico multimodal é constituído do eletroencefalograma (EEG) e rastreamento ocular (RO ou ET, da palavra em inglês *Eye Tracking*), já tendo sido utilizado em diferentes estudos de aprendizado supervisionado e estudos de *Brain Computer Interface*, ou BCI; onde a integração homem-máquina é aprofundada (Xu et al., 2022; Kim et al., 2015; Lee et al., 2010).

1.1 CONTEXTUALIZAÇÃO DE PROBLEMA

Apesar das múltiplas vantagens, o acesso a estes datasets ainda é restrito. Sobre a coleta de EEG e ET, Kastrati et al. comenta:

*“Coletar e classificar dados simultâneos de EEG e de rastreamento ocular é **demorado e caro**, pois requer equipamento e experiência [...]. Portanto, o acesso a dados de EEG-ET gravados simultaneamente é **altamente restrito**, o que retarda significativamente o progresso neste campo”. – Kastrati et al. (2021).*

No recente estudo sobre a análise conjunta de dados de EEG e ET por Dimigen e Ehinger (2020) foram levantados quatro principais problemas com este tipo de coleta (figura 1.1):

- Integração de dados
- A remoção de artefatos

- Controle de sobreposição temporal de respostas cerebrais
- Controle de influências de baixo-nível




Figura 1.1. Principais problemas de integração em datasets de EEG e ET. Fonte: Dimigen e Ehinger (2020).

Para auxiliar nos problemas levantados, a solução dos autores consistiu na construção de códigos especializados (o pacote EYE-EEG), que trabalham de forma integrada a uma *toolbox* já consolidada em estudos de EEG, o EEGLAB (Delorme e Makeig, 2014) - a ser explorada adiante. A redução do custo das coletas fisiológicas já vem sendo abordada através de equipamentos comercialmente disponíveis. Um exemplo é o desenvolvimento de “*smart watches*”, pequenos computadores de pulso que permitem o acompanhamento da frequência cardíaca do usuário, além do monitoramento de outras atividades fisiológicas, como o sono (Canaltech, 2022). O Mindwave Mobile II (Neurosky, Vale do Silício, CA, Estados Unidos), é um exemplo de equipamento comercial que possibilita a captura de ondas cerebrais, além de métricas próprias do fabricante utilizadas para estimar atenção, meditação e a captura de piscadas dos usuários. Atualmente também existem equipamentos disponíveis comercialmente para a coleta de ET, como o GP3 (Gazepoint, Vancouver, BC, Estados Unidos).

Com o propósito de aumentar a acessibilidade aos datasets multimodais e suas amplas vantagens de uso, o presente projeto tem por objetivo a criação de uma ferramenta de coleta simultânea de EEG e ET acessível a partir da coleta de dados de dois equipamentos comerciais – GP3 e Mindwave Mobile II. A ferramenta construída tem como *output* uma base de dados multimodal utilizada para treinamento de algoritmos classificatórios com o auxílio do software de mineração de dados Orange (Demsar et al., 2013), e terão seus resultados apresentados adiante no texto.

1.2 OBJETIVOS

Criar uma ferramenta a partir de equipamentos comerciais que gere um dataset fisiológico multimodal com dados de EEG e ET.

1.2.1 Objetivos Específicos

- Criar código para coleta simultânea de EEG e ET;
- Criar dataset multimodal a partir da fusão de dados de EEG e ET coletados pela ferramenta;
- Avaliar o erro de sincronização, precisão e acurácia da ferramenta;
- Realizar um estudo de caso com a aplicação do dataset gerado pela ferramenta para treinar algoritmos classificatórios;
- Avaliar a performance dos algoritmos treinados para discutir a usabilidade da ferramenta em estudos futuros;

1.3 JUSTIFICATIVA

A capacidade de coletar dados de forma simplificada e de baixo custo pode abrir espaço para novas investigações científicas e também favorecer uma maior e mais representativa volumetria da população de estudo por eliminar a necessidade de deslocamento do participante à centros com os equipamentos (Brand et al., 2020). Ferramentas que gerem datasets multimodais também podem conferir vantagens na aplicação de iniciativas de aprendizado de máquina, *Brain Computer Interface* (BCI) e efomentar avanços na área de Inteligência Artificial (IA) por promover bases de dados onde os algoritmos possam ser treinados.

De forma geral, os benefícios da solução se concentram em:

- Aumento da acessibilidade à estação de coleta, tanto por participantes quanto por pesquisadores;
- Aumento da volumetria de dados;
- Maior disponibilidade de bases de dados fisiológicos para incentivar o desenvolvimento de outras frentes de estudo;

1.4 [REFAZER] ORGANIZAÇÃO DO DOCUMENTO

O presente texto tem capítulos. O primeiro capítulo trata da contextualização do problema, objetivos gerais e específicos, e a justificativa para a abordagem selecionada.

O segundo capítulo trata do referencial teórico, levantando pontos históricos importantes ao desenvolvimento desta pesquisa, uma introdução ao que seriam os sinais

capturados pelos dois equipamentos de EEG e ET, características dos diferentes tipos de equipamento de captura e aborda a conversão de sinais analógicos para digital.

O terceiro capítulo trata do processo da aquisição e do tratamento de sinais fisiológicos a serem classificados por algoritmos de aprendizado de máquina supervisionado – processos como remoção de ruído e seleção de características. Também aborda métodos de fusão de bases de dados de diferentes fontes - a nível de característica e a nível de decisão.

O quarto capítulo apresenta os métodos de avaliação dos algoritmos classificatórios.

O quinto capítulo aprofunda nos possíveis métodos de sincronização de coleta e de bases de dados.

O sexto capítulo introduz a proposta de ferramenta de coleta simultânea elaborada por código e aborda o método de sincronização off-line, com sincronização por código temporal.

O sétimo capítulo aborda o cronograma.

O oitavo capítulo aborda os resultados esperados do estudo.s

O nono capítulo apresenta as referencias do estudo.

2 ELETRICIDADE CEREBRAL

2.1 CORRENTES ELÉTRICAS

A diferença de potencial elétrico entre um material condutor gera um fluxo de cargas nomeado de **corrente elétrica** (Creder, 1989). A intensidade do fluxo é medida em ampère (A) e determinada pela quantidade de partículas que atravessam o seguimento do condutor pelo tempo. As correntes podem ser contínuas ou alternadas, a depender se o sentido da corrente varia ou não. Enquanto a corrente contínua é composta de polos (positivo e negativo), a alternada é composta de fases (Bhargava e Kulshreshtha, 1983). O cálculo de corrente elétrica é dado pela seguinte equação:

$$I = \frac{\Delta Q}{\Delta T}, \quad (2.1)$$

onde ΔQ é a quantidade de partículas que passam em um seguimento do condutor e ΔT indica o tempo.

2.2 NEURÔNIOS

Os neurônios são células responsáveis pela condução de impulsos nervosos e se comportam como um “cabo eletrificado” - analogia levantada a respeito da condução de impulsos elétricos, como apresentado no clássico estudo de Hodgkin e Huxley (1952), que teve como resultado uma modelagem dos potenciais de ação emitidos pelas células nervosas através de equações diferenciais não-lineares para o cálculo da corrente elétrica da membrana celular.

Existem aproximadamente 86 bilhões de neurônios no cérebro (Caire et al., 2022). Os neurônios comunicam-se uns com os outros através das **sinapses**, onde ocorre a transmissão dos impulsos nervosos. É possível distinguir três partes anatómicas no neurônio: o corpo celular, o axônio e os dendrito (figura 2.1).




Figura 2.1. Impulsos nervosos conduzidos em neurônios. Fonte: Ludwig et al. (2021).

2.2.1 Impulsos Nervosos e Potencial de Ação

Para passar informações, os neurônios geram **impulsos nervosos**, ou alterações no potencial elétrico de sua membrana. Este sinal elétrico ocorre quando o estímulo recebido pelo neurônio ultrapassa um limiar de ativação, que desencadeia uma série de respostas celulares. A célula pode estar em repouso (com valor do interior celular em cerca de -70mV), passando por despolarização (quando ocorre um fluxo de cargas elétricas que faz com que o meio intracelular passe a ser positivo em relação ao meio extracelular), e em repolarização, quando a célula está retornando ao potencial de repouso, como representado na figura 2.1.




Figura 2.2. Impulsos nervosos conduzidos em neurônios. Fonte: Chen e Lui (2021).

2.3 ELETROENCEFALOGRAMA

O conjunto de impulsos nervosos de grupos de neurônios geram campos magnéticos que podem ser captados por eletrodos colocados sobre a cabeça humana (Kandel, 2000). Estes campos magnéticos foram primeiro registrados de coletas em humanos aproximadamente em 1929, em um experimento conduzido pelo psiquiatra alemão Hans Berger (Ince et al., 2021) – figura 2.2.




Figura 2.3. Primeiro EEG registrado em humanos, resultado do trabalho do psiquiatra Hans Berger. Fonte: Ince et al. (2021).

Estes registros são o resultado dos potenciais de ação emitidos pelas células nervosas abaixo do eletrodo, e permitem uma boa resolução temporal do comportamento nervoso (podendo atingir precisão de milissegundos), mas em geral não permitem uma boa resolução espacial (como identificar a localização espacial do grupo celular responsável pela variação de voltagem observada).

2.3.1 Tipos de Eletrodos para Captura de EEG

Existem diferentes tipos de eletrodos para a captura de EEG. Um resumo é apresentado na tabela 2.1. É notável também que com o desenvolvimento da capacidade computacional, novos recursos e métodos para a análise destes dados vem sendo benéficos à construção do conhecimento científico, agora também contando com o desenvolvimento de algoritmos de aprendizado de máquina, aprendizado profundo e inteligência artificial.

2.3.2 Sistema Internacional 10/20 de Posicionamento de Eletrodos

A técnica de registro de EEG vem sendo desde então aperfeiçoada e escolhida em investigações comportamentais devido a sua natureza não invasiva. Um exemplo de aperfeiçoamento foi a criação de um sistema internacional de posicionamentos de eletrodos para a coleta de EEG – o sistema 10/20 (Klem et al., 1999), representado na figura 2.3. O registro capturado nos eletrodos advém de uma diferença de potencial elétrico. Esta diferença pode ser em referência à um eletrodo colocado em uma região externa ao escalpo (como orelha), ou à uma voltagem média comum (Tavares, 2011).

3 RASTREAMENTO OCULAR

3.1 ANATOMIA OCULAR

O globo ocular é majoritariamente opaco, com exceção da córnea, que é transparente. A pupila é a região que dá passagem para a luz e possui diâmetro variável. Os músculos da íris são os que controlam a dilatação da pupila. A focalização da imagem deve se concentrar na fóvea, onde se encontram células muito sensíveis a luz (Helene e Helene, 2011). A fixação ocular compreende a um período de cerca de 100 milissegundos onde o olhar se fixa em um ponto de convergência (Barreto et al., 2012). Este período se encerra com o movimento de sacada, que compreende ao movimento rápido até uma nova fixação do olhar em outro local. Através da coleta do posicionamento ocular, é possível calcular uma taxa de dispersão focal ao longo do tempo e piscadas. Estes dados foram previamente correlacionados com estados emocionais (Soleymani et al., 2012) e também aplicados em estudos com algoritmos de aprendizado de máquina e deep learning. Barreto (2012) resumiu alguns dos principais termos utilizados em pesquisas de rastreamento ocular (RO):




Figura 3.1

3.2 EQUIPAMENTOS DE RASTREAMENTO

Para detectar onde o participante está focando seu olhar ao longo do tempo, alguns equipamentos de ET fazem uso de luz infravermelha e câmeras de alta definição que projetam a luz diretamente no olho do participante e gravam a direção do olhar a partir do reflexo. Como a luz infravermelha abrange um comprimento de onda não detectável pelo olho humano, o direcionamento desta luz no olho não interfere visão do participante. O cálculo do direcionamento ocular é feito com base em algoritmos próprios de cada fabricante. Existem alguns tipos de equipamentos de rastreamento ocular. São eles: (1) Webcam, (2) Vestível (Wearable) e (3) Baseados em Tela. Webcam diz respeito a equipamentos não especializados para o uso de rastreamento; usáveis correspondem a equipamentos como óculos de rastreamento ocular e realidade virtual, e os baseados em tela dizem respeito aos equipamentos de coleta especializada que podem ser acoplados a um computador Tobii Pro (2020).

3.3 ELETROOCULOGRAMA

Fonte: <https://eyewiki.aao.org/Electrooculogram>

Definition The electrooculogram (EOG) is an electrophysiologic test that measures the existing resting electrical potential between the cornea and Bruch's membrane. The mean transepithelial voltage of bovine Retinal pigment epithelium is 6 millivolts (mV). [1]

History The EOG was described and named by Elwin Marg in 1951. Clinical applications were described first by Geoffrey Arden in 1962, who realized that the most valuable information was the comparison of the amplitudes under light and dark-adapted states (the Arden ratio).

Testing process The patient should be dilated. The amount of light passing through the pupils is measured in a unit called Trolands (the product of luminance (cd/m²) and pupil area (mm²)). [2] Thus the pupillary diameter may change the needed luminance for the same effect on the retina.

The patient should be in stable indoor lighting for at least 30 min before the test. Strong retinal illumination including retinal imaging (fluorescein angiogram, fundus photography and others) and indirect ophthalmoscopy should be avoided during this period.

The patient is told to remain still other than moving his/her eyes back and forth. Four recording skin electrodes (silver-silver chloride or gold-disk) are placed at the medial and lateral canthi of both eyes, and the grounding electrode is placed on the forehead.

Principle of EOG The difference of electrical potential of the anterior and posterior

part of the eyeball is called the standing potential.[2] Standing potential indirectly measures the transepithelial potential (TEP) of the retinal pigment epithelium (RPE). TEP is the difference of membrane potential of basolateral and apical membranes of RPE.

The standing potential may be determined in 2 ways:

EOG- determines function of outer retina and RPE. It has positive waveform in light and negative waveform in dark. It is recorded during 15 min of dark adaptation and 15 min of light adaptation. During 15 min of dark adaptation the standing potential usually reaches a minimum level (dark trough/DT) at 10-15 min. During 15 min of light adaptation the standing potential achieves the highest value at 7-12 min called a light peak/LP. The LP results from increased free intracellular calcium released from the endoplasmic reticulum. The role of bestrophin of endoplasmic reticulum and L type calcium channel of basolateral membrane is crucial in this. The increased intracellular calcium opens the 'Calcium dependent light peak chloride channels' of the basolateral membrane through which negative chloride ions are extruded from the RPE and the RPE depolarizes in light.[3] Fast Oscillations (FO)- Is an optional additional test performed using alternate 1 min dark and light periods. It has negative waveform in light and positive waveform in dark. This opposite waveform compared to EOG is related to different mechanism of FO and shorter dark and light periods. At the onset of light, there is a decrease in potassium levels at the subretinal space. This creates a strong outward hyperpolarising potassium current from the apical membrane of RPE which results in the c wave of electroretinogram. The chloride channels at the basolateral membrane (CFTR) of RPE may have important role in the generation of the FO, which may be reduced in cystic fibrosis.[4] The wave form of FO is sinusoidal compared to the EOG which has a shape of plateau after post hoc DC restoration by digital integration, Components of the EOG The light-insensitive component accounts for the dark trough and is dependent on the integrity of the retinal pigment epithelium (RPE) as well as the cornea, lens, and ciliary body. The light-sensitive component is the slow light rise of the EOG and is generated by the depolarization of the basal membrane of the RPE.

Reporting of EOG According to the 2017 ISCEV standards,[2] the report of EOG should include

Light peak: dark trough ratio (this terminology is preferred over conventional Arden ratio) Amplitude of dark trough (mv) Time from the start of light phase to light peak (when present) type of adapting light source pupil size Difficulties/deviation from protocol including patient compliance, inconsistent eye movements Interpretation of Results The Arden ratio, the ratio of the Light peak (Lp) to dark trough (Dt) is used to determine the normalcy of the results.

An Arden ratio of 1.80 or greater is normal, 1.65 to 1.80 is subnormal, and ≤ 1.65 is

significantly subnormal.

3.3.1 Artefatos em EEG por Movimentação Ocular



Figura 3.2. Artefatos oculares em registro de EEG. Fonte: Britton et al. (2016)

4 SÉRIES TEMPORAIS

Séries temporais são sequências de informações ao longo do tempo, onde informações vizinhas são dependentes (Ehlers, 2007). As séries podem ser contínuas ou discretas. Um exemplo de sinal contínuo é a diferença da voltagem de neurônios capturada por eletrodos ao longo do tempo. Exemplos de séries temporais incluem:

- Mudança de temperatura ao longo do dia
- Frequência de Disparo de Neurônios ao longo do tempo
- Mudança de Voltagem ao longo do tempo

As séries temporais tem um vasto uso em estatística, economia, matemática, entre outras áreas.

Time series analysis comprises methods for analyzing time series data in order to extract meaningful statistics and other characteristics of the data. Time series forecasting is the use of a model to predict future values based on previously observed values. While regression analysis is often employed in such a way as to test relationships between one or more different time series, this type of analysis is not usually called "time series analysis", which refers in particular to relationships between different points in time within a single series. Interrupted time series analysis is used to detect changes in the evolution of a time series from before to after some intervention which may affect the underlying variable.

Time series data have a natural temporal ordering. This makes time series analysis distinct from cross-sectional studies, in which there is no natural ordering of the observations (e.g. explaining people's wages by reference to their respective education levels, where the individuals' data could be entered in any order). Time series analysis is also distinct from spatial data analysis where the observations typically relate to geographical locations (e.g. accounting for house prices by the location as well as the intrinsic characteristics of the houses). A stochastic model for a time series will generally reflect the fact that observations close together in time will be more closely related than observations further apart. In addition, time series models will often make use of the natural one-way ordering of time so that values for a given period will be expressed as deriving in some way from past values, rather than from future values (see time reversibility).

Time series analysis can be applied to real-valued, continuous data, discrete numeric data, or discrete symbolic data (i.e. sequences of characters, such as letters and words in the English language[1]).

Methods for analysis Methods for time series analysis may be divided into two classes: frequency-domain methods and time-domain methods. The former include spectral analysis and wavelet analysis; the latter include auto-correlation and cross-correlation analysis. In the time domain, correlation and analysis can be made in a filter-like manner using scaled correlation, thereby mitigating the need to operate in the frequency domain.

Additionally, time series analysis techniques may be divided into parametric and non-parametric methods. The parametric approaches assume that the underlying stationary stochastic process has a certain structure which can be described using a small number of parameters (for example, using an autoregressive or moving average model). In these approaches, the task is to estimate the parameters of the model that describes the stochastic process. By contrast, non-parametric approaches explicitly estimate the covariance or the spectrum of the process without assuming that the process has any particular structure.

Methods of time series analysis may also be divided into linear and non-linear, and univariate and multivariate.

Panel data A time series is one type of panel data. Panel data is the general class, a multidimensional data set, whereas a time series data set is a one-dimensional panel (as is a cross-sectional dataset). A data set may exhibit characteristics of both panel data and time series data. One way to tell is to ask what makes one data record unique from the other records. If the answer is the time data field, then this is a time series data set candidate. If determining a unique record requires a time data field and an additional identifier which is unrelated to time (e.g. student ID, stock symbol, country code), then it is panel data candidate. If the differentiation lies on the non-time identifier, then the data set is a cross-sectional data set candidate.

Analysis There are several types of motivation and data analysis available for time series which are appropriate for different purposes.

Motivation In the context of statistics, econometrics, quantitative finance, seismology, meteorology, and geophysics the primary goal of time series analysis is forecasting. In the context of signal processing, control engineering and communication engineering it is used for signal detection. Other applications are in data mining, pattern recognition and machine learning, where time series analysis can be used for clustering,[2][3] classification,[4] query by content,[5] anomaly detection as well as forecasting.[6]

Exploratory analysis

Tuberculosis incidence US 1953-2009 Further information: Exploratory analysis A straightforward way to examine a regular time series is manually with a line chart. An example chart is shown on the right for tuberculosis incidence in the United States, made with a spreadsheet program. The number of cases was standardized to a rate per 100,000 and the percent change per year in this rate was calculated. The nearly steadily dropping line shows that the TB incidence was decreasing in most years, but the percent change in this rate varied by as much as ± 10

A study of corporate data analysts found two challenges to exploratory time series analysis: discovering the shape of interesting patterns, and finding an explanation for these patterns.[7] Visual tools that represent time series data as heat map matrices can help overcome these challenges.

Other techniques include:

Autocorrelation analysis to examine serial dependence Spectral analysis to examine cyclic behavior which need not be related to seasonality. For example, sunspot activity varies over 11 year cycles.[8][9] Other common examples include celestial phenomena, weather patterns, neural activity, commodity prices, and economic activity. Separation into components representing trend, seasonality, slow and fast variation, and cyclical irregularity: see trend estimation and decomposition of time series Curve fitting Main article: Curve fitting Curve fitting[10][11] is the process of constructing a curve, or mathematical function, that has the best fit to a series of data points,[12] possibly subject to constraints.[13][14] Curve fitting can involve either interpolation,[15][16] where an exact fit to the data is required, or smoothing,[17][18] in which a "smooth" function is constructed that approximately fits the data. A related topic is regression analysis,[19][20] which focuses more on questions of statistical inference such as how much uncertainty is present in a curve that is fit to data observed with random errors. Fitted curves can be used as an aid for data visualization,[21][22] to infer values of a function where no data are available,[23] and to summarize the relationships among two or more variables.[24] Extrapolation refers to the use of a fitted curve beyond the range of the observed data,[25] and is subject to a degree of uncertainty[26] since it may reflect the method used to construct the curve as much as it reflects the observed data.

The construction of economic time series involves the estimation of some components for some dates by interpolation between values ("benchmarks") for earlier and later dates. Interpolation is estimation of an unknown quantity between two known quantities (historical data), or drawing conclusions about missing information from the available information ("reading between the lines").[27] Interpolation is useful where the data surrounding the missing data is available and its trend, seasonality, and longer-term cycles are known. This is often done by using a related series known for all relevant dates.[28]

Alternatively polynomial interpolation or spline interpolation is used where piecewise polynomial functions are fit into time intervals such that they fit smoothly together. A different problem which is closely related to interpolation is the approximation of a complicated function by a simple function (also called regression). The main difference between regression and interpolation is that polynomial regression gives a single polynomial that models the entire data set. Spline interpolation, however, yield a piecewise continuous function composed of many polynomials to model the data set.

Extrapolation is the process of estimating, beyond the original observation range, the value of a variable on the basis of its relationship with another variable. It is similar to interpolation, which produces estimates between known observations, but extrapolation is subject to greater uncertainty and a higher risk of producing meaningless results.

Function approximation Main article: [Function approximation](#) In general, a function approximation problem asks us to select a function among a well-defined class that closely matches ("approximates") a target function in a task-specific way. One can distinguish two major classes of function approximation problems: First, for known target functions, approximation theory is the branch of numerical analysis that investigates how certain known functions (for example, special functions) can be approximated by a specific class of functions (for example, polynomials or rational functions) that often have desirable properties (inexpensive computation, continuity, integral and limit values, etc.).

Second, the target function, call it g , may be unknown; instead of an explicit formula, only a set of points (a time series) of the form $(x, g(x))$ is provided. Depending on the structure of the domain and codomain of g , several techniques for approximating g may be applicable. For example, if g is an operation on the real numbers, techniques of interpolation, extrapolation, regression analysis, and curve fitting can be used. If the codomain (range or target set) of g is a finite set, one is dealing with a classification problem instead. A related problem of online time series approximation[29] is to summarize the data in one-pass and construct an approximate representation that can support a variety of time series queries with bounds on worst-case error.

To some extent, the different problems (regression, classification, fitness approximation) have received a unified treatment in statistical learning theory, where they are viewed as supervised learning problems.

Prediction and forecasting In statistics, prediction is a part of statistical inference. One particular approach to such inference is known as predictive inference, but the prediction can be undertaken within any of the several approaches to statistical inference. Indeed, one description of statistics is that it provides a means of transferring knowledge about a sample of a population to the whole population, and to other related populations, which is not necessarily the same as prediction over time. When information is transferred

across time, often to specific points in time, the process is known as forecasting.

Fully formed statistical models for stochastic simulation purposes, so as to generate alternative versions of the time series, representing what might happen over non-specific time-periods in the future. Simple or fully formed statistical models to describe the likely outcome of the time series in the immediate future, given knowledge of the most recent outcomes (forecasting). Forecasting on time series is usually done using automated statistical software packages and programming languages, such as Julia, Python, R, SAS, SPSS and many others. Forecasting on large scale data can be done with Apache Spark using the Spark-TS library, a third-party package.[30] Classification Main article: Statistical classification Assigning time series pattern to a specific category, for example identify a word based on series of hand movements in sign language.

Signal estimation See also: Signal processing and Estimation theory This approach is based on harmonic analysis and filtering of signals in the frequency domain using the Fourier transform, and spectral density estimation, the development of which was significantly accelerated during World War II by mathematician Norbert Wiener, electrical engineers Rudolf E. Kálmán, Dennis Gabor and others for filtering signals from noise and predicting signal values at a certain point in time. See Kalman filter, Estimation theory, and Digital signal processing

Segmentation Main article: Time-series segmentation Splitting a time-series into a sequence of segments. It is often the case that a time-series can be represented as a sequence of individual segments, each with its own characteristic properties. For example, the audio signal from a conference call can be partitioned into pieces corresponding to the times during which each person was speaking. In time-series segmentation, the goal is to identify the segment boundary points in the time-series, and to characterize the dynamical properties associated with each segment. One can approach this problem using change-point detection, or by modeling the time-series as a more sophisticated system, such as a Markov jump linear system.

Models Models for time series data can have many forms and represent different stochastic processes. When modeling variations in the level of a process, three broad classes of practical importance are the autoregressive (AR) models, the integrated (I) models, and the moving average (MA) models. These three classes depend linearly on previous data points.[31] Combinations of these ideas produce autoregressive moving average (ARMA) and autoregressive integrated moving average (ARIMA) models. The autoregressive fractionally integrated moving average (ARFIMA) model generalizes the former three. Extensions of these classes to deal with vector-valued data are available under the heading of multivariate time-series models and sometimes the preceding acronyms are extended by including an initial "V" for "vector", as in VAR for vector autoregression.

An additional set of extensions of these models is available for use where the observed time-series is driven by some "forcing" time-series (which may not have a causal effect on the observed series): the distinction from the multivariate case is that the forcing series may be deterministic or under the experimenter's control. For these models, the acronyms are extended with a final "X" for "exogenous".

Non-linear dependence of the level of a series on previous data points is of interest, partly because of the possibility of producing a chaotic time series. However, more importantly, empirical investigations can indicate the advantage of using predictions derived from non-linear models, over those from linear models, as for example in nonlinear autoregressive exogenous models. Further references on nonlinear time series analysis: (Kantz and Schreiber),[32] and (Abarbanel)[33]

Among other types of non-linear time series models, there are models to represent the changes of variance over time (heteroskedasticity). These models represent autoregressive conditional heteroskedasticity (ARCH) and the collection comprises a wide variety of representation (GARCH, TARCH, EGARCH, FIGARCH, CGARCH, etc.). Here changes in variability are related to, or predicted by, recent past values of the observed series. This is in contrast to other possible representations of locally varying variability, where the variability might be modelled as being driven by a separate time-varying process, as in a doubly stochastic model.

In recent work on model-free analyses, wavelet transform based methods (for example locally stationary wavelets and wavelet decomposed neural networks) have gained favor. Multiscale (often referred to as multiresolution) techniques decompose a given time series, attempting to illustrate time dependence at multiple scales. See also Markov switching multifractal (MSMF) techniques for modeling volatility evolution.

A Hidden Markov model (HMM) is a statistical Markov model in which the system being modeled is assumed to be a Markov process with unobserved (hidden) states. An HMM can be considered as the simplest dynamic Bayesian network. HMM models are widely used in speech recognition, for translating a time series of spoken words into text.

Notation

5 SINCRONIZAÇÃO

O uso de equipamentos com função exclusiva de sincronização para coletas simultâneas é comum em pesquisas ambientes academicos e clínicos. A proposta de oferecer maior acessibilidade através da redução de custo e desenvolvimento de novas tecnologias encontra, portanto, um desafio a respeito de como realizar a sincronização dos dados fisiológicos sem abrir mão da praticidade e custo dos equipamentos desenvolvidos. Algumas propostas já foram exploradas a respeito, como o uso de piscadas e código temporal para garantir a sincronização de EEG e ET (Bækgaard et al. 2015, Notaro et al. 2018).

5.1 FREQUÊNCIA DE COLETA

Como os sinais analógicos são convertidos para sinais digitais, existe uma perda de informação por esta conversão. A **resolução de frequência** mede o espaço entre duas frequências.

$$srate/N$$

Srate = sampling rate N = Número de amostras

5.1.1 Frequência Nyquist

É a frequência mais rápida onde o sinal pode ser medido, onde é estabelecido que a maior frequência que podemos medir é a metade da frequência de coleta.s

5.2 SINCRONIZAÇÃO COM TIMECODE

Notaro et al. (2018) faz uso do código temporal, ou *timecode*, para sincronizar dados de EEG, ET e dados comportamentais coletados de participantes enquanto estes faziam atividades de um site de aprendizagem de linguas. O driver do fabricante do equipamento comercial de EEG utilizado permite alteração da latência da coleta de dados, que foi

modificada do valor padrão de 16 milissegundos para 1 milissegundo, afim de aumentar a precisão do equipamento. A informação da ocorrência de clicks no site foi retida na forma de milissegundos (HH:MM:SS:MsMsMs), e esta informação foi utilizada para sincronizar dados de ET, EEG e movimentação de mouse.

5.3 SINCRONIZAÇÃO COM PISCADAS

Piscadas duram cerca de 200 milissegundos em média e podem indicar estados de alerta (Caffier, 2013). Piscadas também aparecem em dados de EEG de forma característica, podendo alcançar uma amplitude de sinal acima de 200 microvolts em eletrodos próximos a órbita ocular (Hoffmann e Falkenstein, 2008). Assim sendo, é possível realizar uma sincronização por piscadas ao se detectar o movimento em ambos os equipamentos de coleta. No caso do EEG, as piscadas são comumente descartadas como artefatos indesejáveis. Já no estudo de Bækgaard et al. (2015), elas são a assinatura de sincronização entre os equipamentos de coleta de EEG e ET em função de sua onda característica (geralmente muitos milivolts acima do sinal do EEG), e de também ser detectado através dos equipamentos de rastreamento ocular.

O desafio da sincronização de EEG e ET se dá em função de serem séries temporais muito distintas e de frequências de amostra diferentes. No caso dos equipamentos comerciais de interesse desta pesquisa, a coleta de EEG pode ser realizada em até 512 Hz, enquanto a frequência de coleta de ET chega num máximo de 60 Hz. Além disso, o sinal de EEG pode apresentar mais de um canal, enquanto dados de ET podem ser representados na forma de coordenadas. Desta forma, Bækgaard et al. (2015) propõe uma sincronização por assinaturas dentro de cada um dos tipos de dados coletados. Piscadas ocorrem com frequência e de forma espontânea, além de ser uma informação capturada em equipamentos de EEG e ET.

5.3.1 Identificação no Sinal do EEG

A piscada envolve ativação muscular, e o dipolo ocular também influencia na captura de alterações de voltagem em eletrodos próximos aos olhos (Croft e Barry, 2000). Seu reflexo no EEG pode ser facilmente identificado pois tende a ter uma amplitude e forma de sinal característicos. A amplitude de uma atividade de piscada no sinal de EEG tem uma média de 200 microvolts (Hoffmann et al., 2008). Esta característica permite que o poder elétrico somado de eletrodos de interesse possam auxiliar na determinação de uma probabilidade do evento capturado ser uma piscada. No estudo de Bækgaard et al. (2015), as assinaturas de piscadas foram alinhadas entre as modalidades de EEG e ET para garantir a sincronização, e o começo da atividade de piscada (com o fechamento das

pálpebras) foi eleito como o ponto de referencia da assinatura.

Para se detectar a piscada através de um sinal, é possível tentar realizar o método de *Independent Component Analysis*, ou análise de componente independente, mas as características do sinal de piscada também permite outras abordagens, como a identificação por função de probabilidade.

5.3.2 Identificação no Sinal de ET

Como o equipamento de rastreamento procura encontrar sinais da movimentação ocular, ele também detecta a ausencia desse sinal. No estudo de Bækgaard et al. (2015), uma perda de até 500 milissegundos foi considerada como indicador da ocorrência de uma piscada. No equipamento de coleta de ET GP3, o fabricante oferece uma forma de identificar a existencia de uma piscada. Ela ocorre através da propriedade Blinking Validation Flag, ou BKID, onde qualquer valor diferente de 0 indica ocorrência de piscada durante o timeframe. A extração de piscada através do BKID foi utilizada no estudo de Seha et al. (2019), onde o blink rate foi validado e sincronizado com o vídeo do próprio equipamento (que indica quando houve piscada através da ausencia da imagem dos olhos do usuário).

5.4 MÉTODOS PARA SINCRONIZAÇÃO

Existem diferentes métodos para calculo de sincronização entre séries temporais. A forma mais simples é por **correlação de Pearson**, que mede como dois sinais mudam ao longo do tempo em valores que vão de -1 a 1; com -1 indicando uma correlação perfeita e negativa, 1 uma correlação perfeita e 0, sem correlação. É importante notar que anomalias vão impactar significativamente a correlação, e que os dados assumem que a variância é homogênea.

Outro método de sincronização entre séries temporais é o **lag cross-correlation**, onde é possível identificar qual sinal vem primeiro. A correlação é calculada através da mudança gradual de um vetor de série temporal e subsequente cálculo de correlação. A correlação cruzada procura calcular a similaridade entre dois sinais com a aplicação de um *delay* em apenas um dos sinais.

Um exemplo de seu uso é no trabalho de Com dois sinais diferentes em EEG e ET, Bækgaard et al. (2015) opta por correlacionar as funções de probabilidade do evento observado em ambos os equipamentos, ser uma piscada. Para correlacionar assinaturas diferentes, as probabilidades de ocorrencia de um evento (piscada) em duas séries temporais são convertidas em uma mesma frequência amostral (Bækgaard et al., 2014). A

similitude entre sinais é medida na amplitude do sinal da correlação. A correlação cruzada é definida como:

$$(f * g) = f(-t) * g(t), \quad (5.1)$$

onde $*$ significa convolução e $f(-t)$ é o conjugado complexo de $f(t)$.

5.4.1 Códigos para Sincronização

Alguns equipamentos podem se beneficiar da existencia de *toolboxes* ou bibliotecas direcionadas à sincronização. É o caso dos equipamentos Tobii na solução de EEG-Eye para a linguagem MATLAB. Uma forma de se fazer sincronização é através

5.5 CORRELAÇÃO EEG E ET

Shared triggers Common trigger pulses ("triggers") are sent frequently from the stimulation computer to both ET computer and EEG recording computer. This is achieved via a Y-shaped cable that is attached to the parallel port of the stimulation computer and splits up the pulse so it is looped through to EEG and ET. We recommend to send triggers with a sufficient duration (e.g. at least 5 ms at 500 Hz sampling rate) to avoid the loss of some of the triggers. The advantage of this method is that the same physical signal is used for synchronization (although this does not guarantee that the trigger is inserted into the ET and EEG data streams without delays). The disadvantage is the need for an extra cable.

Messages+triggers Messages are short text strings that can be inserted into the eye tracking data. While triggers are still sent to the EEG, messages are used as the corresponding events for the ET. Here, the ET computer is given a command to insert an ASCII text message (containing a keyword and the value of the corresponding EEG trigger) into the eye tracking data. In the stimulation software, the commands to send a trigger (to the EEG) and a message (to the ET) are given in immediate succession.

Analogue output A copy of the eye track is fed directly into the EEG. A digital-to-analogue converter card in the ET outputs (some of) the data as an analogue signal. With SMI, this signal can be fed directly into the EEG headbox. This requires a custom cable and resistors to scale the output voltage of the D/A converter to the EEG amplifier's recording range. While this method affords easy synchronisation, there are disadvantages: First, voltages need to be rescaled to pixels for analysis. Second, the ET signal may exceed the amplifier's recording range and electrical interference with the EEG is possible. Third, additional information from the ET (messages, eye movements detected online) is not available. Fourth, quality of the ET signal suffers considerably from the D/A and

subsequent A/D conversion. Finally, fewer channels remain to record the EEG (recording binocular gaze position and pupil diameter occupies six channels).

Basics: Synchronization signals

Send triggers and/or messages to align the recordings The toolbox requires that there are at least two shared events present in the ET and EEG: One near the beginning and one near the end of the recording. These events will be called start-event and end-event in the following. Eye tracking data in between the start-event and end-event will be linearly interpolated to match the sampling frequency of the EEG. We recommend to use a unique event value (e.g. "100") to mark the start-event and another unique event-value (e.g., "200") for the end-event. The remaining shared events (triggers or messages) sent during the experiment (between start-event and end-event) are used to evaluate the quality of synchronization. Synchronization is possible even if some intermediate events were lost during transmission.

Original sampling rates of EEG and ET do not need to be the same. The ET will be resampled to the sampling frequency of the EEG. For example, if the EEG was sampled at 500 Hz, and eye movements were recorded at 1000 Hz, the toolbox will downsample the eye track to 500 Hz. Since ET data outside of the synchronization range (before start-event, after end-event) cannot be interpolated, it is replaced by zeros. Please note that the EEG recording should not be paused during the experiment. [Clarification, April 2013: It is not a problem to pause the eye tracker recording, e.g. for recalibrations, because the time stamp assigned to each ET sample continues to increase even during the pause. However, the toolbox currently cannot recognize and handle pauses in the EEG recording. Therefore, the EEG recording should be continuous and must not be paused.]

Note: The current Beta version of the toolbox does not yet implement low-pass filtering of the eye track to prevent aliasing in case that the eye track is downsampled to a much lower EEG sampling rate. We plan to add this in the future.

If synchronization method 2 (messages plus trigger) is used, synchronization messages sent to the eye tracker need to have a specified format. This format consists of an arbitrary user-defined keyword (e.g., "MYKEYWORD") followed by an integer value ("MYKEYWORD 100"). The integer value needs to be the same as that of the corresponding trigger pulse sent to the EEG (usually an 8-bit number between 1 and 255). An example is given in the code below. The EYE-EEG parser (Step 2: Preprocess eye track and store as MATLAB) will recognize messages with the keyword and treat them as synchronization events. A keyword-synchronization messages should be sent together with every trigger sent to the EEG, so intermediate events in-between start-event and end-event can be used to assess synchronization quality. Additional messages (that do not contain the keyword) may be sent to code other aspects of the experimental design.

They are ignored by the toolbox.

The following code is an example for an experimental runtime file containing the necessary synchronization signals. The example is for the software Presentation[™], but similar commands exist in other software (e.g., Psychtoolbox, EPrime[™]):++

6 ACESSO A DATASETS FISIOLÓGICOS

Apesar da existência de fontes de datasets fisiológicos, o número de datasets disponíveis ainda é restrito. Sobre a qualidade dos datasets, Mendoza et al. (2021) observou que nenhum dos nove datasets disponíveis publicamente para treinamento de algoritmos de classificação de emoção analisados possuía todos os critérios de referência levantados por estudos anteriores. Apesar da ausência dessas referências, os datasets apresentaram uma base para desenvolvimentos futuros. Sobre a disponibilidade de datasets fisiológicos, Rim et al. (2020) faz uma análise de datasets públicos e privados. No exemplo apresentado na figura 3.1, é possível observar que datasets públicos combinando sinais são minoria nas diferentes fontes de dados analisadas.

O campo de neurociência computacional é um dos diversos campos beneficiados com o desenvolvimento da tecnologia, que constantemente melhora no sentido de propor novas ferramentas de captura de sinais fisiológicos e novas formas de processá-los. Diferentes equipamentos de EEG e ET implicam em uma diferente forma de se montar a coleta e processar os dados coletados. Embora surjam novos métodos, importantes considerações devem ser feitas a respeito da resolução de captura, de forma a não se deixar perder informação desejada.

6.1 AQUISIÇÃO DE DADOS FISIOLÓGICOS

Um exemplo de como se realizar a montagem para coleta de EEG e ET é demonstrado na figura 3.1, utilizado na montagem do dataset EEGEyeNet (Kastrati et al., 2021), onde o participante é colocado de frente para o monitor para apresentação de estímulos com o equipamento de coleta de EEG sobre a cabeça e o aparelho de ET direcionado aos olhos do participante. A piscada é comumente removida como artefato indesejável nos dados de EEG, fazendo parte de muitos pré-processamentos de estudos com EEG e ET (Hosseini, 2020). Entretanto, ET e EEG podem ser sincronizados a partir da assinatura da piscada, permitindo uma correção contínua dos dados (Bækgaard e Larsen, 2014). Outras formas de sincronização de EEG e ET também foram propostas, como por código temporal ou com auxílio de equipamentos externos – exploradas adiante.

Figura 3.2. Setup de coleta de EEG e ET. Fonte: Kastrati et al. (2021) A fusão

de dados pode ser realizada no nível de característica ou feature, assim como a nível de decisão do algoritmo classificatório (Klein, 2014; Mendes et al., 2016). explicadas adiante. Na figura 3.2. é possível observar um fluxo de processamento dos sinais capturados por diferentes sensores. Os diferentes sensores representados no estudo de Mendes et al. (2016) são aqui representados pela coleta de EEG e ET.

Figura 3.2. Exemplo de Fluxo para Fusão de Dados de Sensores. Fonte: Mendes et al. (2016). Na Feature Level Fusion (FLF), os dados de diversas fontes são extraídos dos sensores e unidos de forma a gerar um vetor único com informações multimodais; no Decision Fusion (DL) a classificação ocorre para cada categoria de fonte de dado (exemplo: uma classificação para EEG e outra para ET) e estas classificações são combinadas em um esquema de voto (exemplo: a classificação mais comum) para se chegar em uma categoria final (Bota et al., 2020). A respeito de qual formato seria melhor, Bota et al. (2020) explorou o assunto para cinco bases de dados fisiológicos classificados de acordo com o estímulo emocional apresentado ao participante e observou que o melhor método de fusão é altamente correlacionado à base dados, embora o FLF tenha sido escolhido como o melhor em função de sua baixa complexidade em relação ao DF. No estudo de Kastrati et al. (2021), dados de EEG e ET foram coletados por equipamentos com 500Hz de resolução e sincronizados por código, com auxílio do Eye EEG Toolbox para MATLAB. A sincronização foi confirmada pelo início de sinais registrados em ambos os equipamentos, apresentando erros menores que dois milissegundos.

7 APLICAÇÃO DE DATASETS FISIOLÓGICOS

O pré-processamento de EEG consiste em remoção de artefatos, tais como contração muscular e movimentação ocular. Um exemplo de pipeline de processamento para dados de EEG é apresentado na figura 3.3. A etapa de extração de características consiste em, partindo dos dados com remoção de artefatos indesejáveis, extrair métricas estatísticas, como média, mediana e desvio padrão aplicados a uma janela de tempo, ou outras métricas, como entropia de Shannon (como feito no estudo de Thapaliya et al. (2019)). A seleção de features pode envolver o uso de algoritmos que permitem reduzir o número de características a serem apresentadas como input ao algoritmo, como o Principal Component Analysis (PCA). A partir dessas etapas, os dados seguem são comumente divididos entre treinamento e teste, para validar o algoritmo ou algoritmos a serem estudados. O estudo de King et al. (2017) apresenta alguns exemplos de informações que podem ser extraídas de sinais fisiológicos capturados por sensores no quadro 3.1.s

7.1 AVALIAÇÃO DE ALGORITMOS

Após entender como deverá ser realizado o pré-processamento dos dados fisiológicos multimodais e sua união, é necessário entender de qual forma a avaliação do melhor método de sincronização será realizada. No presente estudo, o objetivo esperado é de se encontrar o melhor método de integrar os dados multimodais como sendo aquele que obtém uma maior acurácia dentre os algoritmos selecionados. O presente capítulo introduz o conceito de classificadores lineares, não lineares e das métricas de avaliação de algoritmos classificatórios.

Algoritmos classificatórios podem ser lineares ou não lineares. Classificadores lineares conseguem separar as categorias de dados em uma reta no espaço vetorial, seja ela com uma ou mais dimensões (reta, plano ou hiperplano). Um exemplo do que seriam dados linearmente separáveis e não podem ser observados na figura 4.1. Alguns algoritmos classificatórios bastante utilizados são introduzidos adiante. Para problemas mais complexos, é comum o uso de algoritmos que classifiquem dados não lineares, como o Support Vector Machine (SVM), K-Nearest Neighbor (KNN), Rede Neural Artificial (ANN) e Regressão Logística (RL).

Para a avaliação do algoritmo, a acurácia e precisão oferecem métricas para avaliar o erro observado do output (ou resultado) do modelo. Para isso, é necessário saber o valor real e o valor estimado pelo algoritmo classificatório. A acurácia mede a proximidade de um determinado valor e o valor de referência (ou valor real) (equação 4.1). A precisão mede a dispersão dos valores obtidos pelo modelo (equação 4.2). Um bom algoritmo é preciso e possui alta acurácia.

A performance de algoritmos classificatórios pode ser melhor observada através de uma matriz de confusão. Esta matriz permite observar onde o algoritmo mais erra, se em classificar verdadeiros positivos ou verdadeiros negativos. A matriz do exemplo é utilizada para classificadores binários, embora uma versão desta matriz possa ser utilizada para classificadores multicategóricos.

Em seu estudo sobre o uso de algoritmos para classificação de emoções a partir de dados fisiológicos, Zheng et al. (2014) coletou dados de dilatação da pupila, movimentação ocular e EEG para identificar qual seria a classificação do estímulo emocional apresentado aos participantes. O processo de coleta do estudo pode ser observado na figura 2. A classificação do estímulo apresentado (vídeo clips de 4 minutos de duração) obteve acurácia máxima de 73.59

Figura 5.4. Design de Experimento para Coleta de EEG e ET. Fonte: Zheng et al. (2014).

Lu et al. (2015) também faz uso de dados de EEG e RO para classificação de emoções nas três valências emocionais eleitas no estudo de Zheng et al. (2014). Em contraste com o volume de informações coletadas no estudo de Zheng et al., Lu et al. coletam uma maior quantidade de dados de rastreamento ocular – extraindo 16 métricas de RO, enquanto o estudo de Zheng foca em apenas métricas principais da dilatação ocular. Os resultados da acurácia do algoritmo aplicado aos diferentes métodos de fusão de dados multimodais estão resumidos na imagem 5.5, ficando evidente que, independente do método utilizado para fusão das modalidades de EEG e RO, as melhores acurácias foram encontradas para base de dados de mais de uma fonte de informação fisiológica.

Figura 5.5. Acurácia por Método de Fusão de Modalidade e Modalidade Única em Algoritmo Supervisionado. Fonte: Lu et. al. (2015). No trabalho de Thapaliya et al. (2019) dados de EEG e ET foram aplicados em algoritmos de máquina, com o objetivo de estudar uma melhora no método de diagnóstico de crianças com autismo através de diferentes formas de pré-processamento (exemplo de processamento do estudo na figura 5.6). Os dados de EEG tiveram suas métricas estatísticas coletadas para a construção de um vetor de características (incluindo desvio padrão e média por janela de tempo dos dados de EEG filtrados), assim como a entropia calculada por janela temporal. Para os dados de RO, os tempos de fixação foram coletados, em conjunto com o resultado de

testes cognitivos.

Figura 5.6. União de dados de EEG e ET. Fonte: Thapaliya et al. (2019). Em seu estudo, diferentes métodos de construção de vetores de características foram analisados, tanto para os dados unimodais quanto para a junção de EEG e ET. Através das acurácias apresentadas para os diferentes métodos de processamento, podemos observar que determinados algoritmos aumentaram sua acurácia a depender do modo no qual o vetor de características foi construído. Por exemplo, enquanto o algoritmo Support Vector Machine (SVM) atingiu 71% Lim e Chia (2015), estudaram a correlação de ondas EEG detectadas em um equipamento de eletrodo único e estresse cognitivo induzido pelo teste de Stroop. A análise foi feita com base na aplicação de três algoritmos: Artificial Neural Network, k-Nearest Neighbor (KNN) e Linear Discriminant Analysis (LDA), dos dados de EEG transformados pela aplicação da Transformação Cosseno Discreta (Discrete Cosine Transform – DCT). O KNN com o DCT conseguiu classificar melhor o estado de estresse do participante. O uso do MindWave Mobile 2 foi recentemente empregado para o controle de cadeira de rodas (Abuzaher e Al-Azzeh, 2021; Permana et al., 2019), controle de mão robótica e robô móvel (Purnamasari et al., 2019; Rusanu et al., 2019; Ruşanu et al., 2021) e predição de personalidade (Bhardwaj et al., 2021). Outro estudo com uso de eletrodo único como fonte de dados eletrofisiológicos foi o trabalho de Quesada-Tabares et al. (2017), onde foi demonstrado que o uso de EEG comercial e com eletrodo único também possui um importante poder classificatório quando aplicado em algoritmos. Em seu estudo, sete participantes observaram imagens selecionadas do International Affective Picture System (IAPS) pertencentes a três grupos com diferentes valores de valência e excitabilidade. O teste de ANOVA aplicado indicou uma diferença estatisticamente significativa entre os sets de imagens. Um segundo teste foi conduzido pela aplicação de um algoritmo de classificação no estilo árvore de decisão, chegando a uma acurácia média entre os sete participantes de 80.71%. Bos (2021) também explora o uso do MindWave no contexto escolar para medir a atenção dos alunos. Em seu estudo, o nível de atenção com alunos assistindo a um vídeo educacional sem e outro com interações (fazendo pergunta aos alunos) é explorado e a distribuição percentual das diferentes bandas de frequência são comparadas entre os grupos. Bos (2021) observou uma relativa diminuição banda de frequência de onda beta para o grupo que não assistiu ao vídeo interativo, o que foi relacionado a um processamento cognitivo reduzido e menor atenção. Bhardwaj et al. (2021) analisou o uso dos dados coletados com o MindWave para classificar sete traços de personalidade com o algoritmo deep long short term memory (DeepLSTM) e tratando os dados com transformada de Fourier Rápida. A pesquisa contou com 50 participantes (25 mulheres e 25 homens), com idades entre 18 e 46 anos, ao longo de cinco dias, e os dados foram coletados enquanto os participantes assistiam vídeos relacionados a traços de personalidade. Os traços foram separados de acordo com os tipos de personalidade

definidos no Myers-Briggs Type Indicator, e ao final de cada vídeo, o participante deveria dizer se concordavam, discordavam ou eram neutros aos questionários de personalidade sobre o traço proeminente no estímulo. O questionário de cada participante foi utilizado para determinar o traço de personalidade, que serviria para então classificar os dados em três possíveis outputs: (a) participante tem traço de personalidade apresentado no vídeo, (b) participante não tem traço apresentado de forma significativa e (c) participante tem traço oposto ao apresentado no vídeo.

5.6 CONSIDERAÇÕES FINAIS

Datasets multimodais tendem a performar melhor em algoritmos classificatórios que datasets unimodais. A forma de processamento dos dados também pode ter impactos na performance classificatórias dos algoritmos. Equipamentos comerciais já foram previamente utilizados em estudos de algoritmos classificatórios. É esperado que um método de fusão eficiente reflita em uma maior acurácia dos algoritmos treinados no dataset. Para comparar a eficácia de um determinado método de construção de bases de dados, cada uma das bases geradas no presente projeto terá a acurácia calculada e comparada com as demais bases de dados.

Outra forma de avaliação é através da curva ROC, ou Característica de Operação do Receptor. A curva é obtida a o se observar a variação da taxa de verdadeiros positivos (sensibilidade, ou Positivos Verdadeiros / Positivos Totais) em função de $1 -$ especificidade, ou taxa de falsos positivos (Positivos Falsos / Negativos Totais).

8 MATERIAIS E MÉTODOS

8.1 PROPOSTA DE FERRAMENTA

Dois equipamentos serão utilizados para construção da ferramenta de coleta sincronizada: Mindwave Mobile II da Neurosky Inc. e o GP3 da Gazepoint Inc., para a coleta de EEG e ET, respectivamente. Um código será construído de forma a permitir a coleta síncrona do movimento ocular e das ondas cerebrais pelos dois equipamentos comerciais. No presente capítulo as ferramentas serão apresentadas no que diz respeito às suas principais características, e especificidades do código de coleta serão apresentadas.

8.2 MINDWAVE MOBILE II

O equipamento (representado na figura 6.1) possui um eletrodo de coleta e um eletrodo de referência que ficam posicionados acima da sobrancelha esquerda e na orelha esquerda do participante, respectivamente. A posição do eletrodo de coleta em relação ao sistema de referência de posição de eletrodos (10-20), é o FP1, correspondendo a região Frontopolar 1. A coleta de dados do aparelho se dá por conexão via bluetooth e funciona em computadores Mac, Windows ou celulares Androids ou iOS, disponíveis em um raio de 10 metros. Ele coleta ondas cerebrais variando entre 3 e 100Hz, com uma frequência de 512Hz (NeuroSky Inc., 2015). O aparelho automaticamente distingue os dados coletados em ondas alfa, beta, gama, teta e delta; além de coletar informações subjetivas no formato de medidas de atenção e meditação, por meio de um algoritmo de reforço de aprendizado não disponibilizado ao público. Também mede a ativação muscular próxima ao eletrodo para estimar a qualidade do sinal. O MindWave Mobile filtra interferência elétrica e converte o sinal detectado pelo eletrodo em sinal digital. O chip que faz o filtro e conversão se chama ThinkGear, e permite a filtragem de ruído para interferência ativação muscular (EMG) e 50/60Hz de corrente alternada.

8.3 GAZEPOINT GP3

O GP3 é um equipamento comercial de coleta do movimento dos olhos, fabricado pela Gazepoint Inc (representado na figura 6.2). Possui software próprio para análise dos dados, além de ser possível realizar coleta de dados com linguagens de programação open-source. O GP3 funciona emitindo uma luz infravermelha (IR) diretamente nos olhos do participante e captando a reflexão da luz para localizar o ponto focal ao longo do tempo. Permite coletar a direção do olhar, número de fixações, tempo até a primeira fixação, taxa de piscadas, duração de piscadas, diâmetro da pupila, tempo de duração do olhar em um determinado ponto focal, objetos observados em uma imagem, entre outros (Gazepoint Inc.).

8.3.1 Especificações GP3

O Gazepoint GP3 estabelece sua conexão com o computador através de dois cabos USB - um cabo de energia e outro para dados. Seu posicionamento ideal é logo abaixo do monitor de estímulo. Para um melhor posicionamento, o fabricante sugere uma distância ideal de 65 cm dos olhos do participante até o equipamento. O GP3 possui as seguintes características, conforme especificado pelo fabricante:

- Acurácia de 0.5-1 grau de ângulo visual
- 60 Hz de frequência de atualização
- calibração de 5 e 9 pontos
- API
- Captura movimento de 25cm horizontais e 11cm verticais
- 15 cm de limite de profundidade de movimento

Para poder realizar a coleta dos dados, é necessário manter o Gazepoint Control (API do desenvolvedor) ligado.

8.3.2 Calibração GP3

Uma calibração é realizada pela própria API do equipamento, afim de estabelecer qual o apontamento ocular do participante. A calibração pode ser feita em 5 pontos ou 9 pontos no monitor de exibição de estímulo. Os pontos na tela são apresentados em sequência e o participante deve acompanhá-los com o olhar até a finalização da calibração.

Após a calibração ser concluída, a API calcula o erro do sistema em relação ao olhar para o olho esquerdo (em verde) e direito (vermelho).

8.3.3 Dados Capturados pelo GP3

Fixação: É um agrupamento de pontos focais do olhar que duram entre 20-300 ms (Brand, 2020).

Gaze Point: Gaze point é o ponto focal do usuário em um dado momento. No equipamento GP3 é gravado um ponto focal a cada aproximadamente 17 milissegundos. O ponto de gaze é gravado em relação as coordenadas x e y, que servem para identificar a posição do olhar na tela de experimento.

Sacada: Compreende a um movimento rápido dos olhos após a fixação, e pode ser medida através de pixels por segundo. O valor limite entre sacada e fixação é a velocidade de 1.8 pixels por segundo (George e Routray, 2016), onde acima é uma sacada e abaixo, uma fixação.

8.3.4 Avaliação da Qualidade dos Dados

Acurácia é a capacidade de medir a localização do olhar do usuário na tela.

Precisão é a habilidade de produzir movimentos consistentes.

8.4 MONTAGEM

6.5 MONTAGEM Para o uso do GP3, o software próprio do fabricante será utilizado, o Gazepoint Control. Para o uso do brainwave mobile 2, um aplicativo Windows será utilizado para atestar a conexão e apresentar a porta de saída da conexão bluetooth (porta COM), o NeuroExperiementer. Para a coleta simultânea, duas linguagens de programação serão utilizadas: MATLAB e Python, com o uso do Anaconda para gerenciamento de pacotes de interesse, no caso do desenvolvimento em Python. A montagem do setup será feita com base nas coletas realizadas para a construção dos datasets EE-GEyeNet e ZuCO, com o participante sentado frente a tela de apresentação de estímulos, e com os olhos posicionados a uma distância ideal do aparelho de. ET. O Gazepoint ficará distante do participante até o software próprio acusar distância ideal (sinalizado por um sinal verde no topo do software de regulação do equipamento). Para teste de coleta serão utilizados dois monitores: um para calibração e apresentação de imagens, e outro para o desenvolvimento de código e testagem (figura 6.3). Após verificar que ambos os equipamentos estão conectados ao computador, o ambiente de desenvolvimento será

ativado por terminal e a variável com o número de porta COM correspondente a atual conexão via bluetooth do Mindwave será alterado no respectivo código de teste. O código será então executado.

Figura 6.3 Montagem de Coleta. Fonte: Autoria Própria.

Tabela 6.1 Características Monitor utilizado na Coleta de Eye Tracking Monitor Video Interno conectado a Intel® HD Graphics 630 Resolução da área de trabalho 1920 x 1080 Resolução do sinal ativo 1920 x 1080 Taxa de atualização 60 Hz Intensidade de bits 6 bits Formato de cor RGB Espaço de cores Alcance dinâmico padrão

6.6 CRIAÇÃO E SINCRONIZAÇÃO DO DATASET O equipamento GP3 possui uma Application Programming Interface (API) própria, o Open Gaze API (Gazepoint®). A API é uma alternativa de se controlar o equipamento sem precisar do software pago também feito pela Gazepoint®. A API utiliza de um Transmission Control Protocol – Internet Protocol (TCP/IP) socket, que permite a comunicação entre a aplicação e o servidor (fonte dos dados de ET). O IP determina o endereço para o qual os dados serão enviados, e o TCP utiliza a arquitetura de rede para realizar o transporte. O formato de dado utilizado para a API é o Extensible Markup Language (XML), e pode ser implementado em outras linguagens, como Python. As portas utilizadas para a comunicação de forma padrão são: localhost (127.0.0.1) e port 4242.

Estas portas e a linguagem XML serão utilizadas para possibilitar o uso da linguagem Python e MATLAB para estabelecer a conexão e iniciar as principais funções da ferramenta GP3. No API o cliente tem duas tags de comunicação: GET e SET. Ao utilizar o SET o cliente pode alterar o valor de alguma variável. O comando GET não tem a possibilidade de alteração de valores. O servidor pode enviar dados para o cliente com diferentes tags: ACK, NACK, CAL e REC. As duas primeiras são geradas em resposta aos comandos de GET e SET (ACK – Sucesso e NACK – Falha). Os CAL são gerados com bases nas calibrações e REC serve para os dados gravados. Estas regras de escrita são utilizadas pelo código em Python para estabelecer o controle do GP3, permitindo que o código calibre o equipamento e estabeleça definições de variáveis.

Para o funcionamento adequado do Mindwave, é necessário instalar uma tecnologia chamada ThinkGear, que permite a troca de informações entre o equipamento e os softwares compatíveis e processa o sinal detectado pelo eletrodo. O ThinkGear também é responsável pelo cálculo dos chamados eSense Meteres, correspondendo aos dados de Atenção e Meditação (algoritmo não apresentado), em uma escala de 0 a 100. Sobre variações individuais, a Mindwave ressalta que: “algumas partes do algoritmo do eSense estão aprendendo dinamicamente e aplicando algoritmos de aprendizado de adaptação lenta para ajustar as flutuações naturais de cada indivíduo (...) permitindo que o sensor opere em condições pessoais e ambientais diversas, enquanto ainda oferece uma boa

acuracia e confiabilidade.”

Para a operação do Mindwave, também é necessário informar a frequência elétrica do país (no Brasil, 60Hz, mesmo que Estados Unidos e Canadá), o que o fabricante indica ser realizado pelo software Mindwave Mobile Tutorial. Esta frequência é definida com a intenção de ser removida dos dados coletados pelo Mindwave Mobile II, na forma de pré-processamento para remoção de artefatos (Mindwave®[®], 2018).

Após essas configurações iniciais o código será iniciado. A construção de código seguirá dois propósitos de testes de sincronização: por timecode e por coleta controlada por código. Uma representação da conexão do código com o equipamento é apresentada na figura 6.4, e um exemplo de construção de dataset pelo método citado acima é apresentado na figura 6.5.

8.4.1

8.5 OBSERVAÇÕES SOBRE QUADROS E TABELAS

Quadros e tabelas são de uso semelhante às figuras, no que diz respeito à numeração, uso de legenda, e necessidade de citar ao menos uma vez antes da ocorrência. No entanto, no caso dos quadros e tabelas a legenda deve ser colocada acima, e não abaixo como nas figuras.

A Tabela 8.1 ilustra esse uso. Observe que a citação de uma tabela específica (pelo número) é com a palavra “tabela” em maiúscula, ao contrário da referência a tabelas em geral. Note que em uma tabela as bordas são horizontais (não use bordas verticais para separar colunas), e não são necessárias bordas para separar cada linha. Separe apenas as linhas do início, fim, e dos indicadores dos campos presentes, como no exemplo. Podem ser usadas bordas horizontais para separar regiões distintas de dados (seções de dados), se necessário.

Tabela 8.1. Parâmetros utilizados na implementação do método de detecção de bordas proposto, em cada configuração considerada.

Configuração	Parâmetro		
	A	B	C
1	10	5	2
2	20	5	3
3	30	8	5

O Quadro 8.1 é um outro exemplo. Note que um quadro se diferencia de uma tabela pelo uso de campos fechados, por meio de linhas horizontais e verticais. As tabelas são mais usadas para dados quantitativos, enquanto quadrados são mais usados quando há descrições textuais (mesmo que haja dados quantitativos também).

Quadro 8.1. Exemplo de um quadro (retirado de [1]): *Variáveis explicativas que representam características socioeconômicas dos idosos.* Fonte: [1]

Variável	Descrição*	Categorização
Nível de escolaridade	Número de anos de estudo (A5a, A5b, A6)	Nenhum 1 a 7 anos 8 anos e mais
Tem seguro/plano privado de saúde?	Que tipo de seguro de saúde o(a) Sr.(a) tem? (F1)	Sim Não
Tem casa própria?	Esta casa é: (J2)	Sim Não
Uso de serviços de saúde	Durante os últimos 12 meses, aonde o(a) Sr.(a) foi quando se sentiu doente ou quando precisou fazer uma consulta de saúde? (F3)	Usou Não usou
Estado nutricional	Com relação a seu estado nutricional o(a) Sr.(a) se considera bem nutrido? (C22i)	Bem nutrido Não está bem nutrido

Fonte: Estudo SABE.

*Os códigos em parênteses na descrição das variáveis se referem à identificação da variável no banco de dados do Estudo SABE. [1]

9 RESULTADOS E DISCUSSÕES

Tabela 9.1. Fatores de qualidades medidos em função do número de amostras, nos testes de reconstrução realizados.

Número de amostras	Fator de qualidade
10	0.30
20	0.45
30	0.60
40	0.90
50	0.93

Tabela 9.2. Outro exemplo de tabela.

a	b	c	d	e
10	20	30	40	50
100	200	300	400	500

10 CONCLUSÃO

LISTA DE REFERÊNCIAS

- [1] M. M. F. Gomes. *Passado e presente: uma análise dos determinantes da mortalidade entre idosos com base nos dados da SABE 2000–2006*. Tese de doutorado, Centro de Desenvolvimento e Planejamento Regional, Faculdade de Ciências Econômicas, Universidade Federal de Minas Gerais – UFMG, 2011.

APÊNDICE A

EXEMPLO DE APÊNDICE

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

APÊNDICE B

OUTRO EXEMPLO DE APÊNDICE

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

ANEXO A

EXEMPLO DE ANEXO

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

OUTRO EXEMPLO DE ANEXO

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.