



Universidade de Brasília – UnB
Campus Gama – FGA
Programa de Pós-Graduação em Engenharia Biomédica

**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA E
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

ANA PAULA SANDES DE SOUZA

Orientador: DR. GERARDO ANTONIO IDROBO PIZO



UNB – UNIVERSIDADE DE BRASÍLIA

FGA – FACULDADE GAMA



**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

ANA PAULA SANDES DE SOUZA

ORIENTADOR: DR. GERARDO ANTONIO IDROBO PIZO

**DISSERTAÇÃO DE MESTRADO EM
ENGENHARIA BIOMÉDICA**

PUBLICAÇÃO: 011A/2022

BRASÍLIA/DF, AGOSTO DE 2022

UNB – UNIVERSIDADE DE BRASÍLIA

FGA – FACULDADE GAMA

PROGRAMA DE PÓS-GRADUAÇÃO

**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

ANA PAULA SANDES DE SOUZA

DISSERTAÇÃO DE MESTRADO SUBMETIDA AO PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA BIOMÉDICA DA UNIVERSIDADE DE BRASÍLIA, COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE MESTRE EM ENGENHARIA BIOMÉDICA

APROVADA POR:

Dr. Gerardo Antonio Idrobo Pizo

(Orientador)

DR^a. Marília Miranda Forte Gomes

(Examinador interno)

Dr. Membro Externo

(Examinador externo)

FICHA CATALOGRÁFICA

SOUZA, ANA

Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso [Distrito Federal], 2019.

27p., 210 × 297 mm (FGA/UnB Gama, Mestrado em Engenharia Biomédica, 2022).

Dissertação de Mestrado em Engenharia Biomédica, Faculdade UnB Gama, Programa de Pós-Graduação em Engenharia Biomédica.

1. Neurociência Computacional

2. Eletroencefalograma

3. Rastreamento Ocular

4. Sincronização de Sinais

I. FGA UnB/UnB.

II. Título (série)

REFERÊNCIA

SOUZA, ANA (2022). Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso. Dissertação de mestrado em engenharia biomédica, Publicação 011A/2022, Programa de Pós-Graduação, Faculdade UnB Gama, Universidade de Brasília, Brasília, DF, 27p.

CESSÃO DE DIREITOS

AUTOR: Ana Paula Sandes de Souza

TÍTULO: Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso

GRAU: Mestre

ANO: 2022

É concedida à Universidade de Brasília permissão para reproduzir cópias desta dissertação de mestrado e para emprestar ou vender tais cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte desta dissertação de mestrado pode ser reproduzida sem a autorização por escrito do autor.

anapaulasandes.s@gmail.com

Brasília, DF – Brasil

RESUMO

O eletroencefalograma (EEG) e o rastreamento ocular (ET) oferecem formas não-invasivas de se observar o comportamento do sistema nervoso e são importantes ferramentas na construção de bases de dados fisiológicos. O custo dos equipamentos de coleta e a sincronização dos dados coletados constituem gargalos na construção de datasets multimodais. Diferentes estudos relacionam a integração de dados fisiológicos a um maior poder classificatório em algoritmos de aprendizado supervisionado. O presente estudo observa os mais recentes métodos de sincronização de equipamentos de coleta e dados para a construção de datasets multimodais de EEG e ET, além de propor uma ferramenta de coleta simultânea de baixo custo que auxilie na construção de bases de dados fisiológicos. É esperado que uma forma acessível de construção de bases de dados multimodais incentive o desenvolvimento de novos algoritmos de aprendizado de máquina, e auxilie na criação de uma maior quantidade de datasets fisiológicos disponíveis para estudos futuros.

Palavras-chave: EEG; ET; Sincronização; Base de Dados Fisiológicos;

ABSTRACT

Electroencephalogram (EEG) and eye tracking (ET) are non-invasive ways of observing the nervous system behavior and are important tools in the construction of physiological databases. The equipment cost and synchronization of data are bottlenecks in the multimodal dataset construction. Studies relate physiological data integration to a higher classification accuracy in supervised learning algorithms. This study observes the latest methods of synchronizing data for building multimodal EEG and ET datasets through the usage of commercially available equipment. It is expected that an affordable way of building multimodal databases will encourage the development of new machine learning algorithms, and increase the amount of physiological datasets available for future studies.

Keywords: EEG; ET; Synchronization; Physiological Dataset;

SUMÁRIO

1	Introdução	1
1.1	Contextualização de Problema	1
1.2	Objetivos	2
1.2.1	Objetivos Específicos	2
1.3	Justificativa	2
1.4	Organização do Documento	3
2	Captura de Rastreamento Ocular	4
2.1	Anatomia Ocular	4
2.2	Equipamentos de Rastreamento	4
2.3	Calibração do Equipamento de Coleta	5
3	Séries Temporais	6
4	Sincronização	7
4.1	Frequência de Coleta	7
4.1.1	Frequência Nyquist	7
4.2	Sincronização com Timecode	7
4.3	Sincronização com Piscadas	8
4.3.1	Identificação no Sinal do EEG	8
4.3.2	Identificação no Sinal de ET	8
4.4	Correlação Cruzada	9
4.5	Códigos para Sincronização	9
5	Acesso a Datasets Fisiológicos	10

5.1	Aquisição de Dados Fisiológicos	10
6	Aplicação de Datasets Fisiológicos	12
6.1	Avaliação de Algoritmos	12
7	Materiais e Métodos	16
7.1	Proposta de Ferramenta	16
7.2	Mindwave Mobile II	16
7.3	Gazepoint GP3	17
7.3.1	Especificações GP3	17
7.3.2	Calibração GP3	17
7.3.3	Dados Capturados pelo GP3	18
7.3.4	Avaliação da Qualidade dos Dados	18
7.3.5	18
7.4	Dicas para o capítulo	19
7.5	Observações Sobre Quadros e Tabelas	19
8	Resultados e Discussões	21
9	Conclusão	22
	Lista de Referências	22
	Apêndice A	24
	Apêndice B	25
	Anexo A	26
	Anexo B	27

LISTA DE TABELAS

7.1	Parâmetros utilizados na implementação do método de detecção de bordas proposto, em cada configuração considerada.	19
8.1	Fatores de qualidades medidos em função do número de amostras, nos testes de reconstrução realizados.	21
8.2	Outro exemplo de tabela.	21

LISTA DE QUADROS

- 7.1 Exemplo de um quadro (retirado de [1]): *Variáveis explicativas que representam características socioeconômicas dos idosos*. Fonte: [1] 20

LISTA DE FIGURAS

LISTA DE NOMENCLATURAS E ABREVIACES

1 INTRODUÇÃO

Existe uma importante vantagem advinda do uso de bases fisiológicas chamadas multimodais, ou de mais de um tipo de dado fisiológico em algoritmos supervisionados: a possibilidade de conferir um maior poder classificatório em relação aos datasets unimodais (Kang et al., 2020; Thapaliya et al., 2019). Sobre os benefícios já alcançados com estes datasets, é possível citar: melhora de diagnóstico de transtornos neurológicos, como depressão e autismo (Kang et al., 2020; Thapaliya et al., 2019; Wu et al., 2021), maior poder de classificação de emoções (Guo et al., 2019; Zheng et al., 2019; Lu et al., 2015; Zheng et al., 2014), e uma maior compreensão da ativação de mecanismos nervosos durante atividades de rotina, como leitura (Hollenstein et al., 2018). Um modelo específico de dataset fisiológico multimodal é constituído do eletroencefalograma (EEG) e rastreamento ocular (RO ou ET, da palavra em inglês Eye Tracking). Seu uso no treinamento de algoritmos classificatórios atestou sua aplicabilidade em diferentes contextos clínicos e acadêmicos, além de um aumento de acurácia na classificação de diferentes doenças nervosas e de emoções.

1.1 CONTEXTUALIZAÇÃO DE PROBLEMA

Apesar das múltiplas vantagens, o acesso a estes datasets ainda é restrito. Sobre a coleta de EEG e ET, Kastrati et al. (2021) comenta:

“Coletar e classificar dados simultâneos de EEG e de rastreamento ocular é demorado e caro, pois requer equipamento e experiência para aquisição de EEG e rastreamento ocular. Portanto, o acesso a dados de EEG-ET gravados simultaneamente é altamente restrito, o que retarda significativamente o progresso neste campo”. – Kastrati et al. (2021).

A redução do custo das coletas fisiológicas já vem sendo abordada através de equipamentos comercialmente disponíveis. Um exemplo é o desenvolvimento de “smart watches”, pequenos computadores de pulso que permitem o acompanhamento da frequência cardíaca do usuário, além do monitoramento de outras atividades fisiológicas, como o sono. O Mindwave Mobile 2, do fabricante Neurosky®[®], é um exemplo de equipamento comercial que possibilita a captura de ondas cerebrais e métricas próprias do fabricante

utilizadas para estimar medidas de atenção, meditação e a captura de piscadas dos usuários. Este equipamento permite o desenvolvimento de aplicações na forma de jogos interativos, neurofeedback e outras aplicações lúdicas (Neurosky). A respeito de seu uso em pesquisas científicas, ele já foi utilizado para estimar quais métodos de ensino despertavam maior atenção em alunos do ensino fundamental, estimar personalidade de participantes através da apresentação de vídeo clips eleitos para instigar um determinado traço de personalidade, e classificação de emoções. Além deste equipamento para coleta de EEG, também existem equipamentos disponíveis comercialmente para a coleta de ET, como o GP3 (Gazepoint®).

Com o propósito de aumentar a acessibilidade aos datasets multimodais e suas amplas vantagens de uso, o presente projeto tem por objetivo a criação de uma ferramenta de coleta simultânea de EEG e RO acessível a partir da coleta de dados de dois equipamentos comerciais – GP3 para a coleta de RO, e Mindwave Mobile 2 para a coleta de dados de ativação neuronal. A ferramenta terá como output um dataset constituído de dados de EEG e RO coletados simultaneamente. O output será testado em um estudo de caso através da análise de performance de quatro diferentes algoritmos classificatórios treinados com o output para classificar entre duas possíveis atividades.

1.2 OBJETIVOS

Criar uma ferramenta capaz de gerar um dataset de EEG e ET coletado de forma síncrona e validar o dataset através da performance de algoritmos de aprendizado supervisionado treinados com ele.

1.2.1 Objetivos Específicos

1. Criar código para coleta simultânea de EEG e RO;
2. Criar dataset multimodal a partir da fusão de dados de EEG e RO coletados pela ferramenta e classificado de acordo com o estímulo apresentado ao participante;
3. Treinar diferentes algoritmos supervisionados com o dataset multimodal gerado;

1.3 JUSTIFICATIVA

Apesar da existência de técnicas que permitam a extração de mais de um modo de dados fisiológicos a partir de um equipamento apenas - como a extração da posição ocular a partir de assinaturas elétricas em dados de EEG, estes métodos necessitam de um grande volume de dados, o que exige equipamentos mais refinados e, por vezes, uma grande

disponibilidade de tempo para criação dos datasets e deslocamento de participantes até a estação de coleta. A coleta de ET e EEG por equipamento comercial e acessível, seria, portanto, uma alternativa que permite um maior controle no desenvolvimento de estudos com algoritmos de aprendizado de máquina, sem depender de equipamentos de alto custo ou deslocamento de participantes até a estação.

É argumentado que um maior acesso a construção de bases de dados multimodais poderá expandir e aprofundar os avanços em neurociência e estudos comportamentais, ao proporcionar um maior controle do design de experimento e expandir a quantidade de datasets fisiológicos gerados.

1.4 ORGANIZAÇÃO DO DOCUMENTO

O presente texto tem nove capítulos. O primeiro capítulo trata da contextualização do problema, objetivos gerais e específicos, e a justificativa para a abordagem selecionada.

O segundo capítulo trata do referencial teórico, levantando pontos históricos importantes ao desenvolvimento desta pesquisa, uma introdução ao que seriam os sinais capturados pelos dois equipamentos de EEG e ET, características dos diferentes tipos de equipamento de captura e aborda a conversão de sinais analógicos para digital.

O terceiro capítulo trata do processo da aquisição e do tratamento de sinais fisiológicos a serem classificados por algoritmos de aprendizado de máquina supervisionado – processos como remoção de ruído e seleção de características. Também aborda métodos de fusão de bases de dados de diferentes fontes - a nível de característica e a nível de decisão.

O quarto capítulo apresenta os métodos de avaliação dos algoritmos classificatórios.

O quinto capítulo aprofunda nos possíveis métodos de sincronização de coleta e de bases de dados.

O sexto capítulo introduz a proposta de ferramenta de coleta simultânea elaborada por código e aborda o método de sincronização off-line, com sincronização por código temporal.

O sétimo capítulo aborda o cronograma.

O oitavo capítulo aborda os resultados esperados do estudo.

O nono capítulo apresenta as referências do estudo.

2 CAPTURA DE RASTREAMENTO OCULAR

2.1 ANATOMIA OCULAR

O globo ocular é majoritariamente opaco, com exceção da córnea, que é transparente. A pupila é a região que dá passagem para a luz e possui diâmetro variável. Os músculos da íris são os que controlam a dilatação da pupila. A focalização da imagem deve se concentrar na fóvea, onde se encontram células muito sensíveis a luz (Helene e Helene, 2011). A fixação ocular compreende a um período de cerca de 100 milissegundos onde o olhar se fixa em um ponto de convergência (Barreto et al., 2012). Este período se encerra com o movimento de sacada, que compreende ao movimento rápido até uma nova fixação do olhar em outro local. Através da coleta do posicionamento ocular, é possível calcular uma taxa de dispersão focal ao longo do tempo e piscadas. Estes dados foram previamente correlacionados com estados emocionais (Soleymani et al., 2012) e também aplicados em estudos com algoritmos de aprendizado de máquina e deep learning. Barreto (2012) resumiu alguns dos principais termos utilizados em pesquisas de rastreamento ocular (RO):

2.2 EQUIPAMENTOS DE RASTREAMENTO

Para detectar onde o participante está focando seu olhar ao longo do tempo, alguns equipamentos de ET fazem uso de luz infravermelha e câmeras de alta definição que projetam a luz diretamente no olho do participante e gravam a direção do olhar a partir do reflexo. Como a luz infravermelha abrange um comprimento de onda não detectável pelo olho humano, o direcionamento desta luz no olho não interfere na visão do participante. O cálculo do direcionamento ocular é feito com base em algoritmos próprios de cada fabricante. Existem alguns tipos de equipamentos de rastreamento ocular. São eles: (1) Webcam, (2) Vestível (Wearable) e (3) Baseados em Tela. Webcam diz respeito a equipamentos não especializados para o uso de rastreamento; usáveis correspondem a equipamentos como óculos de rastreamento ocular e realidade virtual, e os baseados em tela dizem respeito aos equipamentos de coleta especializada que podem ser acoplados a um computador Tobii Pro (2020).

2.3 CALIBRAÇÃO DO EQUIPAMENTO DE COLETA

Como funciona a calibração

3 SÉRIES TEMPORAIS

Séries temporais são sequências de pontos ao longo do tempo, onde pontos vizinhos são dependentes (Ehlers, 2007). As séries podem ser contínuas ou discretas. Um exemplo de sinal contínuo é a diferença da voltagem de neurônios capturada por eletrodos ao longo do tempo.

4 SINCRONIZAÇÃO

O uso de equipamentos com função exclusiva de sincronização para coletas simultâneas é comum em pesquisas ambientes academicos e clínicos. A proposta de oferecer maior acessibilidade através da redução de custo e desenvolvimento de novas tecnologias encontra, portanto, um desafio a respeito de como realizar a sincronização dos dados fisiológicos sem abrir mão da praticidade e custo dos equipamentos desenvolvidos. Algumas propostas já foram exploradas a respeito, como o uso de piscadas e código temporal para garantir a sincronização de EEG e ET (Bækgaard et al. 2015, Notaro et al. 2018).

4.1 FREQUÊNCIA DE COLETA

Como os sinais analógicos são convertidos para sinais digitais, existe uma perda de informação por esta conversão. A **resolução de frequência** mede o espaço entre duas frequências.

$$srate/N$$

Srate = sampling rate N = Número de amostras

4.1.1 Frequência Nyquist

É a frequência mais rápida onde o sinal pode ser medido, onde é estabelecido que a maior frequência que podemos medir é a metade da frequência de coleta.s

4.2 SINCRONIZAÇÃO COM TIMECODE

Notaro et al. (2018) faz uso do código temporal, ou *timecode*, para sincronizar dados de EEG, ET e dados comportamentais coletados de participantes enquanto estes faziam atividades de um site de aprendizagem de linguas. O driver do fabricante do equipamento comercial de EEG utilizado permite alteração da latência da coleta de dados, que foi

modificada do valor padrão de 16 milissegundos para 1 milissegundo, afim de aumentar a precisão do equipamento. A informação da ocorrência de clicks no site foi retida na forma de milissegundos (HH:MM:SS:MsMsMs), e esta informação foi utilizada para sincronizar dados de ET, EEG e movimentação de mouse.

4.3 SINCRONIZAÇÃO COM PISCADAS

Piscadas duram cerca de 200 milissegundos em média e podem indicar estados de alerta (Caffier, 2013). Piscadas também aparecem em dados de EEG de forma característica, podendo alcançar uma amplitude de sinal acima de 200 microvolts em eletrodos próximos a órbita ocular (Hoffmann e Falkenstein, 2008). Assim sendo, é possível realizar uma sincronização por piscadas ao se detectar o movimento em ambos os equipamentos de coleta. No caso do EEG, as piscadas são comumente descartadas como artefatos indesejáveis. Já no estudo de Bækgaard et al. (2015), elas são a assinatura de sincronização entre os equipamentos de coleta de EEG e ET em função de sua onda característica (geralmente muitos milivolts acima do sinal do EEG), e de também ser detectado através dos equipamentos de rastreamento ocular.

4.3.1 Identificação no Sinal do EEG

Para se detectar a piscada através de um sinal, é possível tentar realizar o método de *Independent Component Analysis*, ou análise de componente independente, mas as características do sinal de piscada também permite outras abordagens, como a identificação por função de probabilidade. Considerando o movimento de maior característica da piscada, é preferível se calcular a probabilidade do movimento de fechar os olhos ao movimento de abertura, em função de uma variação em tempo ser mais comumente encontrada na fase de abertura (Caffier, 2013).

4.3.2 Identificação no Sinal de ET

Como o equipamento de rastreamento procura encontrar sinais da movimentação ocular, ele também detecta a ausência desse sinal. No estudo de Bækgaard et al. (2015), uma perda de até 500 milissegundos foi considerada como indicador da ocorrência de uma piscada. No equipamento de coleta de ET GP3, o fabricante oferece uma forma de identificar a existência de uma piscada. Ela ocorre através da propriedade *Blinking Validation Flag*, ou BKID, onde qualquer valor diferente de 0 indica ocorrência de piscada durante o timeframe. A extração de piscada através do BKID foi utilizada no estudo de Seha et al. (2019), onde o blink rate foi validado e sincronizado com o vídeo do próprio

equipamento (que indica quando houve piscada através da ausência da imagem dos olhos do usuário).

4.4 CORRELAÇÃO CRUZADA

A correlação cruzada procura calcular a similaridade entre dois sinais com a aplicação de um *delay* em apenas um dos sinais. Para correlacionar assinaturas diferentes, as probabilidades de ocorrência de um evento (piscada) em duas séries temporais são convertidas em uma mesma frequência amostral (Bækgaard et al., 2014). A similaridade entre sinais é medida na amplitude do sinal da correlação. A correlação cruzada é definida como:

$$(f * g) = f(-t) * g(t), \quad (4.1)$$

onde $*$ significa convolução e $f(-t)$ é o conjugado complexo de $f(t)$.

4.5 CÓDIGOS PARA SINCRONIZAÇÃO

Alguns equipamentos podem se beneficiar da existência de *toolboxes* ou bibliotecas direcionadas à sincronização. É o caso dos equipamentos Tobii na solução de EEG-Eye para a linguagem MATLAB. Uma forma de se fazer sincronização é através

5 ACESSO A DATASETS FISIOLÓGICOS

Apesar da existência de fontes de datasets fisiológicos, o número de datasets disponíveis ainda é restrito. Sobre a qualidade dos datasets, Mendoza et al. (2021) observou que nenhum dos nove datasets disponíveis publicamente para treinamento de algoritmos de classificação de emoção analisados possuía todos os critérios de referência levantados por estudos anteriores. Apesar da ausência dessas referências, os datasets apresentaram uma base para desenvolvimentos futuros. Sobre a disponibilidade de datasets fisiológicos, Rim et al. (2020) faz uma análise de datasets públicos e privados. No exemplo apresentado na figura 3.1, é possível observar que datasets públicos combinando sinais são minoria nas diferentes fontes de dados analisadas.

O campo de neurociência computacional é um dos diversos campos beneficiados com o desenvolvimento da tecnologia, que constantemente melhora no sentido de propor novas ferramentas de captura de sinais fisiológicos e novas formas de processá-los. Diferentes equipamentos de EEG e ET implicam em uma diferente forma de se montar a coleta e processar os dados coletados. Embora surjam novos métodos, importantes considerações devem ser feitas a respeito da resolução de captura, de forma a não se deixar perder informação desejada.

5.1 AQUISIÇÃO DE DADOS FISIOLÓGICOS

Um exemplo de como se realizar a montagem para coleta de EEG e ET é demonstrado na figura 3.1, utilizado na montagem do dataset EEGEyeNet (Kastrati et al., 2021), onde o participante é colocado de frente para o monitor para apresentação de estímulos com o equipamento de coleta de EEG sobre a cabeça e o aparelho de ET direcionado aos olhos do participante. A piscada é comumente removida como artefato indesejável nos dados de EEG, fazendo parte de muitos pré-processamentos de estudos com EEG e ET (Hosseini, 2020). Entretanto, ET e EEG podem ser sincronizados a partir da assinatura da piscada, permitindo uma correção contínua dos dados (Bækgaard e Larsen, 2014). Outras formas de sincronização de EEG e ET também foram propostas, como por código temporal ou com auxílio de equipamentos externos – exploradas adiante.

Figura 3.2. Setup de coleta de EEG e ET. Fonte: Kastrati et al. (2021) A fusão

de dados pode ser realizada no nível de característica ou feature, assim como a nível de decisão do algoritmo classificatório (Klein, 2014; Mendes et al., 2016). explicadas adiante. Na figura 3.2. é possível observar um fluxo de processamento dos sinais capturados por diferentes sensores. Os diferentes sensores representados no estudo de Mendes et al. (2016) são aqui representados pela coleta de EEG e ET.

Figura 3.2. Exemplo de Fluxo para Fusão de Dados de Sensores. Fonte: Mendes et al. (2016). Na Feature Level Fusion (FLF), os dados de diversas fontes são extraídos dos sensores e unidos de forma a gerar um vetor único com informações multimodais; no Decision Fusion (DL) a classificação ocorre para cada categoria de fonte de dado (exemplo: uma classificação para EEG e outra para ET) e estas classificações são combinadas em um esquema de voto (exemplo: a classificação mais comum) para se chegar em uma categoria final (Bota et al., 2020). A respeito de qual formato seria melhor, Bota et al. (2020) explorou o assunto para cinco bases de dados fisiológicos classificados de acordo com o estímulo emocional apresentado ao participante e observou que o melhor método de fusão é altamente correlacionado à base dados, embora o FLF tenha sido escolhido como o melhor em função de sua baixa complexidade em relação ao DF. No estudo de Kastrati et al. (2021), dados de EEG e ET foram coletados por equipamentos com 500Hz de resolução e sincronizados por código, com auxílio do Eye EEG Toolbox para MATLAB. A sincronização foi confirmada pelo início de sinais registrados em ambos os equipamentos, apresentando erros menores que dois milissegundos.

6 APLICAÇÃO DE DATASETS FISIOLÓGICOS

O pré-processamento de EEG consiste em remoção de artefatos, tais como contração muscular e movimentação ocular. Um exemplo de pipeline de processamento para dados de EEG é apresentado na figura 3.3. A etapa de extração de características consiste em, partindo dos dados com remoção de artefatos indesejáveis, extrair métricas estatísticas, como média, mediana e desvio padrão aplicados a uma janela de tempo, ou outras métricas, como entropia de Shannon (como feito no estudo de Thapaliya et al. (2019)). A seleção de features pode envolver o uso de algoritmos que permitem reduzir o número de características a serem apresentadas como input ao algoritmo, como o Principal Component Analysis (PCA). A partir dessas etapas, os dados seguem são comumente divididos entre treinamento e teste, para validar o algoritmo ou algoritmos a serem estudados. O estudo de King et al. (2017) apresenta alguns exemplos de informações que podem ser extraídas de sinais fisiológicos capturados por sensores no quadro 3.1.s

6.1 AVALIAÇÃO DE ALGORITMOS

Após entender como deverá ser realizado o pré-processamento dos dados fisiológicos multimodais e sua união, é necessário entender de qual forma a avaliação do melhor método de sincronização será realizada. No presente estudo, o objetivo esperado é de se encontrar o melhor método de integrar os dados multimodais como sendo aquele que obtém uma maior acurácia dentre os algoritmos selecionados. O presente capítulo introduz o conceito de classificadores lineares, não lineares e das métricas de avaliação de algoritmos classificatórios.

Algoritmos classificatórios podem ser lineares ou não lineares. Classificadores lineares conseguem separar as categorias de dados em uma reta no espaço vetorial, seja ela com uma ou mais dimensões (reta, plano ou hiperplano). Um exemplo do que seriam dados linearmente separáveis e não podem ser observados na figura 4.1. Alguns algoritmos classificatórios bastante utilizados são introduzidos adiante. Para problemas mais complexos, é comum o uso de algoritmos que classifiquem dados não lineares, como o Support Vector Machine (SVM), K-Nearest Neighbor (KNN), Rede Neural Artificial (ANN) e Regressão Logística (RL).

Para a avaliação do algoritmo, a acurácia e precisão oferecem métricas para avaliar o erro observado do output (ou resultado) do modelo. Para isso, é necessário saber o valor real e o valor estimado pelo algoritmo classificatório. A acurácia mede a proximidade de um determinado valor e o valor de referência (ou valor real) (equação 4.1). A precisão mede a dispersão dos valores obtidos pelo modelo (equação 4.2). Um bom algoritmo é preciso e possui alta acurácia.

A performance de algoritmos classificatórios pode ser melhor observada através de uma matriz de confusão. Esta matriz permite observar onde o algoritmo mais erra, se em classificar verdadeiros positivos ou verdadeiros negativos. A matriz do exemplo é utilizada para classificadores binários, embora uma versão desta matriz possa ser utilizada para classificadores multicategóricos.

Em seu estudo sobre o uso de algoritmos para classificação de emoções a partir de dados fisiológicos, Zheng et al. (2014) coletou dados de dilatação da pupila, movimentação ocular e EEG para identificar qual seria a classificação do estímulo emocional apresentado aos participantes. O processo de coleta do estudo pode ser observado na figura 2. A classificação do estímulo apresentado (vídeo clips de 4 minutos de duração) obteve acurácia máxima de 73.59

Figura 5.4. Design de Experimento para Coleta de EEG e ET. Fonte: Zheng et al. (2014).

Lu et al. (2015) também faz uso de dados de EEG e RO para classificação de emoções nas três valências emocionais eleitas no estudo de Zheng et al. (2014). Em contraste com o volume de informações coletadas no estudo de Zheng et al., Lu et al. coletam uma maior quantidade de dados de rastreamento ocular – extraindo 16 métricas de RO, enquanto o estudo de Zheng foca em apenas métricas principais da dilatação ocular. Os resultados da acurácia do algoritmo aplicado aos diferentes métodos de fusão de dados multimodais estão resumidos na imagem 5.5, ficando evidente que, independente do método utilizado para fusão das modalidades de EEG e RO, as melhores acurácias foram encontradas para base de dados de mais de uma fonte de informação fisiológica.

Figura 5.5. Acurácia por Método de Fusão de Modalidade e Modalidade Única em Algoritmo Supervisionado. Fonte: Lu et. al. (2015). No trabalho de Thapaliya et al. (2019) dados de EEG e ET foram aplicados em algoritmos de máquina, com o objetivo de estudar uma melhora no método de diagnóstico de crianças com autismo através de diferentes formas de pré-processamento (exemplo de processamento do estudo na figura 5.6). Os dados de EEG tiveram suas métricas estatísticas coletadas para a construção de um vetor de características (incluindo desvio padrão e média por janela de tempo dos dados de EEG filtrados), assim como a entropia calculada por janela temporal. Para os dados de RO, os tempos de fixação foram coletados, em conjunto com o resultado de

testes cognitivos.

Figura 5.6. União de dados de EEG e ET. Fonte: Thapaliya et al. (2019). Em seu estudo, diferentes métodos de construção de vetores de características foram analisados, tanto para os dados unimodais quanto para a junção de EEG e ET. Através das acurácias apresentadas para os diferentes métodos de processamento, podemos observar que determinados algoritmos aumentaram sua acurácia a depender do modo no qual o vetor de características foi construído. Por exemplo, enquanto o algoritmo Support Vector Machine (SVM) atingiu 71% Lim e Chia (2015), estudaram a correlação de ondas EEG detectadas em um equipamento de eletrodo único e estresse cognitivo induzido pelo teste de Stroop. A análise foi feita com base na aplicação de três algoritmos: Artificial Neural Network, k-Nearest Neighbor (KNN) e Linear Discriminant Analysis (LDA), dos dados de EEG transformados pela aplicação da Transformação Cosseno Discreta (Discrete Cosine Transform – DCT). O KNN com o DCT conseguiu classificar melhor o estado de estresse do participante. O uso do MindWave Mobile 2 foi recentemente empregado para o controle de cadeira de rodas (Abuzaher e Al-Azzeh, 2021; Permana et al., 2019), controle de mão robótica e robô móvel (Purnamasari et al., 2019; Rusanu et al., 2019; Ruşanu et al., 2021) e predição de personalidade (Bhardwaj et al., 2021). Outro estudo com uso de eletrodo único como fonte de dados eletrofisiológicos foi o trabalho de Quesada-Tabares et al. (2017), onde foi demonstrado que o uso de EEG comercial e com eletrodo único também possui um importante poder classificatório quando aplicado em algoritmos. Em seu estudo, sete participantes observaram imagens selecionadas do International Affective Picture System (IAPS) pertencentes a três grupos com diferentes valores de valência e excitabilidade. O teste de ANOVA aplicado indicou uma diferença estatisticamente significativa entre os sets de imagens. Um segundo teste foi conduzido pela aplicação de um algoritmo de classificação no estilo árvore de decisão, chegando a uma acurácia média entre os sete participantes de 80.71%. Bos (2021) também explora o uso do MindWave no contexto escolar para medir a atenção dos alunos. Em seu estudo, o nível de atenção com alunos assistindo a um vídeo educacional sem e outro com interações (fazendo pergunta aos alunos) é explorado e a distribuição percentual das diferentes bandas de frequência são comparadas entre os grupos. Bos (2021) observou uma relativa diminuição banda de frequência de onda beta para o grupo que não assistiu ao vídeo interativo, o que foi relacionado a um processamento cognitivo reduzido e menor atenção. Bhardwaj et al. (2021) analisou o uso dos dados coletados com o MindWave para classificar sete traços de personalidade com o algoritmo deep long short term memory (DeepLSTM) e tratando os dados com transformada de Fourier Rápida. A pesquisa contou com 50 participantes (25 mulheres e 25 homens), com idades entre 18 e 46 anos, ao longo de cinco dias, e os dados foram coletados enquanto os participantes assistiam vídeos relacionados a traços de personalidade. Os traços foram separados de acordo com os tipos de personalidade

definidos no Myers-Briggs Type Indicator, e ao final de cada vídeo, o participante deveria dizer se concordavam, discordavam ou eram neutros aos questionários de personalidade sobre o traço proeminente no estímulo. O questionário de cada participante foi utilizado para determinar o traço de personalidade, que serviria para então classificar os dados em três possíveis outputs: (a) participante tem traço de personalidade apresentado no vídeo, (b) participante não tem traço apresentado de forma significativa e (c) participante tem traço oposto ao apresentado no vídeo.

5.6 CONSIDERAÇÕES FINAIS

Datasets multimodais tendem a performar melhor em algoritmos classificatórios que datasets unimodais. A forma de processamento dos dados também pode ter impactos na performance classificatórias dos algoritmos. Equipamentos comerciais já foram previamente utilizados em estudos de algoritmos classificatórios. É esperado que um método de fusão eficiente reflita em uma maior acurácia dos algoritmos treinados no dataset. Para comparar a eficácia de um determinado método de construção de bases de dados, cada uma das bases geradas no presente projeto terá a acurácia calculada e comparada com as demais bases de dados.

Outra forma de avaliação é através da curva ROC, ou Característica de Operação do Receptor. A curva é obtida a o se observar a variação da taxa de verdadeiros positivos (sensibilidade, ou Positivos Verdadeiros / Positivos Totais) em função de $1 - \text{especificidade}$, ou taxa de falsos positivos (Positivos Falsos / Negativos Totais).

7 MATERIAIS E MÉTODOS

7.1 PROPOSTA DE FERRAMENTA

Dois equipamentos serão utilizados para construção da ferramenta de coleta sincronizada: Mindwave Mobile II da Neurosky Inc. e o GP3 da Gazepoint Inc., para a coleta de EEG e ET, respectivamente. Um código será construído de forma a permitir a coleta síncrona do movimento ocular e das ondas cerebrais pelos dois equipamentos comerciais. No presente capítulo as ferramentas serão apresentadas no que diz respeito às suas principais características, e especificidades do código de coleta serão apresentadas.

7.2 MINDWAVE MOBILE II

O equipamento (representado na figura 6.1) possui um eletrodo de coleta e um eletrodo de referência que ficam posicionados acima da sobrancelha esquerda e na orelha esquerda do participante, respectivamente. A posição do eletrodo de coleta em relação ao sistema de referência de posição de eletrodos (10-20), é o FP1, correspondendo a região Frontopolar 1. A coleta de dados do aparelho se dá por conexão via bluetooth e funciona em computadores Mac, Windows ou celulares Androids ou iOS, disponíveis em um raio de 10 metros. Ele coleta ondas cerebrais variando entre 3 e 100Hz, com uma frequência de 512Hz (NeuroSky Inc., 2015). O aparelho automaticamente distingue os dados coletados em ondas alfa, beta, gama, teta e delta; além de coletar informações subjetivas no formato de medidas de atenção e meditação, por meio de um algoritmo de reforço de aprendizado não disponibilizado ao público. Também mede a ativação muscular próxima ao eletrodo para estimar a qualidade do sinal. O MindWave Mobile filtra interferência elétrica e converte o sinal detectado pelo eletrodo em sinal digital. O chip que faz o filtro e conversão se chama ThinkGear, e permite a filtragem de ruído para interferência ativação muscular (EMG) e 50/60Hz de corrente alternada.

7.3 GAZEPOINT GP3

O GP3 é um equipamento comercial de coleta do movimento dos olhos, fabricado pela Gazepoint Inc (representado na figura 6.2). Possui software próprio para análise dos dados, além de ser possível realizar coleta de dados com linguagens de programação open-source. O GP3 funciona emitindo uma luz infravermelha (IR) diretamente nos olhos do participante e captando a reflexão da luz para localizar o ponto focal ao longo do tempo. Permite coletar a direção do olhar, número de fixações, tempo até a primeira fixação, taxa de piscadas, duração de piscadas, diâmetro da pupila, tempo de duração do olhar em um determinado ponto focal, objetos observados em uma imagem, entre outros (Gazepoint Inc.).

7.3.1 Especificações GP3

O Gazepoint GP3 estabelece sua conexão com o computador através de dois cabos USB - um cabo de energia e outro para dados. Seu posicionamento ideal é logo abaixo do monitor de estímulo. Para um melhor posicionamento, o fabricante sugere uma distância ideal de 65 cm dos olhos do participante até o equipamento. O GP3 possui as seguintes características:

- Acurácia de 0.5-1 grau de ângulo visual
- 60 Hz de frequência de atualização
- calibração de 5 e 9 pontos
- API
- Captura movimento de 25cm horizontais e 11cm verticais
- 15 cm de limite de profundidade de movimento

Para poder realizar a coleta dos dados, é necessário manter o Gazepoint Control (API do desenvolvedor) ligado.

7.3.2 Calibração GP3

Uma calibração é realizada pela própria API do equipamento, afim de estabelecer qual o apontamento ocular do participante. A calibração pode ser feita em 5 pontos ou 9 pontos no monitor de exibição de estímulo. Os pontos na tela são apresentados em sequência e o participante deve acompanhá-los com o olhar até a finalização da calibração.

Após a calibração ser concluída, a API calcula o erro do sistema em relação ao olhar para o olho esquerdo (em verde) e direito (vermelho).

7.3.3 Dados Capturados pelo GP3

Fixação É um agrupamento de pontos focais do olhar que duram entre 20-300 ms (Brand, 2020).

Gaze Point Gaze point é o ponto focal do usuário em um dado momento. No equipamento GP3 é gravado um ponto focal a cada aproximadamente 17 milissegundos. O ponto de gaze é gravado em relação as coordenadas x e y, que servem para identificar a posição do olhar na tela de experimento.

Sacada A sacada compreende a um movimento rápido dos olhos após a fixação.

7.3.4 Avaliação da Qualidade dos Dados

Acurácia é a capacidade de medir a localização do olhar do usuário na tela.

Precisão é a habilidade de produzir movimentos consistentes.

7.3.5

7.4 DICAS PARA O CAPÍTULO

Dicas importantes que devem ser contempladas neste capítulo, segundo [2]:

- Verificar se o capítulo responde as seguintes questões: Como? Com quê? Onde? Quanto?
- A linguagem do projeto deve ser escrita com tempo verbal no futuro e da dissertação no passado.
- É importante mencionar sobre: tipo de pesquisa (bibliográfica, descritiva, documental, experimental etc), dados (fonte de dados, forma de obtenção), população e amostra, tratamento e análise dos dados (descrição mais detalhada do método – ou métodos – que serão utilizados), limitações da pesquisa.

7.5 OBSERVAÇÕES SOBRE QUADROS E TABELAS

Quadros e tabelas são de uso semelhante às figuras, no que diz respeito à numeração, uso de legenda, e necessidade de citar ao menos uma vez antes da ocorrência. No entanto, no caso dos quadros e tabelas a legenda deve ser colocada acima, e não abaixo como nas figuras.

A Tabela 7.1 ilustra esse uso. Observe que a citação de uma tabela específica (pelo número) é com a palavra “tabela” em maiúscula, ao contrário da referência a tabelas em geral. Note que em uma tabela as bordas são horizontais (não use bordas verticais para separar colunas), e não são necessárias bordas para separar cada linha. Separe apenas as linhas do início, fim, e dos indicadores dos campos presentes, como no exemplo. Podem ser usadas bordas horizontais para separar regiões distintas de dados (seções de dados), se necessário.

Tabela 7.1. Parâmetros utilizados na implementação do método de detecção de bordas proposto, em cada configuração considerada.

Configuração	Parâmetro		
	A	B	C
1	10	5	2
2	20	5	3
3	30	8	5

O Quadro 7.1 é um outro exemplo. Note que um quadro se diferencia de uma tabela pelo uso de campos fechados, por meio de linhas horizontais e verticais. As tabelas são mais usadas para dados quantitativos, enquanto quadrados são mais usados quando há descrições textuais (mesmo que haja dados quantitativos também).

Quadro 7.1. Exemplo de um quadro (retirado de [1]): *Variáveis explicativas que representam características socioeconômicas dos idosos.* Fonte: [1]

Variável	Descrição*	Categorização
Nível de escolaridade	Número de anos de estudo (A5a, A5b, A6)	Nenhum 1 a 7 anos 8 anos e mais
Tem seguro/plano privado de saúde?	Que tipo de seguro de saúde o(a) Sr.(a) tem? (F1)	Sim Não
Tem casa própria?	Esta casa é: (J2)	Sim Não
Uso de serviços de saúde	Durante os últimos 12 meses, aonde o(a) Sr.(a) foi quando se sentiu doente ou quando precisou fazer uma consulta de saúde? (F3)	Usou Não usou
Estado nutricional	Com relação a seu estado nutricional o(a) Sr.(a) se considera bem nutrido? (C22i)	Bem nutrido Não está bem nutrido

Fonte: Estudo SABE.

*Os códigos em parênteses na descrição das variáveis se referem à identificação da variável no banco de dados do Estudo SABE. [1]

8 RESULTADOS E DISCUSSÕES

Tabela 8.1. Fatores de qualidades medidos em função do número de amostras, nos testes de reconstrução realizados.

Número de amostras	Fator de qualidade
10	0.30
20	0.45
30	0.60
40	0.90
50	0.93

Tabela 8.2. Outro exemplo de tabela.

a	b	c	d	e
10	20	30	40	50
100	200	300	400	500

9 CONCLUSÃO

LISTA DE REFERÊNCIAS

- [1] M. M. F. Gomes. *Passado e presente: uma análise dos determinantes da mortalidade entre idosos com base nos dados da SABE 2000–2006*. Tese de doutorado, Centro de Desenvolvimento e Planejamento Regional, Faculdade de Ciências Econômicas, Universidade Federal de Minas Gerais – UFMG, 2011.
- [2] M. de A. Marconi e E. M. Lakatos. *Fundamentos de Metodologia Científica*. Editora Atlas S. A., São Paulo, SP, 5^a edição, 2003.

APÊNDICE A

EXEMPLO DE APÊNDICE

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

APÊNDICE B

OUTRO EXEMPLO DE APÊNDICE

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

ANEXO A

EXEMPLO DE ANEXO

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

OUTRO EXEMPLO DE ANEXO

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.