



Universidade de Brasília – UnB
Campus Gama – FGA
Programa de Pós-Graduação em Engenharia Biomédica

**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA E
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

ANA PAULA SANDES DE SOUZA

Orientador: DR. GERARDO ANTONIO IDROBO PIZO



UNB – UNIVERSIDADE DE BRASÍLIA

FGA – FACULDADE GAMA



**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

ANA PAULA SANDES DE SOUZA

ORIENTADOR: DR. GERARDO ANTONIO IDROBO PIZO

**DISSERTAÇÃO DE MESTRADO EM
ENGENHARIA BIOMÉDICA**

PUBLICAÇÃO: 011A/2022

BRASÍLIA/DF, AGOSTO DE 2022

UNB – UNIVERSIDADE DE BRASÍLIA

FGA – FACULDADE GAMA

PROGRAMA DE PÓS-GRADUAÇÃO

**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

ANA PAULA SANDES DE SOUZA

DISSERTAÇÃO DE MESTRADO SUBMETIDA AO PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA BIOMÉDICA DA UNIVERSIDADE DE BRASÍLIA, COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE MESTRE EM ENGENHARIA BIOMÉDICA

APROVADA POR:

Dr. Gerardo Antonio Idrobo Pizo

(Orientador)

DR^a. Marília Miranda Forte Gomes

(Examinador interno)

Dr. Membro Externo

(Examinador externo)

FICHA CATALOGRÁFICA

SOUZA, ANA

Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso [Distrito Federal], 2019.

35p., 210 × 297 mm (FGA/UnB Gama, Mestrado em Engenharia Biomédica, 2022).

Dissertação de Mestrado em Engenharia Biomédica, Faculdade UnB Gama, Programa de Pós-Graduação em Engenharia Biomédica.

1. Neurociência Computacional

2. Eletroencefalograma

3. Rastreamento Ocular

4. Sincronização de Sinais

I. FGA UnB/UnB.

II. Título (série)

REFERÊNCIA

SOUZA, ANA (2022). Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso. Dissertação de mestrado em engenharia biomédica, Publicação 011A/2022, Programa de Pós-Graduação, Faculdade UnB Gama, Universidade de Brasília, Brasília, DF, 35p.

CESSÃO DE DIREITOS

AUTOR: Ana Paula Sandes de Souza

TÍTULO: Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso

GRAU: Mestre

ANO: 2022

É concedida à Universidade de Brasília permissão para reproduzir cópias desta dissertação de mestrado e para emprestar ou vender tais cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte desta dissertação de mestrado pode ser reproduzida sem a autorização por escrito do autor.

anapaulasandes.s@gmail.com

Brasília, DF – Brasil

RESUMO

O eletroencefalograma (EEG) e o rastreamento ocular (ET - *Eye Tracking*) são formas não-invasivas de se observar o comportamento do sistema nervoso através da coleta da atividade neural e posicionamento ocular ao longo do tempo. Desta forma, são importantes ferramentas na construção de bases de dados fisiológicos. Bases de dados com mais de um tipo de dado fisiológico conferem vantagens a respeito do uso em algoritmos classificatórios, apresentando uma maior acurácia do que algoritmos treinados com datasets unimodais. Apesar das vantagens de uso, o acesso a estes datasets ainda é restrito devido ao custo dos equipamentos e a complexidade da sincronização entre diferentes sensores. O presente estudo tem por objetivo apresentar uma ferramenta construída a partir de equipamentos comerciais que tem como *output* um dataset multimodal de EEG e ET coletados simultaneamente. É esperado que a ferramenta promova acessibilidade a datasets multimodais ao gerar uma coleta com equipamentos de baixo custo (relativo a equipamentos clínicos) e incentive o desenvolvimento de diferentes áreas de pesquisa que possam se beneficiar do acesso facilitado da coleta de dados fisiológicos. A ferramenta será avaliada a respeito de sua capacidade de sincronização de EEG e ET, e o dataset multimodal será utilizado para treinar algoritmos classificatórios no software Orange em um estudo de caso com apresentação de estímulos emocionais durante o momento de coleta. A performance dos algoritmos será utilizada para argumentar sobre a possível aplicabilidade da ferramenta em estudos futuros.

Palavras-chave: EEG; ET; Sincronização; Base de Dados Fisiológicos;

ABSTRACT

Electroencephalogram (EEG) and Eye Tracking (ET) are non-invasive methods of observing the nervous system behavior by monitoring neural activity and ocular positioning over time. They are important tools in the construction of physiological databases. Databases with more than one type of physiological data confer advantages in classification algorithms, presenting a greater accuracy than algorithms trained with unimodal datasets. However, access to these datasets is still restricted due to the equipment cost and synchronization complexity between different sensors. The present study aims to present a tool built from commercially available devices whose output is a multimodal dataset of EEG and ET collected simultaneously. The tool is expected to promote accessibility to multimodal datasets by generating a database from low-cost equipment (in comparison to clinical equipment) and encourage the development of different areas of research that can benefit from easier access to physiological data acquisition. The tool will be evaluated regarding its ability to synchronize EEG and ET, and the multimodal dataset will be evaluated in a case study with the participant being submitted to emotional stimuli to be classified by the trained algorithms in Orange software. The algorithms performance will be used to discuss about the tool applicability in future studies.

Keywords: EEG; ET; Synchronization; Physiological Dataset;

SUMÁRIO

1	Introdução	1
1.1	Contextualização de Problema	1
1.2	Objetivos	2
1.2.1	Objetivos Específicos	3
1.3	Justificativa	3
1.4	[REFAZER] Organização do Documento	3
2	Eletricidade Cerebral	5
2.1	Correntes Elétricas	5
2.2	Neurônios	5
2.2.1	Impulsos Nervosos e Potencial de Ação	7
2.3	Eletroencefalograma	8
2.3.1	Sistema Internacional 10/20 de Posicionamento de Eletrodos . . .	8
2.3.2	Tipos de Eletrodos para Captura de EEG	8
3	Rastreamento Ocular	9
3.1	Anatomia Ocular	9
3.2	Equipamentos de Rastreamento	10
3.3	Eletrooculograma	10
4	Sincronização	11
4.1	Frequência de Coleta	11
4.1.1	Frequência Nyquist	11
4.2	Sincronização com Timecode	11
4.3	Sincronização com Piscadas	12

4.3.1	Identificação no Sinal do EEG	12
4.3.2	Identificação no Sinal de ET	13
4.4	Métodos para Sincronização	13
4.4.1	Códigos para Sincronização	14
4.5	Correlação EEG e ET	14
5	Trabalhos Relacionados	17
5.1	Aquisição de Dados Fisiológicos	17
5.2	Uso e Avaliação de Algoritmos	18
6	Materiais e Métodos	22
6.1	Construção da Ferramenta	22
6.1.1	Mindwave Mobile II	22
6.1.2	Gazepoint GP3	23
6.1.3	Avaliação da Qualidade dos Dados	24
6.2	Coleta	24
6.3	Criação do Dataset	25
6.4	Observações Sobre Quadros e Tabelas	27
7	Resultados e Discussões	29
8	Conclusão	30
	Lista de Referências	30
	Apêndice A	32
	Apêndice B	33
	Anexo A	34
	Anexo B	35

LISTA DE TABELAS

6.1	Parâmetros utilizados na implementação do método de detecção de bordas proposto, em cada configuração considerada.	27
7.1	Fatores de qualidades medidos em função do número de amostras, nos testes de reconstrução realizados.	29
7.2	Outro exemplo de tabela.	29

LISTA DE QUADROS

- 6.1 Exemplo de um quadro (retirado de [1]): *Variáveis explicativas que representam características socioeconômicas dos idosos*. Fonte: [1] 28

LISTA DE FIGURAS

1.1	Exemplo de um acelerador linear utilizado no Hospital Universitário de Brasília.	2
2.1	Anatomia de um neurônio com destaque para área de sinapse entre neurônios. Fonte: Bear (2015)	6
2.2	Esquema Modelo Hodgkin-Huxley. Dentro: indicando espaço intracelular; fora: indicando espaço extracelular (imagem a esquerda). Direita: C = capacitor, R = resistor, E = Baterias. Na = Sódio, K = Potássio Fonte: Neuromal Dynamcs (2014)	7
2.3	Impulsos nervosos conduzidos em neurônios	7
6.1	Montagem de Estudo de Caso da Ferramenta de Coleta EEG-ET.	25

LISTA DE NOMENCLATURAS E ABREVIACES

1 INTRODUÇÃO

Existe uma importante vantagem advinda do uso de bases fisiológicas chamadas multimodais, ou de mais de um tipo de dado fisiológico em algoritmos supervisionados: a possibilidade de conferir um maior poder classificatório em relação aos datasets unimodais (Kang et al., 2020; Thapaliya et al., 2019). Sobre os benefícios já alcançados com estes datasets, é possível citar: melhora de diagnóstico de transtornos neurológicos, como depressão e autismo (Kang et al., 2020; Thapaliya et al., 2019; Wu et al., 2021), maior poder de classificação de emoções (Guo et al., 2019; Zheng et al., 2019; Lu et al., 2015; Zheng et al., 2014), e uma maior compreensão da ativação de mecanismos nervosos durante atividades de rotina, como leitura (Hollenstein et al., 2018). Um modelo específico de dataset fisiológico multimodal é constituído do eletroencefalograma (EEG) e rastreamento ocular (RO ou ET, da palavra em inglês *Eye Tracking*), já tendo sido utilizado em diferentes estudos de aprendizado supervisionado e estudos de *Brain Computer Interface*, ou BCI; onde a integração homem-máquina é aprofundada (Xu et al., 2022; Kim et al., 2015; Lee et al., 2010).

1.1 CONTEXTUALIZAÇÃO DE PROBLEMA

Apesar das múltiplas vantagens, o acesso a estes datasets ainda é restrito. Sobre a coleta de EEG e ET, Kastrati et al. comenta:

*“Coletar e classificar dados simultâneos de EEG e de rastreamento ocular é **demorado e caro**, pois requer equipamento e experiência [...]. Portanto, o acesso a dados de EEG-ET gravados simultaneamente é **altamente restrito**, o que retarda significativamente o progresso neste campo”. – Kastrati et al. (2021).*

No recente estudo sobre a análise conjunta de dados de EEG e ET por Dimigen e Ehinger (2020) foram levantados quatro principais problemas com este tipo de coleta (figura 1.1):

- Integração de dados
- A remoção de artefatos

- Controle de sobreposição temporal de respostas cerebrais
- Controle de influências de baixo-nível




Figura 1.1. Principais problemas de integração em datasets de EEG e ET. Fonte: Dimigen e Ehinger (2020).

Para auxiliar nos problemas levantados, a solução dos autores consistiu na construção de códigos especializados (o pacote EYE-EEG), que trabalham de forma integrada a uma *toolbox* já consolidada em estudos de EEG, o EEGLAB (Delorme e Makeig, 2014) - a ser explorada adiante. A redução do custo das coletas fisiológicas já vem sendo abordada através de equipamentos comercialmente disponíveis. Um exemplo é o desenvolvimento de “*smart watches*”, pequenos computadores de pulso que permitem o acompanhamento da frequência cardíaca do usuário, além do monitoramento de outras atividades fisiológicas, como o sono (Canaltech, 2022). O Mindwave Mobile II (Neurosky, Vale do Silício, CA, Estados Unidos), é um exemplo de equipamento comercial que possibilita a captura de ondas cerebrais, além de métricas próprias do fabricante utilizadas para estimar atenção, meditação e a captura de piscadas dos usuários. Atualmente também existem equipamentos disponíveis comercialmente para a coleta de ET, como o GP3 (Gazepoint, Vancouver, BC, Estados Unidos).

Com o propósito de aumentar a acessibilidade aos datasets multimodais e suas amplas vantagens de uso, o presente projeto tem por objetivo a criação de uma ferramenta de coleta simultânea de EEG e ET acessível a partir da coleta de dados de dois equipamentos comerciais – GP3 e Mindwave Mobile II. A ferramenta construída tem como *output* uma base de dados multimodal utilizada para treinamento de algoritmos classificatórios com o auxílio do software de mineração de dados Orange (Demsar et al., 2013), e terão seus resultados apresentados adiante no texto.

1.2 OBJETIVOS

Criar uma ferramenta a partir de equipamentos comerciais que gere um dataset fisiológico multimodal com dados de EEG e ET.

1.2.1 Objetivos Específicos

- Criar código para coleta simultânea de EEG e ET;
- Criar dataset multimodal a partir da fusão de dados de EEG e ET coletados pela ferramenta;
- Avaliar o erro de sincronização, precisão e acurácia da ferramenta;
- Realizar um estudo de caso com a aplicação do dataset gerado pela ferramenta para treinar algoritmos classificatórios;
- Avaliar a performance dos algoritmos treinados para discutir a usabilidade da ferramenta em estudos futuros;

1.3 JUSTIFICATIVA

A capacidade de coletar dados de forma simplificada e de baixo custo pode abrir espaço para novas investigações científicas e também favorecer uma maior e mais representativa volumetria da população de estudo por eliminar a necessidade de deslocamento do participante à centros com os equipamentos (Brand et al., 2020). Ferramentas que gerem datasets multimodais também podem conferir vantagens na aplicação de iniciativas de aprendizado de máquina, *Brain Computer Interface* (BCI) e efomentar avanços na área de Inteligência Artificial (IA) por promover bases de dados onde os algoritmos possam ser treinados.

De forma geral, os benefícios da solução se concentram em:

- Aumento da acessibilidade à estação de coleta, tanto por participantes quanto por pesquisadores;
- Aumento da volumetria de dados;
- Maior disponibilidade de bases de dados fisiológicos para incentivar o desenvolvimento de outras frentes de estudo;

1.4 [REFAZER] ORGANIZAÇÃO DO DOCUMENTO

O presente texto tem capítulos. O primeiro capítulo trata da contextualização do problema, objetivos gerais e específicos, e a justificativa para a abordagem selecionada.

O segundo capítulo trata do referencial teórico, levantando pontos históricos importantes ao desenvolvimento desta pesquisa, uma introdução ao que seriam os sinais

capturados pelos dois equipamentos de EEG e ET, características dos diferentes tipos de equipamento de captura e aborda a conversão de sinais analógicos para digital.

O terceiro capítulo trata do processo da aquisição e do tratamento de sinais fisiológicos a serem classificados por algoritmos de aprendizado de máquina supervisionado – processos como remoção de ruído e seleção de características. Também aborda métodos de fusão de bases de dados de diferentes fontes - a nível de característica e a nível de decisão.

O quarto capítulo apresenta os métodos de avaliação dos algoritmos classificatórios.

O quinto capítulo aprofunda nos possíveis métodos de sincronização de coleta e de bases de dados.

O sexto capítulo introduz a proposta de ferramenta de coleta simultânea elaborada por código e aborda o método de sincronização off-line, com sincronização por código temporal.

O sétimo capítulo aborda o cronograma.

O oitavo capítulo aborda os resultados esperados do estudo.s

O nono capítulo apresenta as referencias do estudo.

2 ELETRICIDADE CEREBRAL

2.1 CORRENTES ELÉTRICAS

A eletricidade é o nome dado a uma série de fenômenos que envolvem o fluxo de cargas elétricas (Gaspar, 2005). O potencial elétrico (também conhecido como tensão), é a quantidade de energia precisa para deslocar uma carga elétrica (Matias e Fratezzi, 2008). A diferença de potencial elétrico entre um material condutor gera um fluxo de cargas nomeado de **corrente elétrica** (Creder, 1989). A intensidade do fluxo é medida em ampère (A) e determinada pela quantidade de partículas que atravessam o seguimento do condutor pelo tempo. As correntes podem ser contínuas ou alternadas, a depender se o sentido da corrente varia ou não; enquanto a corrente contínua é composta de polos, a alternada é composta de fases (Bhargava e Kulshreshtha, 1983). O cálculo de corrente elétrica é dado pela seguinte equação:

$$I = \frac{\Delta Q}{\Delta T}, \quad (2.1)$$

onde ΔQ é a quantidade de partículas que passam em um seguimento do condutor e ΔT indica o tempo.

2.2 NEURÔNIOS

Os neurônios são células responsáveis pela condução de impulsos nervosos e se comportam como um “cabo eletrificado” - analogia levantada a respeito da condução de impulsos elétricos, como apresentado no clássico estudo de Hodgkin e Huxley (1952), que teve como resultado uma modelagem dos potenciais de ação emitidos pelas células nervosas através de equações diferenciais não-lineares (figura 2.2). Os neurônios comunicam-se uns com os outros através das **sinapses**, onde ocorre a transmissão dos impulsos nervosos. É possível distinguir três partes anatómicas no neurônio: o corpo celular, o axônio e os dendrito (figura 2.1).

A membrana celular permite a passagem de cargas elétricas através de canais, que podem ou não necessitar de energia para a movimentação das cargas. **Capacitores** são




Figura 2.1. Anatomia de um neurônio com destaque para área de sinapse entre neurônios. Fonte: Bear (2015)

dispositivos de polaridades diferentes nas extremidades, que armazenam cargas elétricas num campo elétrico (Serway, 2008). Por sua capacidade de separar cargas elétricas entre o ambiente interno e externo, a membrana celular age como os capacitadores, com sua capacitância (habilidade de armazenar cargas elétricas), definida pela seguinte equação:

$$C = \frac{Q}{\Delta V}, \quad (2.2)$$

onde C é a capacitância, Q é a quantidade de carga armazenada e ΔV é a tensão elétrica, medida em farad (F). **Resistência elétrica** diz respeito a capacidade de oposição a passagem de corrente elétrica e é medido em ohms (Ω). Os canais da membrana podem se comportar como resistores, se opondo a passagem da corrente elétrica, e sua resistência pode variar dependendo das condições celulares, como por exemplo se o canal está aberto ou não. Na figura 2.2, E representa **bateria** pois a concentração de íons (partículas elétricas) é diferente no meio intra e extracelular, graças ao trabalho de canais ativos (com custo de energia para manter esse diferencial). De forma simplificada, a corrente aplicada no neurônio pode injetar corrente no capacitor e também ser distribuída pelos canais. Dado a definição de um capacitor, $I_c = du/dt$, é possível definir a corrente elétrica em uma seção da membrana como:

$$C \frac{du}{dt} = - \sum_k I_k(t) + I(t), \quad (2.3)$$

onde u = voltagem ao longo da membrana e t = tempo.




Figura 2.2. Esquema Modelo Hodgkin-Huxley. Dentro: indicando espaço intracelular; fora: indicando espaço extracelular (imagem a esquerda). Direita: C = capacitor, R = resistor, E = Baterias. Na = Sódio, K = Potássio Fonte: Neuromal Dynamics (2014)

2.2.1 Impulsos Nervosos e Potencial de Ação

Para passar informações, os neurônios geram **impulsos nervosos**, ou alterações no potencial elétrico de sua membrana. Este sinal elétrico ocorre quando o estímulo recebido pelo neurônio ultrapassa um limiar de ativação, que desencadeia uma série de respostas celulares. A célula pode estar em repouso (com valor do interior celular em cerca de -70mV), passando por despolarização (quando ocorre um fluxo de cargas elétricas que faz com que o meio intracelular passe a ser positivo em relação ao meio extracelular), e em repolarização, quando a célula está retornando ao potencial de repouso, como representado na figura 2.3.

O aumento do inicial da voltagem é causado pela entrada de sódio através de canais dependentes de voltagem, que se segue pela perda de potássio e fechamento dos canais de sódio.




Figura 2.3. Resumo do potencial de ação. Fonte: Bear (2015).

2.3 ELETROENCEFALOGRAMA

O conjunto de impulsos nervosos de grupos de neurônios geram campos magnéticos que podem ser captados por eletrodos colocados sobre a cabeça humana (Kandel, 2000). Estes campos magnéticos foram primeiro registrados de coletas em humanos aproximadamente em 1929, em um experimento conduzido pelo psiquiatra alemão Hans Berger (Ince et al., 2021) – figura 2.4. Estes registros são o resultado dos potenciais de ação emitidos pelas células nervosas abaixo do eletrodo, e permitem uma boa resolução temporal do comportamento nervoso (podendo atingir precisão de milissegundos), mas em geral não permitem uma boa resolução espacial (como identificar a localização espacial do grupo celular responsável pela variação de voltagem observada).




Figura 2.4. Primeiro EEG registrado em humanos, resultado do trabalho do psiquiatra Hans Berger. Fonte: Ince et al. (2021).

2.3.1 Sistema Internacional 10/20 de Posicionamento de Eletrodos

A técnica de registro de EEG vem sendo desde então aperfeiçoada e escolhida em investigações comportamentais devido a sua natureza não invasiva. Um exemplo de aperfeiçoamento foi a criação de um sistema internacional de posicionamentos de eletrodos para a coleta de EEG – o sistema 10/20 (Klem et al., 1999), representado na figura 2.5. O registro capturado nos eletrodos advém de uma diferença de potencial elétrico. Esta diferença pode ser em referência à um eletrodo colocado em uma região externa ao escalpo (como orelha), ou à uma voltagem média comum (Tavares, 2011).

2.3.2 Tipos de Eletrodos para Captura de EEG

Existem diferentes tipos de eletrodos para a captura de EEG. Um resumo é apresentado na tabela 2.1. É notável também que com o desenvolvimento da capacidade computacional, novos recursos e métodos para a análise destes dados vem sendo benéficos à construção do conhecimento científico, agora também contando com o desenvolvimento de algoritmos de aprendizado de máquina, aprendizado profundo e inteligência artificial.

3 RASTREAMENTO OCULAR

3.1 ANATOMIA OCULAR

O globo ocular é majoritariamente opaco, com exceção da córnea, que é transparente. A pupila é a região que dá passagem para a luz e possui diâmetro variável. Os músculos da íris são os que controlam a dilatação da pupila. A focalização da imagem deve se concentrar na fóvea, onde se encontram células muito sensíveis à luz (Helene e Helene, 2011). A fixação ocular compreende um período de cerca de 100 milissegundos onde o olhar se fixa em um ponto de convergência (Barreto et al., 2012). Este período se encerra com o movimento de sacada, que compreende um movimento rápido até uma nova fixação do olhar em outro local. Através da coleta do posicionamento ocular, é possível calcular uma taxa de dispersão focal ao longo do tempo e piscadas. Estes dados foram previamente correlacionados com estados emocionais (Soleymani et al., 2012) e também aplicados em estudos com algoritmos de aprendizado de máquina e *deep learning*.




Figura 3.1. Representação de polaridades no olho humano. Fonte: López et al. (2019)

3.2 EQUIPAMENTOS DE RASTREAMENTO

Para detectar onde o participante está focando seu olhar ao longo do tempo, alguns equipamentos de ET fazem uso de luz infravermelha e câmeras de alta definição que projetam a luz diretamente no olho do participante e gravam a direção do olhar a partir do reflexo. Como a luz infravermelha abrange um comprimento de onda não detectável pelo olho humano, o direcionamento desta luz no olho não interfere visão do participante. O cálculo do direcionamento ocular é feito com base em algoritmos próprios de cada fabricante. Existem alguns tipos de equipamentos de rastreamento ocular. São eles: (1) Webcam, (2) Vestível (Wearable) e (3) Baseados em Tela. Webcam diz respeito a equipamentos não especializados para o uso de rastreamento; usáveis correspondem a equipamentos como óculos de rastreamento ocular e realidade virtual, e os baseados em tela dizem respeito aos equipamentos de coleta especializada que podem ser acoplados a um computador (Tobii, 2020).

3.3 ELETROOCULOGRAMA

Também é possível detectar a movimentação ocular através de registros elétricos no exame de EEG. Isto ocorre devido às características elétricas do olho, que se comporta como um dipolo (possui duas cargas diferentes separadas), com a córnea sendo o polo positivo e a retina o negativo (López et al., 2019). Isto faz com que seja possível capturar a movimentação ocular ao colocar os eletrodos próximos aos olhos, como na figura 2.6. É possível observar picos de voltagem positiva identificados por eletrodos colocados na posição vertical e picos negativos e positivos identificados por eletrodos na posição horizontal, acompanhando movimentos de sacada do participante.

A diferença de potencial entre regiões é chamado de *standing potential*, que mede a diferença entre o potencial de membrana da base e topo do epitélio de pigmento da retina (Ramkumar et al., 2022).




Figura 3.2. Representação de polaridades no olho humano. Fonte: López et al. (2019)

4 SINCRONIZAÇÃO

O uso de equipamentos com função exclusiva de sincronização para coletas simultâneas é comum em pesquisas ambientes academicos e clínicos. A proposta de oferecer maior acessibilidade através da redução de custo e desenvolvimento de novas tecnologias encontra, portanto, um desafio a respeito de como realizar a sincronização dos dados fisiológicos sem abrir mão da praticidade e custo dos equipamentos desenvolvidos. Algumas propostas já foram exploradas a respeito, como o uso de piscadas e código temporal para garantir a sincronização de EEG e ET (Bækgaard et al. 2015, Notaro et al. 2018).

4.1 FREQUÊNCIA DE COLETA

Como os sinais analógicos são convertidos para sinais digitais, existe uma perda de informação por esta conversão. A **resolução de frequência** mede o espaço entre duas frequências.

$$srate/N$$

Srate = sampling rate N = Número de amostras

4.1.1 Frequência Nyquist

É a frequência mais rápida onde o sinal pode ser medido, onde é estabelecido que a maior frequência que podemos medir é a metade da frequência de coleta.s

4.2 SINCRONIZAÇÃO COM TIMECODE

Notaro et al. (2018) faz uso do código temporal, ou *timecode*, para sincronizar dados de EEG, ET e dados comportamentais coletados de participantes enquanto estes faziam atividades de um site de aprendizagem de linguas. O driver do fabricante do equipamento comercial de EEG utilizado permite alteração da latência da coleta de dados, que foi

modificada do valor padrão de 16 milissegundos para 1 milissegundo, afim de aumentar a precisão do equipamento. A informação da ocorrência de clicks no site foi retida na forma de milissegundos (HH:MM:SS:MsMsMs), e esta informação foi utilizada para sincronizar dados de ET, EEG e movimentação de mouse.

4.3 SINCRONIZAÇÃO COM PISCADAS

Piscadas duram cerca de 200 milissegundos em média e podem indicar estados de alerta (Caffier, 2013). Piscadas também aparecem em dados de EEG de forma característica, podendo alcançar uma amplitude de sinal acima de 200 microvolts em eletrodos próximos a órbita ocular (Hoffmann e Falkenstein, 2008). Assim sendo, é possível realizar uma sincronização por piscadas ao se detectar o movimento em ambos os equipamentos de coleta. No caso do EEG, as piscadas são comumente descartadas como artefatos indesejáveis. Já no estudo de Bækgaard et al. (2015), elas são a assinatura de sincronização entre os equipamentos de coleta de EEG e ET em função de sua onda característica (geralmente muitos milivolts acima do sinal do EEG), e de também ser detectado através dos equipamentos de rastreamento ocular.

O desafio da sincronização de EEG e ET se dá em função de serem séries temporais muito distintas e de frequências de amostra diferentes. No caso dos equipamentos comerciais de interesse desta pesquisa, a coleta de EEG pode ser realizada em até 512 Hz, enquanto a frequência de coleta de ET chega num máximo de 60 Hz. Além disso, o sinal de EEG pode apresentar mais de um canal, enquanto dados de ET podem ser representados na forma de coordenadas. Desta forma, Bækgaard et al. (2015) propõe uma sincronização por assinaturas dentro de cada um dos tipos de dados coletados. Piscadas ocorrem com frequência e de forma espontânea, além de ser uma informação capturada em equipamentos de EEG e ET.

4.3.1 Identificação no Sinal do EEG

A piscada envolve ativação muscular, e o dipolo ocular também influencia na captura de alterações de voltagem em eletrodos próximos aos olhos (Croft e Barry, 2000). Seu reflexo no EEG pode ser facilmente identificado pois tende a ter uma amplitude e forma de sinal característicos. A amplitude de uma atividade de piscada no sinal de EEG tem uma média de 200 microvolts (Hoffmann et al., 2008). Esta característica permite que o poder elétrico somado de eletrodos de interesse possam auxiliar na determinação de uma probabilidade do evento capturado ser uma piscada. No estudo de Bækgaard et al. (2015), as assinaturas de piscadas foram alinhadas entre as modalidades de EEG e ET para garantir a sincronização, e o começo da atividade de piscada (com o fechamento das

pálpebras) foi eleito como o ponto de referencia da assinatura.

Para se detectar a piscada através de um sinal, é possível tentar realizar o método de *Independent Component Analysis*, ou análise de componente independente, mas as características do sinal de piscada também permite outras abordagens, como a identificação por função de probabilidade.

4.3.2 Identificação no Sinal de ET

Como o equipamento de rastreamento procura encontrar sinais da movimentação ocular, ele também detecta a ausencia desse sinal. No estudo de Bækgaard et al. (2015), uma perda de até 500 milissegundos foi considerada como indicador da ocorrência de uma piscada. No equipamento de coleta de ET GP3, o fabricante oferece uma forma de identificar a existencia de uma piscada. Ela ocorre através da propriedade Blinking Validation Flag, ou BKID, onde qualquer valor diferente de 0 indica ocorrência de piscada durante o timeframe. A extração de piscada através do BKID foi utilizada no estudo de Seha et al. (2019), onde o blink rate foi validado e sincronizado com o vídeo do próprio equipamento (que indica quando houve piscada através da ausencia da imagem dos olhos do usuário).

4.4 MÉTODOS PARA SINCRONIZAÇÃO

Existem diferentes métodos para calculo de sincronização entre séries temporais. A forma mais simples é por **correlação de Pearson**, que mede como dois sinais mudam ao longo do tempo em valores que vão de -1 a 1; com -1 indicando uma correlação perfeita e negativa, 1 uma correlação perfeita e 0, sem correlação. É importante notar que anomalias vão impactar significativamente a correlação, e que os dados assumem que a variância é homogênea.

Outro método de sincronização entre séries temporais é o **lag cross-correlation**, onde é possível identificar qual sinal vem primeiro. A correlação é calculada através da mudança gradual de um vetor de série temporal e subsequente cálculo de correlação. A correlação cruzada procura calcular a similaridade entre dois sinais com a aplicação de um *delay* em apenas um dos sinais.

Um exemplo de seu uso é no trabalho de Com dois sinais diferentes em EEG e ET, Bækgaard et al. (2015) opta por correlacionar as funções de probabilidade do evento observado em ambos os equipamentos, ser uma piscada. Para correlacionar assinaturas diferentes, as probabilidades de ocorrencia de um evento (piscada) em duas séries temporais são convertidas em uma mesma frequência amostral (Bækgaard et al., 2014). A

similitude entre sinais é medida na amplitude do sinal da correlação. A correlação cruzada é definida como:

$$(f * g) = f(-t) * g(t), \quad (4.1)$$

onde $*$ significa convolução e $f(-t)$ é o conjugado complexo de $f(t)$.

4.4.1 Códigos para Sincronização

Alguns equipamentos podem se beneficiar da existencia de *toolboxes* ou bibliotecas direcionadas à sincronização. É o caso dos equipamentos Tobii na solução de EEG-Eye para a linguagem MATLAB. Uma forma de se fazer sincronização é através

4.5 CORRELAÇÃO EEG E ET

Shared triggers Common trigger pulses ("triggers") are sent frequently from the stimulation computer to both ET computer and EEG recording computer. This is achieved via a Y-shaped cable that is attached to the parallel port of the stimulation computer and splits up the pulse so it is looped through to EEG and ET. We recommend to send triggers with a sufficient duration (e.g. at least 5 ms at 500 Hz sampling rate) to avoid the loss of some of the triggers. The advantage of this method is that the same physical signal is used for synchronization (although this does not guarantee that the trigger is inserted into the ET and EEG data streams without delays). The disadvantage is the need for an extra cable.

Messages+triggers Messages are short text strings that can be inserted into the eye tracking data. While triggers are still sent to the EEG, messages are used as the corresponding events for the ET. Here, the ET computer is given a command to insert an ASCII text message (containing a keyword and the value of the corresponding EEG trigger) into the eye tracking data. In the stimulation software, the commands to send a trigger (to the EEG) and a message (to the ET) are given in immediate succession.

Analogue output A copy of the eye track is fed directly into the EEG. A digital-to-analogue converter card in the ET outputs (some of) the data as an analogue signal. With SMI, this signal can be fed directly into the EEG headbox. This requires a custom cable and resistors to scale the output voltage of the D/A converter to the EEG amplifier's recording range. While this method affords easy synchronisation, there are disadvantages: First, voltages need to be rescaled to pixels for analysis. Second, the ET signal may exceed the amplifier's recording range and electrical interference with the EEG is possible. Third, additional information from the ET (messages, eye movements detected online) is not available. Fourth, quality of the ET signal suffers considerably from the D/A and

subsequent A/D conversion. Finally, fewer channels remain to record the EEG (recording binocular gaze position and pupil diameter occupies six channels).

Basics: Synchronization signals

Send triggers and/or messages to align the recordings The toolbox requires that there are at least two shared events present in the ET and EEG: One near the beginning and one near the end of the recording. These events will be called start-event and end-event in the following. Eye tracking data in between the start-event and end-event will be linearly interpolated to match the sampling frequency of the EEG. We recommend to use a unique event value (e.g. "100") to mark the start-event and another unique event-value (e.g., "200") for the end-event. The remaining shared events (triggers or messages) sent during the experiment (between start-event and end-event) are used to evaluate the quality of synchronization. Synchronization is possible even if some intermediate events were lost during transmission.

Original sampling rates of EEG and ET do not need to be the same. The ET will be resampled to the sampling frequency of the EEG. For example, if the EEG was sampled at 500 Hz, and eye movements were recorded at 1000 Hz, the toolbox will downsample the eye track to 500 Hz. Since ET data outside of the synchronization range (before start-event, after end-event) cannot be interpolated, it is replaced by zeros. Please note that the EEG recording should not be paused during the experiment. [Clarification, April 2013: It is not a problem to pause the eye tracker recording, e.g. for recalibrations, because the time stamp assigned to each ET sample continues to increase even during the pause. However, the toolbox currently cannot recognize and handle pauses in the EEG recording. Therefore, the EEG recording should be continuous and must not be paused.]

Note: The current Beta version of the toolbox does not yet implement low-pass filtering of the eye track to prevent aliasing in case that the eye track is downsampled to a much lower EEG sampling rate. We plan to add this in the future.

If synchronization method 2 (messages plus trigger) is used, synchronization messages sent to the eye tracker need to have a specified format. This format consists of an arbitrary user-defined keyword (e.g., "MYKEYWORD") followed by an integer value ("MYKEYWORD 100"). The integer value needs to be the same as that of the corresponding trigger pulse sent to the EEG (usually an 8-bit number between 1 and 255). An example is given in the code below. The EYE-EEG parser (Step 2: Preprocess eye track and store as MATLAB) will recognize messages with the keyword and treat them as synchronization events. A keyword-synchronization messages should be sent together with every trigger sent to the EEG, so intermediate events in-between start-event and end-event can be used to assess synchronization quality. Additional messages (that do not contain the keyword) may be sent to code other aspects of the experimental design.

They are ignored by the toolbox.

The following code is an example for an experimental runtime file containing the necessary synchronization signals. The example is for the software Presentation[™], but similar commands exist in other software (e.g., Psychtoolbox, EPrime[™]):++

5 TRABALHOS RELACIONADOS

Apesar da existência de fontes de datasets fisiológicos públicos, o número de datasets disponíveis ainda é restrito. Sobre a qualidade, Mendoza et al. (2021) observou que nenhum de nove datasets disponíveis publicamente para treinamento de algoritmos de classificação de emoção analisados possuía todos os critérios de referência levantados por estudos anteriores. Apesar da ausência dessas referências, os datasets apresentaram uma base para desenvolvimentos futuros. Sobre a disponibilidade de datasets fisiológicos, Rim et al. (2020) faz uma análise de datasets públicos e privados. No exemplo apresentado, é possível observar que datasets públicos combinando sinais são minoria nas diferentes fontes de dados analisadas.

5.1 AQUISIÇÃO DE DADOS FISIOLÓGICOS

Um exemplo de como se realizar a montagem para coleta de EEG e ET é demonstrado na figura 3.1, utilizado na montagem do dataset EEGEyeNet (Kastrati et al., 2021), onde o participante é colocado de frente para o monitor para apresentação de estímulos com o equipamento de coleta de EEG sobre a cabeça e o aparelho de ET direcionado aos olhos do participante. A piscada é comumente removida como artefato indesejável nos dados de EEG, fazendo parte de muitos pré-processamentos de estudos com EEG e ET (Hosseini, 2020). Entretanto, ET e EEG podem ser sincronizados a partir da assinatura da piscada, permitindo uma correção contínua dos dados (Bækgaard e Larsen, 2014). Outras formas de sincronização de EEG e ET também foram propostas, como por código temporal ou com auxílio de equipamentos externos – exploradas adiante.

Figura 3.2. Setup de coleta de EEG e ET. Fonte: Kastrati et al. (2021) A fusão de dados pode ser realizada no nível de característica ou feature, assim como a nível de decisão do algoritmo classificatório (Klein, 2014; Mendes et al., 2016). explicadas adiante. Na figura 3.2. é possível observar um fluxo de processamento dos sinais capturados por diferentes sensores. Os diferentes sensores representados no estudo de Mendes et al. (2016) são aqui representados pela coleta de EEG e ET.

Figura 3.2. Exemplo de Fluxo para Fusão de Dados de Sensores. Fonte: Mendes et al. (2016). Na Feature Level Fusion (FLF), os dados de diversas fontes são extraídos

dos sensores e unidos de forma a gerar um vetor único com informações multimodais; no Decision Fusion (DL) a classificação ocorre para cada categoria de fonte de dado (exemplo: uma classificação para EEG e outra para ET) e estas classificações são combinadas em um esquema de voto (exemplo: a classificação mais comum) para se chegar em uma categoria final (Bota et al., 2020). A respeito de qual formato seria melhor, Bota et al. (2020) explorou o assunto para cinco bases de dados fisiológicos classificados de acordo com o estímulo emocional apresentado ao participante e observou que o melhor método de fusão é altamente correlacionado à base dados, embora o FLF tenha sido escolhido como o melhor em função de sua baixa complexidade em relação ao DF. No estudo de Kastrati et al. (2021), dados de EEG e ET foram coletados por equipamentos com 500Hz de resolução e sincronizados por código, com auxílio do Eye EEG Toolbox para MATLAB. A sincronização foi confirmada pelo início de sinais registrados em ambos os equipamentos, apresentando erros menores que dois milissegundos.

O pré-processamento de EEG consiste em remoção de artefatos, tais como contração muscular e movimentação ocular. Um exemplo de pipeline de processamento para dados de EEG. A etapa de extração de características consiste em, partindo dos dados com remoção de artefatos indesejáveis, extrair métricas estatísticas, como média, mediana e desvio padrão aplicados a uma janela de tempo, ou outras métricas, como entropia de Shannon (como feito no estudo de Thapaliya et al. (2019)). A seleção de features pode envolver o uso de algoritmos que permitem reduzir o número de características a serem apresentadas como input ao algoritmo, como o Principal Component Analysis (PCA). A partir dessas etapas, os dados seguem são comumente divididos entre treinamento e teste, para validar o algoritmo ou algoritmos a serem estudados. O estudo de King et al. (2017) apresenta alguns exemplos de informações que podem ser extraídas de sinais fisiológicos capturados por sensores no quadro 3.1.s

5.2 USO E AVALIAÇÃO DE ALGORITMOS

Após entender como deverá ser realizado o pré-processamento dos dados fisiológicos multimodais e sua união, é necessário entender de qual forma a avaliação do melhor método de sincronização será realizada. No presente estudo, o objetivo esperado é de se encontrar o melhor método de integrar os dados multimodais como sendo aquele que obtém uma maior acurácia dentre os algoritmos selecionados. O presente capítulo introduz o conceito de classificadores lineares, não lineares e das métricas de avaliação de algoritmos classificatórios.

Algoritmos classificatórios podem ser lineares ou não lineares. Classificadores lineares conseguem separar as categorias de dados em uma reta no espaço vetorial, seja ela com uma ou mais dimensões (reta, plano ou hiperplano). Um exemplo do que seriam

dados linearmente separáveis e não podem ser observados na figura 4.1. Alguns algoritmos classificatórios bastante utilizados são introduzidos adiante. Para problemas mais complexos, é comum o uso de algoritmos que classifiquem dados não lineares, como o Support Vector Machine (SVM), K-Nearest Neighbor (KNN), Rede Neural Artificial (ANN) e Regressão Logística (RL).

Para a avaliação do algoritmo, a acurácia e precisão oferecem métricas para avaliar o erro observado do output (ou resultado) do modelo. Para isso, é necessário saber o valor real e o valor estimado pelo algoritmo classificatório. A acurácia mede a proximidade de um determinado valor e o valor de referência (ou valor real) (equação 4.1). A precisão mede a dispersão dos valores obtidos pelo modelo (equação 4.2). Um bom algoritmo é preciso e possui alta acurácia.

A performance de algoritmos classificatórios pode ser melhor observada através de uma matriz de confusão. Esta matriz permite observar onde o algoritmo mais erra, se em classificar verdadeiros positivos ou verdadeiros negativos. A matriz do exemplo é utilizada para classificadores binários, embora uma versão desta matriz possa ser utilizada para classificadores multicategóricos.

Em seu estudo sobre o uso de algoritmos para classificação de emoções a partir de dados fisiológicos, Zheng et al. (2014) coletou dados de dilatação da pupila, movimentação ocular e EEG para identificar qual seria a classificação do estímulo emocional apresentado aos participantes. O processo de coleta do estudo pode ser observado na figura 2. A classificação do estímulo apresentado (vídeo clips de 4 minutos de duração) obteve acurácia máxima de 73.59

Figura 5.4. Design de Experimento para Coleta de EEG e ET. Fonte: Zheng et al. (2014).

Lu et al. (2015) também faz uso de dados de EEG e RO para classificação de emoções nas três valências emocionais eleitas no estudo de Zheng et al. (2014). Em contraste com o volume de informações coletadas no estudo de Zheng et al., Lu et al. coletam uma maior quantidade de dados de rastreamento ocular – extraindo 16 métricas de RO, enquanto o estudo de Zheng foca em apenas métricas principais da dilatação ocular. Os resultados da acurácia do algoritmo aplicado aos diferentes métodos de fusão de dados multimodais estão resumidos na imagem 5.5, ficando evidente que, independente do método utilizado para fusão das modalidades de EEG e RO, as melhores acurácias foram encontradas para base de dados de mais de uma fonte de informação fisiológica.

Figura 5.5. Acurácia por Método de Fusão de Modalidade e Modalidade Única em Algoritmo Supervisionado. Fonte: Lu et. al. (2015). No trabalho de Thapaliya et al. (2019) dados de EEG e ET foram aplicados em algoritmos de máquina, com o objetivo de estudar uma melhora no método de diagnóstico de crianças com autismo através de

diferentes formas de pré-processamento (exemplo de processamento do estudo na figura 5.6). Os dados de EEG tiveram suas métricas estatísticas coletadas para a construção de um vetor de características (incluindo desvio padrão e média por janela de tempo dos dados de EEG filtrados), assim como a entropia calculada por janela temporal. Para os dados de RO, os tempos de fixação foram coletados, em conjunto com o resultado de testes cognitivos.

Figura 5.6. União de dados de EEG e ET. Fonte: Thapaliya et al. (2019). Em seu estudo, diferentes métodos de construção de vetores de características foram analisados, tanto para os dados unimodais quanto para a junção de EEG e ET. Através das acurácias apresentadas para os diferentes métodos de processamento, podemos observar que determinados algoritmos aumentaram sua acurácia a depender do modo no qual o vetor de características foi construído. Por exemplo, enquanto o algoritmo Support Vector Machine (SVM) atingiu 71% Lim e Chia (2015), estudaram a correlação de ondas EEG detectadas em um equipamento de eletrodo único e estresse cognitivo induzido pelo teste de Stroop. A análise foi feita com base na aplicação de três algoritmos: Artificial Neural Network, k-Nearest Neighbor (KNN) e Linear Discriminant Analysis (LDA), dos dados de EEG transformados pela aplicação da Transformação Cosseno Discreta (Discrete Cosine Transform – DCT). O KNN com o DCT conseguiu classificar melhor o estado de estresse do participante. O uso do MindWave Mobile 2 foi recentemente empregado para o controle de cadeira de rodas (Abuzaher e Al-Azzeh, 2021; Permana et al., 2019), controle de mão robótica e robô móvel (Purnamasari et al., 2019; Rusanu et al., 2019; Ruşanu et al., 2021) e predição de personalidade (Bhardwaj et al., 2021). Outro estudo com uso de eletrodo único como fonte de dados eletrofisiológicos foi o trabalho de Quesada-Tabares et al. (2017), onde foi demonstrado que o uso de EEG comercial e com eletrodo único também possui um importante poder classificatório quando aplicado em algoritmos. Em seu estudo, sete participantes observaram imagens selecionadas do International Affective Picture System (IAPS) pertencentes a três grupos com diferentes valores de valência e excitabilidade. O teste de ANOVA aplicado indicou uma diferença estatisticamente significativa entre os sets de imagens. Um segundo teste foi conduzido pela aplicação de um algoritmo de classificação no estilo árvore de decisão, chegando a uma acurácia média entre os sete participantes de 80.71% Bos (2021) também explora o uso do MindWave no contexto escolar para medir a atenção dos alunos. Em seu estudo, o nível de atenção com alunos assistindo a um vídeo educacional sem e outro com interações (fazendo pergunta aos alunos) é explorado e a distribuição percentual das diferentes bandas de frequência são comparadas entre os grupos. Bos (2021) observou uma relativa diminuição banda de frequência de onda beta para o grupo que não assistiu ao vídeo interativo, o que foi relacionado a um processamento cognitivo reduzido e menor atenção. Bhardwaj et al. (2021) analisou o uso dos dados coletados com o MindWave para classificar sete traços

de personalidade com o algoritmo deep long short term memory (DeepLSTM) e tratando os dados com transformada de Fourier Rápida. A pesquisa contou com 50 participantes (25 mulheres e 25 homens), com idades entre 18 e 46 anos, ao longo de cinco dias, e os dados foram coletados enquanto os participantes assistiam vídeos relacionados a traços de personalidade. Os traços foram separados de acordo com os tipos de personalidade definidos no Myers-Briggs Type Indicator, e ao final de cada vídeo, o participante deveria dizer se concordavam, discordavam ou eram neutros aos questionários de personalidade sobre o traço proeminente no estímulo. O questionário de cada participante foi utilizado para determinar o traço de personalidade, que serviria para então classificar os dados em três possíveis outputs: (a) participante tem traço de personalidade apresentado no vídeo, (b) participante não tem traço apresentado de forma significativa e (c) participante tem traço oposto ao apresentado no vídeo.

5.6 CONSIDERAÇÕES FINAIS

Datasets multi-modais tendem a performar melhor em algoritmos classificatórios que datasets unimodais. A forma de processamento dos dados também pode ter impactos na performance classificatórias dos algoritmos. Equipamentos comerciais já foram previamente utilizados em estudos de algoritmos classificatórios. É esperado que um método de fusão eficiente reflita em uma maior acurácia dos algoritmos treinados no dataset. Para comparar a eficácia de um determinado método de construção de bases de dados, cada uma das bases geradas no presente projeto terá a acurácia calculada e comparada com as demais bases de dados.

Outra forma de avaliação é através da curva ROC, ou Característica de Operação do Receptor. A curva é obtida a o se observar a variação da taxa de verdadeiros positivos (sensibilidade, ou Positivos Verdadeiros / Positivos Totais) em função de $1 - \text{especificidade}$, ou taxa de falsos positivos (Positivos Falsos / Negativos Totais).

6 MATERIAIS E MÉTODOS

6.1 CONSTRUÇÃO DA FERRAMENTA

Dois equipamentos comerciais foram utilizados para construção da ferramenta de coleta sincronizada: Mindwave Mobile II e o GP3; para a coleta de EEG e ET, respectivamente. O código de coleta que gera o dataset multimodal foi construído em MATLAB, e o pré-processamento dos dados antes de serem *inputs* no treinamento de algoritmos no software Orange foi construído em Python. O presente capítulo irá apresentar os equipamentos de coleta e o método adotado para construção da ferramenta.

6.1.1 Mindwave Mobile II

O equipamento possui um eletrodo de coleta e um eletrodo de referência que ficam posicionados acima da sobrancelha esquerda e na orelha esquerda do participante, respectivamente. A posição do eletrodo de coleta em relação ao sistema de referência de posição de eletrodos (10-20), é o FP1, correspondendo a região Frontopolar 1. A coleta de dados do aparelho se dá por conexão via *bluetooth* e funciona em computadores Mac, Windows ou celulares Androids ou iOS, disponíveis em um raio de 10 metros (informações do fabricante). Ele coleta ondas cerebrais variando entre 3 e 100Hz, com uma frequência de 512Hz (NeuroSky Inc., 2015).

O aparelho automaticamente distingue os dados coletados em ondas alfa, beta, gama, teta e delta; além de coletar informações subjetivas no formato de medidas de atenção e meditação, por meio de um algoritmo de reforço de aprendizado não disponibilizado ao público. Também mede a ativação muscular próxima ao eletrodo para estimar a qualidade do sinal. O MindWave Mobile filtra interferência elétrica e converte o sinal detectado pelo eletrodo em sinal digital. O chip que faz o filtro e conversão se chama ThinkGear, e permite a filtragem de ruído para interferência ativação muscular (EMG) e 50/60Hz de corrente alternada.

6.1.2 Gazepoint GP3

O GP3 é um equipamento comercial de coleta do movimento dos olhos, fabricado pela Gazepoint. Possui software próprio para análise dos dados, além de ser possível realizar coleta de dados com linguagens de programação open-source. O GP3 funciona emitindo uma luz infravermelha (IR) diretamente nos olhos do participante e captando a reflexão da luz para localizar o ponto focal ao longo do tempo. Permite coletar a direção do olhar, número de fixações, tempo até a primeira fixação, taxa de piscadas, duração de piscadas, diâmetro da pupila, tempo de duração do olhar em um determinado ponto focal, objetos observados em uma imagem, entre outros (informações do fabricante).

O Gazepoint GP3 estabelece sua conexão com o computador através de dois cabos USB - um cabo de energia e outro para dados. Seu posicionamento ideal é logo abaixo do monitor de estímulo. Para um melhor posicionamento, o fabricante sugere uma distância ideal de 65 cm dos olhos do participante até o equipamento. O GP3 possui as seguintes características, conforme especificado pelo fabricante:

- Acurácia de 0.5-1 grau de ângulo visual
- 60 Hz de frequência de atualização
- calibração de 5 e 9 pontos
- API
- Captura movimento de 25cm horizontais e 11cm verticais
- 15 cm de limite de profundidade de movimento

Para poder realizar a coleta dos dados, é necessário manter o Gazepoint Control (API do desenvolvedor) ligado.

6.1.2.1 Calibração GP3

Uma calibração é realizada pela própria API do equipamento, afim de estabelecer qual o apontamento ocular do participante. A calibração pode ser feita em 5 pontos ou 9 pontos no monitor de exibição de estímulo. Os pontos na tela são apresentados em sequencia e o participante deve acompanhá-los com o olhar até a finalização da calibração.

Após a calibração ser concluída, a API calcula o erro do sistema em relação ao olhar para o olho esquerdo (em verde) e direito (vermelho).

6.1.2.2 Dados Capturados pelo GP3

Fixação: É um agrupamento de pontos focais do olhar que duram entre 20-300 ms (Brand, 2020).

Gaze Point: Gaze point é o ponto focal do usuário em um dado momento. No equipamento GP3 é gravado um ponto focal a cada aproximadamente 17 milissegundos. O ponto de gaze é gravado em relação as coordenadas x e y, que servem para identificar a posição do olhar na tela de experimento.

Sacada: Compreende a um movimento rápido dos olhos após a fixação, e pode ser medida através de pixels por segundo. O valor limite entre sacada e fixação é a velocidade de 1.8 pixels por segundo (George e Routray, 2016), onde acima é uma sacada e abaixo, uma fixação.

6.1.3 Avaliação da Qualidade dos Dados

Acurácia é a capacidade de medir a localização do olhar do usuário na tela.

Precisão é a habilidade de produzir movimentos consistentes.

6.2 COLETA

Para a coleta simultânea, duas linguagens de programação foram utilizadas: MATLAB e Python. A montagem do *setup* foi feita com base nas coletas realizadas para a construção dos datasets EEGEyeNet e ZuCO.

Inicialmente, o software Gazepoint Control foi ligado para rodar em *background* no computador. Em seguida, o MindWave mobile II foi ligado e teve sua conexão *bluetooth* estabelecida e verificada. A porta de conexão (porta COM) PC-Mindwave pode mudar, então foi verificado em qual porta foi estabelecida a conexão em todo início de nova coleta. Após a verificação da porta, foi observado se houve necessidade ou não de alterar este valor na variável do código.

O Gazepoint ficou distante do participante até o software próprio acusar distância ideal (sinalizado por um sinal verde no topo do software de regulação do equipamento). Para teste de coleta foram utilizados dois monitores: um para calibração e apresentação de imagens, e outro para o desenvolvimento de código e testagem (figura 8.1)



Figura 6.1. Montagem de Estudo de Caso da Ferramenta de Coleta EEG-ET.

6.3 CRIAÇÃO DO DATASET

O equipamento GP3 possui uma *Application Programming Interface* (API) própria, o Open Gaze API. A API é uma alternativa de se controlar o equipamento sem precisar do software pago também feito pela Gazepoint. A API utiliza de um *Transmission Control Protocol – Internet Protocol (TCP/IP) socket*, que permite a comunicação entre a aplicação e o servidor (fonte dos dados de ET). O IP determina o endereço para o qual os dados serão enviados, e o TCP utiliza a arquitetura de rede para realizar o transporte. O formato de dado utilizado para a API é o *Extensible Markup Language* (XML), que também pode ser implementado e estabelecer conexão com Python. As portas utilizadas para a comunicação de forma padrão são: localhost (127.0.0.1) e port 4242.

Na API do Gazepoint, o cliente tem duas tags de comunicação: GET e SET. Ao utilizar o SET o cliente pode alterar o valor de alguma variável. O comando GET não tem a possibilidade de alteração de valores. O servidor pode enviar dados para o cliente com diferentes tags: ACK, NACK, CAL e REC. As duas primeiras são geradas em resposta aos comandos de GET e SET (ACK – Sucesso e NACK – Falha). Os CAL são gerados com bases nas calibrações e REC serve para os dados gravados. Estas regras de escrita são utilizadas pelo código em Python para estabelecer o controle do GP3, permitindo que o código calibre o equipamento e estabeleça definições de variáveis.

Para o funcionamento adequado do Mindwave, é necessário instalar uma tecnologia chamada *ThinkGear* (TG), que permite a troca de informações entre o equipamento e

os softwares compatíveis e processa o sinal detectado pelo eletrodo. O TG também é responsável pelo cálculo dos chamados **eSense Meteres**, correspondendo aos dados de Atenção e Meditação em uma escala de 0 a 100 (Neurosky, 2018).

6.4 OBSERVAÇÕES SOBRE QUADROS E TABELAS

Quadros e tabelas são de uso semelhante às figuras, no que diz respeito à numeração, uso de legenda, e necessidade de citar ao menos uma vez antes da ocorrência. No entanto, no caso dos quadros e tabelas a legenda deve ser colocada acima, e não abaixo como nas figuras.

A Tabela 6.1 ilustra esse uso. Observe que a citação de uma tabela específica (pelo número) é com a palavra “tabela” em maiúscula, ao contrário da referência a tabelas em geral. Note que em uma tabela as bordas são horizontais (não use bordas verticais para separar colunas), e não são necessárias bordas para separar cada linha. Separe apenas as linhas do início, fim, e dos indicadores dos campos presentes, como no exemplo. Podem ser usadas bordas horizontais para separar regiões distintas de dados (seções de dados), se necessário.

Tabela 6.1. Parâmetros utilizados na implementação do método de detecção de bordas proposto, em cada configuração considerada.

Configuração	Parâmetro		
	A	B	C
1	10	5	2
2	20	5	3
3	30	8	5

O Quadro 6.1 é um outro exemplo. Note que um quadro se diferencia de uma tabela pelo uso de campos fechados, por meio de linhas horizontais e verticais. As tabelas são mais usadas para dados quantitativos, enquanto quadrados são mais usados quando há descrições textuais (mesmo que haja dados quantitativos também).

Quadro 6.1. Exemplo de um quadro (retirado de [1]): *Variáveis explicativas que representam características socioeconômicas dos idosos.* Fonte: [1]

Variável	Descrição*	Categorização
Nível de escolaridade	Número de anos de estudo (A5a, A5b, A6)	Nenhum 1 a 7 anos 8 anos e mais
Tem seguro/plano privado de saúde?	Que tipo de seguro de saúde o(a) Sr.(a) tem? (F1)	Sim Não
Tem casa própria?	Esta casa é: (J2)	Sim Não
Uso de serviços de saúde	Durante os últimos 12 meses, aonde o(a) Sr.(a) foi quando se sentiu doente ou quando precisou fazer uma consulta de saúde? (F3)	Usou Não usou
Estado nutricional	Com relação a seu estado nutricional o(a) Sr.(a) se considera bem nutrido? (C22i)	Bem nutrido Não está bem nutrido

Fonte: Estudo SABE.

*Os códigos em parênteses na descrição das variáveis se referem à identificação da variável no banco de dados do Estudo SABE. [1]

7 RESULTADOS E DISCUSSÕES

Tabela 7.1. Fatores de qualidades medidos em função do número de amostras, nos testes de reconstrução realizados.

Número de amostras	Fator de qualidade
10	0.30
20	0.45
30	0.60
40	0.90
50	0.93

Tabela 7.2. Outro exemplo de tabela.

a	b	c	d	e
10	20	30	40	50
100	200	300	400	500

8 CONCLUSÃO

LISTA DE REFERÊNCIAS

- [1] M. M. F. Gomes. *Passado e presente: uma análise dos determinantes da mortalidade entre idosos com base nos dados da SABE 2000–2006*. Tese de doutorado, Centro de Desenvolvimento e Planejamento Regional, Faculdade de Ciências Econômicas, Universidade Federal de Minas Gerais – UFMG, 2011.

APÊNDICE A

EXEMPLO DE APÊNDICE

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

APÊNDICE B

OUTRO EXEMPLO DE APÊNDICE

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

ANEXO A

EXEMPLO DE ANEXO

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

OUTRO EXEMPLO DE ANEXO

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.