



Universidade de Brasília – UnB  
Campus Gama – FGA  
Programa de Pós-Graduação em Engenharia Biomédica

**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA E  
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

**ANA PAULA SANDES DE SOUZA**

Orientador: DR. GERARDO ANTONIO IDROBO PIZO



UNB – UNIVERSIDADE DE BRASÍLIA

FGA – FACULDADE GAMA



**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA  
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

**ANA PAULA SANDES DE SOUZA**

**ORIENTADOR: DR. GERARDO ANTONIO IDROBO PIZO**

**DISSERTAÇÃO DE MESTRADO EM  
ENGENHARIA BIOMÉDICA**

**PUBLICAÇÃO: 011A/2022**

**BRASÍLIA/DF, AGOSTO DE 2022**

**UNB – UNIVERSIDADE DE BRASÍLIA**

**FGA – FACULDADE GAMA**

**PROGRAMA DE PÓS-GRADUAÇÃO**

**COLETA SIMULTÂNEA DE ELETROENCEFALOGRAMA  
E RASTREAMENTO OCULAR: FERRAMENTA E ESTUDO DE CASO**

**ANA PAULA SANDES DE SOUZA**

DISSERTAÇÃO DE MESTRADO SUBMETIDA AO PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA BIOMÉDICA DA UNIVERSIDADE DE BRASÍLIA, COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE MESTRE EM ENGENHARIA BIOMÉDICA

APROVADA POR:

---

Dr. Gerardo Antonio Idrobo Pizo

(Orientador)

---

DR<sup>a</sup>. Marília Miranda Forte Gomes

(Examinador interno)

---

Dr. Membro Externo

(Examinador externo)

**FICHA CATALOGRÁFICA**

SOUZA, ANA

Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso [Distrito Federal], 2019.

30p., 210 × 297 mm (FGA/UnB Gama, Mestrado em Engenharia Biomédica, 2022).

Dissertação de Mestrado em Engenharia Biomédica, Faculdade UnB Gama, Programa de Pós-Graduação em Engenharia Biomédica.

1. Neurociência Computacional

2. Eletroencefalograma

3. Rastreamento Ocular

4. Sincronização de Sinais

I. FGA UnB/UnB.

II. Título (série)

**REFERÊNCIA**

SOUZA, ANA (2022). Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso. Dissertação de mestrado em engenharia biomédica, Publicação 011A/2022, Programa de Pós-Graduação, Faculdade UnB Gama, Universidade de Brasília, Brasília, DF, 30p.

**CESSÃO DE DIREITOS**

AUTOR: Ana Paula Sandes de Souza

TÍTULO: Coleta Simultânea de Eletroencefalograma e Rastreamento Ocular: Ferramenta e Estudo de Caso

GRAU: Mestre

ANO: 2022

É concedida à Universidade de Brasília permissão para reproduzir cópias desta dissertação de mestrado e para emprestar ou vender tais cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte desta dissertação de mestrado pode ser reproduzida sem a autorização por escrito do autor.

---

[anapaulasandes.s@gmail.com](mailto:anapaulasandes.s@gmail.com)

Brasília, DF – Brasil

## RESUMO

O eletroencefalograma (EEG) e o rastreamento ocular (ET - *Eye Tracking*) são formas não-invasivas de se observar o comportamento do sistema nervoso através da coleta da atividade neural e posicionamento ocular ao longo do tempo. Desta forma, são importantes ferramentas na construção de bases de dados fisiológicos. Bases de dados com mais de um tipo de dado fisiológico conferem vantagens a respeito do uso em algoritmos classificatórios, apresentando uma maior acurácia do que algoritmos treinados com datasets unimodais. Apesar das vantagens de uso, o acesso a estes datasets ainda é restrito devido ao custo dos equipamentos e a complexidade da sincronização entre diferentes sensores. O presente estudo tem por objetivo apresentar uma ferramenta construída a partir de equipamentos comerciais que tem como *output* um dataset multimodal de EEG e ET coletados simultaneamente. É esperado que a ferramenta promova acessibilidade a datasets multimodais ao gerar uma coleta com equipamentos de baixo custo (relativo a equipamentos clínicos) e incentive o desenvolvimento de diferentes áreas de pesquisa que possam se beneficiar do acesso facilitado da coleta de dados fisiológicos. A ferramenta será avaliada a respeito de sua capacidade de sincronização de EEG e ET, e o dataset multimodal será utilizado para treinar algoritmos classificatórios no software Orange em um estudo de caso com apresentação de estímulos emocionais durante o momento de coleta. A performance dos algoritmos será utilizada para argumentar sobre a possível aplicabilidade da ferramenta em estudos futuros.

**Palavras-chave:** EEG; ET; Sincronização; Base de Dados Fisiológicos;

## **ABSTRACT**

Electroencephalogram (EEG) and Eye Tracking (ET) are non-invasive methods of observing the nervous system behavior by monitoring neural activity and ocular positioning over time. They are important tools in the construction of physiological databases. Databases with more than one type of physiological data confer advantages in classification algorithms, presenting a greater accuracy than algorithms trained with unimodal datasets. However, access to these datasets is still restricted due to the equipment cost and synchronization complexity between different sensors. The present study aims to present a tool built from commercially available devices whose output is a multimodal dataset of EEG and ET collected simultaneously. The tool is expected to promote accessibility to multimodal datasets by generating a database from low-cost equipment (in comparison to clinical equipment) and encourage the development of different areas of research that can benefit from easier access to physiological data acquisition. The tool will be evaluated regarding its ability to synchronize EEG and ET, and the multimodal dataset will be evaluated in a case study with the participant being submitted to emotional stimuli to be classified by the trained algorithms in Orange software. The algorithms performance will be used to discuss about the tool applicability in future studies.

**Keywords:** EEG; ET; Synchronization; Physiological Dataset;

## SUMÁRIO

<b>1</b>	<b>Introdução</b>	<b>1</b>
1.1	Contextualização de Problema . . . . .	1
1.2	Objetivos . . . . .	2
1.2.1	Objetivos Específicos . . . . .	3
1.3	Justificativa . . . . .	3
1.4	Organização do Documento . . . . .	3
<b>2</b>	<b>Eletricidade Cerebral</b>	<b>5</b>
2.1	Correntes Elétricas . . . . .	5
2.2	Neurônios . . . . .	5
2.2.1	Impulsos Nervosos e Potencial de Ação . . . . .	7
2.3	Eletroencefalograma . . . . .	8
2.4	Ondas Cerebrais . . . . .	8
2.4.1	Sistema Internacional 10/20 de Posicionamento de Eletrodos . . .	9
2.4.2	Tipos de Eletrodos para Captura de EEG . . . . .	9
<b>3</b>	<b>Rastreamento Ocular</b>	<b>11</b>
3.1	Anatomia Ocular . . . . .	11
3.2	Equipamentos de Rastreamento . . . . .	12
3.3	Eletrooculograma . . . . .	12
<b>4</b>	<b>Datasets Fisiológicos</b>	<b>13</b>
4.1	Aquisição de EEG e ET . . . . .	14
4.2	Pré-processamento de EEG . . . . .	14
4.3	A Fusão de Dados . . . . .	15

<b>5</b>	<b>Uso em Algoritmos</b>	<b>16</b>
5.1	Algoritmos Classificatórios . . . . .	16
5.2	Uso de Datasets Multimodais de EEG e ET na Pesquisa . . . . .	17
5.3	Equipamentos Comerciais na Pesquisa . . . . .	19
5.4	Considerações Finais . . . . .	20
<b>6</b>	<b>Sincronização</b>	<b>21</b>
6.1	Sincronização com Timecode . . . . .	21
6.2	Sincronização com Piscadas . . . . .	22
6.2.1	Identificação no Sinal do EEG . . . . .	23
6.2.2	Identificação no Sinal de ET . . . . .	24
6.3	Calcular a Sincronização . . . . .	24
<b>7</b>	<b>Conclusão</b>	<b>25</b>
	<b>Lista de Referências</b>	<b>25</b>
	<b>Apêndice A</b>	<b>27</b>
	<b>Apêndice B</b>	<b>28</b>
	<b>Anexo A</b>	<b>29</b>
	<b>Anexo B</b>	<b>30</b>



## **LISTA DE TABELAS**

## **LISTA DE QUADROS**

2.1	Tipos de Eletrodos para coleta de EEG (adaptado de Brain Support Inc. (2019)):	10
-----	--	----

## LISTA DE FIGURAS

1.1	Exemplo de um acelerador linear utilizado no Hospital Universitário de Brasília. . . . .	2
2.1	Anatomia de um neurônio com destaque para área de sinapse entre neurônios. Fonte: Bear (2015) . . . . .	6
2.2	Esquema Modelo Hodgkin-Huxley. Dentro: indicando espaço intracelular; fora: indicando espaço extracelular (imagem a esquerda). Direita: C = capacitor, R = resistor, E = Baterias. Na = Sódio, K = Potássio Fonte: Neuromal Dynamcs (2014) . . . . .	7
2.3	Impulsos nervosos conduzidos em neurônios . . . . .	7
4.1	Número de datasets disponíveis publicamente para estudos de sono por tipo de sinal. Fonte: Rim et al. (2020). . . . .	13
4.2	Setup de coleta de EEG e ET. Fonte: Kastrati et al. (2021) . . . . .	14
4.3	Exemplo de pipeline para processamento de EEG. Fonte: Neuroeletrics (2022) . . . . .	15
4.4	Exemplo de Fluxo para Fusão de Dados de Sensores. Fonte: Mendes et al. (2016) . . . . .	15
5.1	Design de Experimento para Coleta de EEG e ET. Fonte: Zheng et al. (2014) . . . . .	18
5.2	Acurácia por Método de Fusão de Modalidade e Modalidade Única em Algoritmo Supervisionado. Fonte: Lu et. al. (2015) . . . . .	19
5.3	União de dados de EEG e ET. Fonte: Thapaliya et al. (2019) . . . . .	20
6.1	Dados de EEG, ET (eye gaze) e posição de cursor (cursor position) 2 segundos antes da resposta de um participante em atividades de um site de línguas. Fonte: Notaro et al. (2018). . . . .	22
6.2	Assinatura de piscada em microvolts. Fonte: Blinker (2022) . . . . .	23

## LISTA DE NOMENCLATURAS E ABREVIACES

# 1 INTRODUÇÃO

Existe uma importante vantagem advinda do uso de bases fisiológicas chamadas multimodais, ou de mais de um tipo de dado fisiológico em algoritmos supervisionados: a possibilidade de conferir um maior poder classificatório em relação aos datasets unimodais (Kang et al., 2020; Thapaliya et al., 2019). Sobre os benefícios já alcançados com estes datasets, é possível citar: melhora de diagnóstico de transtornos neurológicos, como depressão e autismo (Kang et al., 2020; Thapaliya et al., 2019; Wu et al., 2021), maior poder de classificação de emoções (Guo et al., 2019; Zheng et al., 2019; Lu et al., 2015; Zheng et al., 2014), e uma maior compreensão da ativação de mecanismos nervosos durante atividades de rotina, como leitura (Hollenstein et al., 2018). Um modelo específico de dataset fisiológico multimodal é constituído do eletroencefalograma (EEG) e rastreamento ocular (RO ou ET, da palavra em inglês *Eye Tracking*), já tendo sido utilizado em diferentes estudos de aprendizado supervisionado e estudos de *Brain Computer Interface*, ou BCI; onde a integração homem-máquina é aprofundada (Xu et al., 2022; Kim et al., 2015; Lee et al., 2010).

## 1.1 CONTEXTUALIZAÇÃO DE PROBLEMA

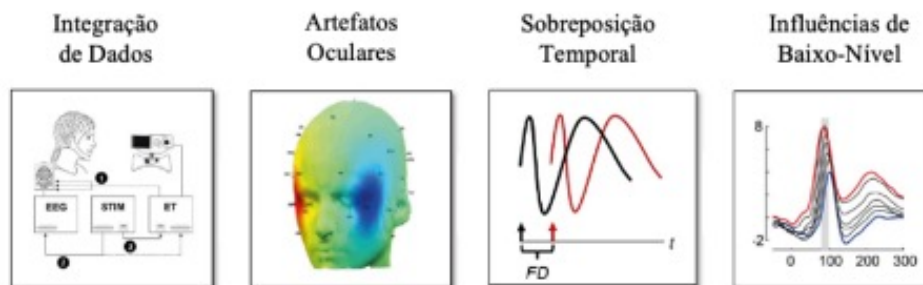
Apesar das múltiplas vantagens, o acesso a estes datasets ainda é restrito. Sobre a coleta de EEG e ET, Kastrati et al. comenta:

*“Coletar e classificar dados simultâneos de EEG e de rastreamento ocular é **demorado e caro**, pois requer equipamento e experiência [...]. Portanto, o acesso a dados de EEG-ET gravados simultaneamente é **altamente restrito**, o que retarda significativamente o progresso neste campo”. – Kastrati et al. (2021).*

No recente estudo sobre a análise conjunta de dados de EEG e ET por Dimigen e Ehinger (2020) foram levantados quatro principais problemas com este tipo de coleta (figura 1.1):

- Integração de dados
- A remoção de artefatos

- Controle de sobreposição temporal de respostas cerebrais
- Controle de influências de baixo-nível



**Figura 1.1.** Principais problemas de integração em datasets de EEG e ET. Fonte: Dimigen e Ehinger (2020).

Para auxiliar nos problemas levantados, a solução dos autores consistiu na construção de códigos especializados (o pacote EYE-EEG), que trabalham de forma integrada a uma *toolbox* já consolidada em estudos de EEG, o EEGLAB (Delorme e Makeig, 2014) - a ser explorada adiante. A redução do custo das coletas fisiológicas já vem sendo abordada através de equipamentos comercialmente disponíveis. Um exemplo é o desenvolvimento de “*smart watches*”, pequenos computadores de pulso que permitem o acompanhamento da frequência cardíaca do usuário, além do monitoramento de outras atividades fisiológicas, como o sono (Canaltech, 2022). O Mindwave Mobile II (Neurosky, Vale do Silício, CA, Estados Unidos), é um exemplo de equipamento comercial que possibilita a captura de ondas cerebrais, além de métricas próprias do fabricante utilizadas para estimar atenção, meditação e a captura de piscadas dos usuários. Atualmente também existem equipamentos disponíveis comercialmente para a coleta de ET, como o GP3 (Gazepoint, Vancouver, BC, Estados Unidos).

Com o propósito de aumentar a acessibilidade aos datasets multimodais e suas amplas vantagens de uso, o presente projeto tem por objetivo a criação de uma ferramenta de coleta simultânea de EEG e ET acessível a partir da coleta de dados de dois equipamentos comerciais – GP3 e Mindwave Mobile II. A ferramenta construída tem como *output* uma base de dados multimodal utilizada para treinamento de algoritmos classificatórios com o auxílio do software de mineração de dados Orange (Demsar et al., 2013), e terão seus resultados apresentados adiante no texto.

## 1.2 OBJETIVOS

Criar uma ferramenta a partir de equipamentos comerciais que gere um dataset fisiológico multimodal com dados de EEG e ET.

### 1.2.1 Objetivos Específicos

- Criar código para coleta simultânea de EEG e ET;
- Criar dataset multimodal a partir da fusão de dados de EEG e ET coletados pela ferramenta;
- Avaliar o erro de sincronização, precisão e acurácia da ferramenta;
- Realizar um estudo de caso com a aplicação do dataset gerado pela ferramenta para treinar algoritmos classificatórios;
- Avaliar a performance dos algoritmos treinados para discutir a usabilidade da ferramenta em estudos futuros;

## 1.3 JUSTIFICATIVA

A capacidade de coletar dados de forma simplificada e de baixo custo pode abrir espaço para novas investigações científicas e também favorecer uma maior e mais representativa volumetria da população de estudo por eliminar a necessidade de deslocamento do participante à centros com os equipamentos (Brand et al., 2020). Ferramentas que gerem datasets multimodais também podem conferir vantagens na aplicação de iniciativas de aprendizado de máquina, *Brain Computer Interface* (BCI) e efomentar avanços na área de Inteligência Artificial (IA) por promover bases de dados onde os algoritmos possam ser treinados.

De forma geral, os benefícios da solução se concentram em:

- Aumento da acessibilidade à estação de coleta, tanto por participantes quanto por pesquisadores;
- Aumento da volumetria de dados;
- Maior disponibilidade de bases de dados fisiológicos para incentivar o desenvolvimento de outras frentes de estudo;

## 1.4 ORGANIZAÇÃO DO DOCUMENTO

O presente texto tem nove capítulos. O primeiro capítulo trata da contextualização do problema, objetivos gerais e específicos, e a justificativa para a abordagem selecionada.

O segundo capítulo trata das características da eletricidade cerebral, dando base para entendimento do que é o sinal de onda cerebral.

O terceiro capítulo trata do Rastreamento ocular, com os principais tipos de equipamento e abordagem de eletrooculograma.

O quarto capítulo aborda a acessibilidade à datasets fisiológicos e geração de bases.

O quinto capítulo trata do uso do dataset multimodal em algoritmos classificatórios.

O sexto capítulo aborda a questão da sincronização de dados de múltiplos sensores.

O sétimo capítulo aborda os materiais e métodos para construção da ferramenta e estudo de caso.

O oitavo capítulo aborda os resultados e discussões.

O nono capítulo apresenta a conclusão deste estudo.



## 2 ELETRICIDADE CEREBRAL

### 2.1 CORRENTES ELÉTRICAS

A eletricidade é o nome dado a uma série de fenômenos que envolvem o fluxo de cargas elétricas (Gaspar, 2005). O potencial elétrico (também conhecido como tensão), é a quantidade de energia precisa para deslocar uma carga elétrica (Matias e Fratezzi, 2008). A diferença de potencial elétrico entre um material condutor gera um fluxo de cargas nomeado de **corrente elétrica** (Creder, 1989). A intensidade do fluxo é medida em ampère (A) e determinada pela quantidade de partículas que atravessam o seguimento do condutor pelo tempo. As correntes podem ser contínuas ou alternadas, a depender se o sentido da corrente varia ou não; enquanto a corrente contínua é composta de polos, a alternada é composta de fases (Bhargava e Kulshreshtha, 1983). O cálculo de corrente elétrica é dado pela seguinte equação:


$$I = \frac{\Delta Q}{\Delta T}, \quad (2.1)$$

onde  $\Delta Q$  é a quantidade de partículas que passam em um seguimento do condutor e  $\Delta T$  indica o tempo.

### 2.2 NEURÔNIOS

Os neurônios são células responsáveis pela condução de impulsos nervosos e se comportam como um “cabo eletrificado” - analogia levantada a respeito da condução de impulsos elétricos, como apresentado no clássico estudo de Hodgkin e Huxley (1952), que teve como resultado uma modelagem dos potenciais de ação emitidos pelas células nervosas através de equações diferenciais não-lineares (figura 2.2). Os neurônios comunicam-se uns com os outros através das **sinapses**, onde ocorre a transmissão dos impulsos nervosos. É possível distinguir três partes anatómicas no neurônio: o corpo celular, o axônio e os dendrito (figura 2.1).

A membrana celular permite a passagem de cargas elétricas através de canais, que podem ou não necessitar de energia para a movimentação das cargas. **Capacitores** são



**Figura 2.1.** Anatomia de um neurônio com destaque para área de sinapse entre neurônios. Fonte: Bear (2015)


dispositivos de polaridades diferentes nas extremidades, que armazenam cargas elétricas num campo elétrico (Serway, 2008). Por sua capacidade de separar cargas elétricas entre o ambiente interno e externo, a membrana celular age como os capacitadores, com sua capacitância (habilidade de armazenar cargas elétricas), definida pela seguinte equação:

$$C = \frac{Q}{\Delta V}, \quad (2.2)$$

onde  $C$  é a capacitância,  $Q$  é a quantidade de carga armazenada e  $\Delta V$  é a tensão elétrica, medida em farad (F). **Resistência elétrica** diz respeito a capacidade de oposição a passagem de corrente elétrica e é medido em ohms ( $\Omega$ ). Os canais da membrana podem se comportar como resistores, se opondo a passagem da corrente elétrica, e sua resistência pode variar dependendo das condições celulares, como por exemplo se o canal está aberto ou não. Na figura 2.2,  $E$  representa **bateria** pois a concentração de íons (partículas elétricas) é diferente no meio intra e extracelular, graças ao trabalho de canais ativos (com custo de energia para manter esse diferencial). De forma simplificada, a corrente aplicada no neurônio pode injetar corrente no capacitor e também ser distribuída pelos canais. Dado a definição de um capacitor,  $I_c = du/dt$ , é possível definir a corrente elétrica em uma seção da membrana como:

$$C \frac{du}{dt} = - \sum_k I_k(t) + I(t), \quad (2.3)$$

onde  $u$  = voltagem ao longo da membrana e  $t$  = tempo.




**Figura 2.2.** Esquema Modelo Hodgkin-Huxley. Dentro: indicando espaço intracelular; fora: indicando espaço extracelular (imagem a esquerda). Direita: C = capacitor, R = resistor, E = Baterias. Na = Sódio, K = Potássio Fonte: Neuromal Dynamics (2014)

### 2.2.1 Impulsos Nervosos e Potencial de Ação

Para passar informações, os neurônios geram **impulsos nervosos**, ou alterações no potencial elétrico de sua membrana. Este sinal elétrico ocorre quando o estímulo recebido pelo neurônio ultrapassa um limiar de ativação, que desencadeia uma série de respostas celulares. A célula pode estar em repouso (com valor do interior celular em cerca de -70mV), passando por despolarização (quando ocorre um fluxo de cargas elétricas que faz com que o meio intracelular passe a ser positivo em relação ao meio extracelular), e em repolarização, quando a célula está retornando ao potencial de repouso, como representado na figura 2.3.


O aumento do inicial da voltagem é causado pela entrada de sódio através de canais dependentes de voltagem, que se segue pela perda de potássio e fechamento dos canais de sódio.



**Figura 2.3.** Resumo do potencial de ação. Fonte: Bear (2015).

## 2.3 ELETROENCEFALOGRAMA

O conjunto de impulsos nervosos de grupos de neurônios geram campos magnéticos que podem ser captados por eletrodos colocados sobre a cabeça humana (Kandel, 2000). Estes campos magnéticos foram primeiro registrados de coletas em humanos aproximadamente em 1929, em um experimento conduzido pelo psiquiatra alemão Hans Berger (Ince et al., 2021) – figura 2.4. Estes registros são o resultado dos potenciais de ação emitidos pelas células nervosas abaixo do eletrodo, e permitem uma boa resolução temporal do comportamento nervoso (podendo atingir precisão de milissegundos), mas em geral não permitem uma boa resolução espacial (como identificar a localização espacial do grupo celular responsável pela variação de voltagem observada).



**Figura 2.4.** Primeiro EEG registrado em humanos, resultado do trabalho do psiquiatra Hans Berger. Fonte: Ince et al. (2021).


## 2.4 ONDAS CEREBRAIS

O cérebro consegue gerar ondas ritmicas geradas pelos impulsos nervosos de grupos de neurônios. A oscilação de um neurônio único pode ser explorada na figura 2.3. As grandes oscilações (geradas por mais de um neurônio sendo ativado) pode ser detectada pelos eletrodos posicionados no crânio no eletroencefalograma (Llinas, 2014) e serem classificadas de acordo com suas características. Um exemplo de agrupamento das ondas cerebrais pode ser observado na figura 2.4.

As ondas cerebrais são caracterizadas pela **frequência, amplitude e fase** (figura 2.5). A amplitude mede a magnitude da oscilação de uma onda e pode ser representada pela equação

$$y = A * \text{sen}(t - k) + b, \quad (2.4)$$

onde  $y$  é a função de onda (mede amplitude no instante  $t$ ),  $A$  é a amplitude da onda,  $\text{sen}$  representa uma função senoidal,  $t$  é o tempo,  $k$  é a translação temporal e  $b$  mede a translação de onda.




**Figura 2.5.** Ondas gamma, beta, alfa, teta e delta.

#### **2.4.1 Sistema Internacional 10/20 de Posicionamento de Eletrodos**

A técnica de registro de EEG vem sendo desde então aperfeiçoada e escolhida em investigações comportamentais devido a sua natureza não invasiva. Um exemplo de aperfeiçoamento foi a criação de um sistema internacional de posicionamentos de eletrodos para a coleta de EEG – o sistema 10/20 (Klem et al., 1999), representado na figura 2.6. O registro capturado nos eletrodos advém de uma diferença de potencial elétrico. Esta diferença pode ser em referência à um eletrodo colocado em uma região externa ao escalpo (como orelha), ou à uma voltagem média comum (Tavares, 2011).

#### **2.4.2 Tipos de Eletrodos para Captura de EEG**

Existem diferentes tipos de eletrodos para a captura de EEG. Um resumo é apresentado no quadro 2.1. É notável também que com o desenvolvimento da capacidade computacional, novos recursos e métodos para a análise destes dados vem sendo benéficos à construção do conhecimento científico, agora também contando com o desenvolvimento de algoritmos de aprendizado de máquina, aprendizado profundo e inteligência artificial.



**Figura 2.6.** Sistema Internacional 10/20 de Posicionamento de Eletrodos. Em destaque: Posição do eletrodo de coleta passiva do MindWave Mobile 2. A = Ear lobe, AF = anterior frontal, C = central, CP = centroparietal, F = frontal, FC = frontocentral, FT = frontotemporal, N = nasion, O = occipital, P = parietal, PO = parietooccipital, T = temporal. Klem et al. (1999).

**Quadro 2.1.** Tipos de Eletrodos para coleta de EEG (adaptado de Brain Support Inc. (2019)):


Tipo de Eletrodo	Descrição
Passivo	Geralmente feitos de prata, contam com a aplicação de gel condutor para reduzir a perda de informação antes de serem colocados na cabeça do participante.
Ativo	Geralmente feitos em prata, permitem o registro de variações de voltagem com redução de ruído do ambiente através de um circuito integrado aos eletrodos, com conversores de impedância.
Seco	Não necessita da aplicação de gel para melhora da coleta do sinal.

Fonte: Brain Support Inc. (2019).

### 3 RASTREAMENTO OCULAR

#### 3.1 ANATOMIA OCULAR

O globo ocular é majoritariamente opaco, com exceção da córnea, que é transparente. A pupila é a região que dá passagem para a luz e possui diâmetro variável. Os músculos da íris são os que controlam a dilatação da pupila. A focalização da imagem deve se concentrar na fóvea, onde se encontram células muito sensíveis à luz (Helene e Helene, 2011). A fixação ocular compreende um período de cerca de 100 milissegundos onde o olhar se fixa em um ponto de convergência (Barreto et al., 2012). Este período se encerra com o movimento de sacada, que compreende um movimento rápido até uma nova fixação do olhar em outro local. Através da coleta do posicionamento ocular, é possível calcular uma taxa de dispersão focal ao longo do tempo e piscadas. Estes dados foram previamente correlacionados com estados emocionais (Soleymani et al., 2012) e também aplicados em estudos com algoritmos de aprendizado de máquina e *deep learning*.



**Figura 3.1.** Representação de polaridades no olho humano. Fonte: López et al. (2019)


### 3.2 EQUIPAMENTOS DE RASTREAMENTO

Para detectar onde o participante está focando seu olhar ao longo do tempo, alguns equipamentos de ET fazem uso de luz infravermelha e câmeras de alta definição que projetam a luz diretamente no olho do participante e gravam a direção do olhar a partir do reflexo. Como a luz infravermelha abrange um comprimento de onda não detectável pelo olho humano, o direcionamento desta luz no olho não interfere na visão do participante. O cálculo do direcionamento ocular é feito com base em algoritmos próprios de cada fabricante. Existem alguns tipos de equipamentos de rastreamento ocular. São eles: (1) Webcam, (2) Vestível (Wearable) e (3) Baseados em Tela. Webcam diz respeito a equipamentos não especializados para o uso de rastreamento; usáveis correspondem a equipamentos como óculos de rastreamento ocular e realidade virtual, e os baseados em tela dizem respeito aos equipamentos de coleta especializada que podem ser acoplados a um computador (Tobii, 2020).

### 3.3 ELETROOCULOGRAMA

Também é possível detectar a movimentação ocular através de registros elétricos no exame de EEG. Isto ocorre devido às características elétricas do olho, que se comporta como um dipolo (possui duas cargas diferentes separadas), com a córnea sendo o polo positivo e a retina o negativo (López et al., 2019). Isto faz com que seja possível capturar a movimentação ocular ao colocar os eletrodos próximos aos olhos, como na figura 2.6. É possível observar picos de voltagem positiva identificados por eletrodos colocados na posição vertical e picos negativos e positivos identificados por eletrodos na posição horizontal, acompanhando movimentos de sacada do participante.

A diferença de potencial entre regiões é chamado de *standing potential*, que mede a diferença entre o potencial de membrana da base e topo do epitélio de pigmento da retina (Ramkumar et al., 2022).




**Figura 3.2.** Representação de polaridades no olho humano. Fonte: López et al. (2019)



## 4 DATASETS FISIOLÓGICOS


Apesar da existência de fontes de datasets fisiológicos públicos, o número de datasets disponíveis ainda é restrito. Sobre a qualidade das bases de dados, Mendoza et al. (2021) observou que nenhum de nove datasets disponíveis publicamente para treinamento de algoritmos de classificação analisados possuía todos os critérios de referência levantados por estudos anteriores, embora ainda mantivessem seu valor para incentivar desenvolvimentos futuros. Sobre a disponibilidade de datasets fisiológicos, Rim et al. (2020) fez uma análise de datasets públicos e privados. No exemplo apresentado, é possível observar que datasets públicos combinando sinais são minoria nas diferentes fontes de dados analisadas (figura 4.1).



**Figura 4.1.** Número de datasets disponíveis publicamente para estudos de sono por tipo de sinal. Fonte: Rim et al. (2020).

## 4.1 AQUISIÇÃO DE EEG E ET

Um exemplo de como se realizar a montagem para coleta de EEG e ET é demonstrado na figura 4.2, utilizado na montagem do dataset EEGEyeNet (Kastrati et al., 2021), onde o participante é colocado de frente para o monitor para apresentação de estímulos com o equipamento de coleta de EEG sobre a cabeça e o aparelho de ET direcionado aos olhos.

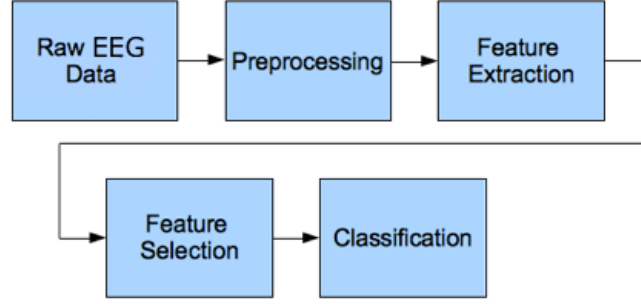


**Figura 4.2.** Setup de coleta de EEG e ET. Fonte: Kastrati et al. (2021)

## 4.2 PRÉ-PROCESSAMENTO DE EEG

O pré-processamento de EEG consiste em remoção de artefatos, tais como contração muscular e movimentação ocular. A etapa de extração de características consiste em, partindo dos dados com remoção de artefatos indesejáveis, extrair métricas estatísticas, como média, mediana e desvio padrão aplicados a uma janela de tempo, ou outras métricas, como entropia de Shannon (como feito no estudo de Thapaliya et al. (2019)). A seleção de features pode envolver o uso de algoritmos que permitem reduzir o número de características a serem apresentadas como input ao algoritmo, como o *Principal Component Analysis* (PCA). Um exemplo de pipeline é apresentado na figura 4.3. A partir dessas etapas, os dados são divididos entre treinamento e teste, para validar o algoritmo ou algoritmos a serem estudados.

O pré-processamento será diferente dependendo se a fonte de dados é de *single electrode* (somente um eletrodo) ou não, e do que é o sinal de interesse. Comumente não são estudados sinais acima de 90Hz (Neuroelectronics, 2022), de forma que um filtro pode ser aplicado para remover frequências que não forem de interesse. Também é comum dividir o sinal em épocas temporais de alguns segundos de duração, para extrair componentes destas janelas e construir a fase de extração de características. Esse processo acontece anteriormente a se inputar os dados a um modelo algorítmico.

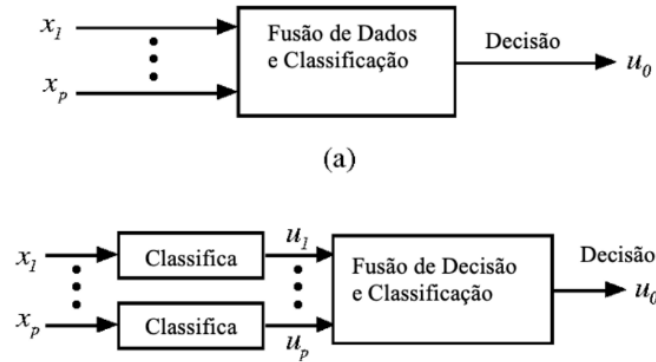


**Figura 4.3.** Exemplo de pipeline para processamento de EEG. Fonte: Neuroelectrics (2022)

### 4.3 A FUSÃO DE DADOS

A fusão ou união de dados advindos de diferentes sensores pode ser realizada no nível de característica ou *feature*, assim como a nível de decisão do algoritmo classificatório (Klein, 2014; Mendes et al., 2016). Na figura 4.4. é possível observar um fluxo de processamento dos sinais capturados por diferentes sensores. Os diferentes sensores representados no estudo de Mendes et al. (2016) são aqui representados pela coleta de EEG e ET.

Na **Feature Level Fusion** (FLF), os dados de diversas fontes são extraídos dos sensores e unidos de forma a gerar um vetor único com informações multimodais; no **Decision Fusion** (DL) a classificação ocorre para cada categoria de fonte de dado (exemplo: uma classificação para EEG e outra para ET) e estas classificações são combinadas em um esquema de voto (exemplo: a classificação mais comum) para se chegar em uma categoria final (Bota et al., 2020). A respeito de qual formato seria melhor, Bota et al. (2020) observou que o melhor método de fusão é altamente correlacionado à base dados, embora o FLF tenha sido escolhido como o melhor em função de sua baixa complexidade em relação ao DF.



**Figura 4.4.** Exemplo de Fluxo para Fusão de Dados de Sensores. Fonte: Mendes et al. (2016)

## 5 USO EM ALGORITMOS

### 5.1 ALGORITMOS CLASSIFICATÓRIOS

Algoritmos classificatórios podem ser lineares ou não lineares. Classificadores lineares conseguem separar as categorias de dados em uma reta no espaço vetorial, seja ela com uma ou mais dimensões (reta, plano ou hiperplano) (Souza, 2018). Para problemas mais complexos, é comum o uso de algoritmos que classifiquem dados não lineares, como o *Support Vsector Machine* (SVM), *K-Nearest Neighbor* (KNN) e Rede Neural Artificial (ANN).

Para a avaliação do algoritmo, a acurácia e precisão oferecem métricas para avaliar o erro observado do output (ou resultado) do modelo. Para isso, é necessário saber o valor real e o valor estimado pelo algoritmo classificatório. A acurácia mede a proximidade de um determinado valor e o valor de referência (ou valor real) (equação 5.1). A precisão mede a dispersão dos valores obtidos pelo modelo (equação 5.2). Um bom algoritmo é preciso e possui alta acurácia.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (5.1)$$

$$Precision = \frac{TP}{TP + FP} \quad (5.2)$$

$$Recall = \frac{TP}{TP + FN} \quad (5.3)$$

$$F1 = \frac{2 * Precision * Recall}{Precision + Recall} = \frac{2 * TP}{2 * TP + FP + FN}, \quad (5.4)$$

onde TP = verdadeiros positivos, ou onde a previsão do valor tido com verdadeiro estava correta; TN = verdadeiros negativos; FP e FN onde o modelo errou e em qual modalidade (se na classificação dos positivos ou dos falsos, respectivamente). Por este motivo, existe a necessidade de separar o dataset em dataset de treino e dataset de teste. De forma habitual, o dataset de teste é 20% do dataset total, selecionado de forma

aleatória. Ao final do momento de treinamento, onde o algoritmo tenta encontrar padrões nas diferentes classes do dataset, o dataset de teste é classificado pelo algoritmo de acordo com o que foi aprendido e então as métricas de performance são calculadas.

A performance de algoritmos classificatórios também pode ser observada através de uma matriz de confusão (Duda e Stork, 2001). Esta matriz permite observar onde o algoritmo mais erra - se em classificar verdadeiros positivos ou verdadeiros negativos.

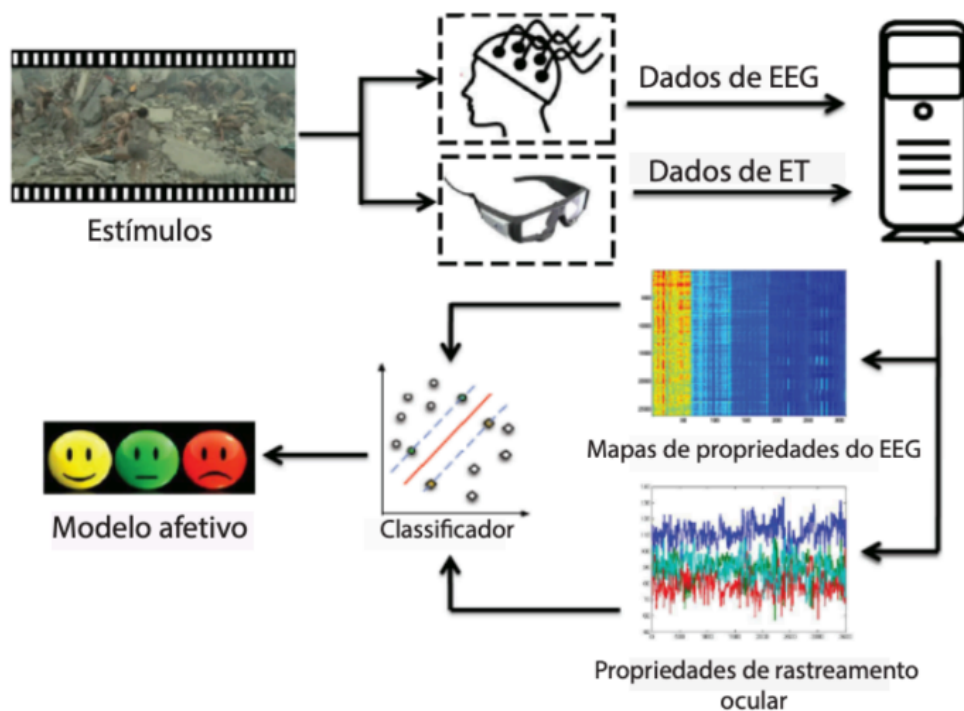
Outra forma de avaliação é através da curva ROC, ou Característica de Operação do Receptor. A curva é obtida a o se observar a variação da taxa de verdadeiros positivos (sensibilidade, ou Positivos Verdadeiros / Positivos Totais) em função de  $1 - \text{especificidade}$ , ou taxa de falsos positivos (Positivos Falsos / Negativos Totais).

## 5.2 USO DE DATASETS MULTIMODAIS DE EEG E ET NA PESQUISA

Em seu estudo sobre o uso de algoritmos para classificação de emoções a partir de dados fisiológicos, Zheng et al. (2014) coletou dados de dilatação da pupila, movimentação ocular e EEG para identificar qual seria a classificação do estímulo emocional apresentado aos participantes. O processo de coleta do estudo pode ser observado na figura 5.3. A classificação do estímulo apresentado (vídeo clips de 4 minutos de duração) obteve acurácia máxima de **73.59%** de dados coletados em 12 sessões de experimento, onde, em cada sessão, os 5 participantes assistiram a 15 vídeos (5 de emoção neutra, 5 de positiva e 5 de negativa).

Lu et al. (2015) também faz uso de dados de EEG e ET para classificação de emoções nas três valências emocionais eleitas no estudo de Zheng et al. (2014). Em contraste com o volume de informações coletadas no estudo de Zheng et al., Lu et al. coletam uma maior quantidade de dados de rastreamento ocular – extraindo 16 métricas de ET, enquanto o estudo de Zheng foca em apenas métricas principais da dilatação ocular. Os resultados da acurácia do algoritmo aplicado aos diferentes métodos de fusão de dados multimodais estão resumidos na imagem 5.4, ficando evidente que, independente do método utilizado para fusão das modalidades de EEG e ET, as melhores acurácias foram encontradas para base de dados de mais de uma fonte de informação fisiológica.

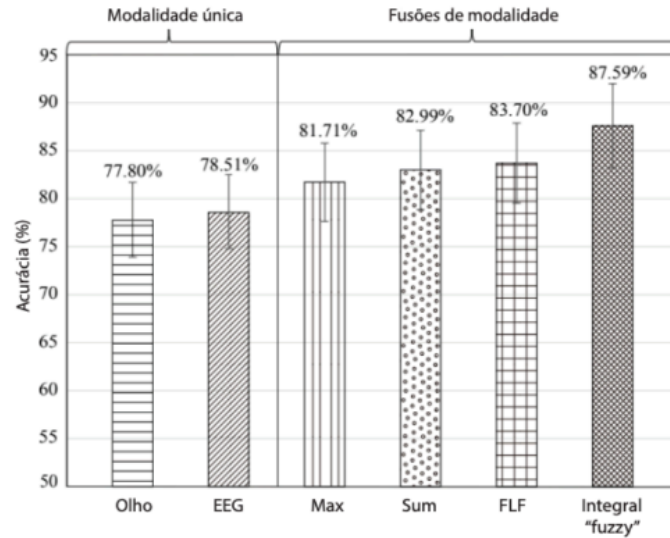
No trabalho de Thapaliya et al. (2019) dados de EEG e ET foram aplicados em algoritmos de máquina, com o objetivo de estudar uma melhora no método de diagnóstico de crianças com autismo através de diferentes formas de pré-processamento (exemplo de processamento do estudo na figura 5.5). Os dados de EEG tiveram suas métricas estatísticas coletadas para a construção de um vetor de características (incluindo desvio padrão e média por janela de tempo dos dados de EEG filtrados), assim como a entropia calculada por janela temporal. Para os dados de ET, os tempos de fixação foram



**Figura 5.1.** Design de Experimento para Coleta de EEG e ET. Fonte: Zheng et al. (2014)

coletados, em conjunto com o resultado de testes cognitivos. Em seu estudo, diferentes métodos de construção de vetores de características foram analisados, tanto para os dados unimodais quanto para a junção de EEG e ET. Através das acurácias apresentadas para os diferentes métodos de processamento, é possível observar que determinados algoritmos aumentaram sua acurácia a depender do modo no qual o vetor de características foi construído. Por exemplo, enquanto o algoritmo Support Vector Machine (SVM) atingiu **71%** de acurácia com o vetor que incluiu Entropia para as janelas de EEG e PCA, a regressão logística com maior acurácia foi atingida com o dataset de desvio padrão de EEG e dados de rastreamento ocular sem a aplicação de PCA (Thapaliya et al., 2019).

Lim e Chia (2015), estudaram a correlação de ondas EEG detectadas em um equipamento de eletrodo único e estresse cognitivo induzido pelo teste de Stroop. A análise foi feita com base na aplicação de três algoritmos: *Artificial Neural Network*, *k-Nearest Neighbor* (KNN) e *Linear Discriminant Analysis* (LDA), dos dados de EEG transformados pela aplicação da Transformação Cosseno Discreta (*Discrete Cosine Transform – DCT*). O KNN com o DCT conseguiu classificar melhor o estado de estresse do participante.



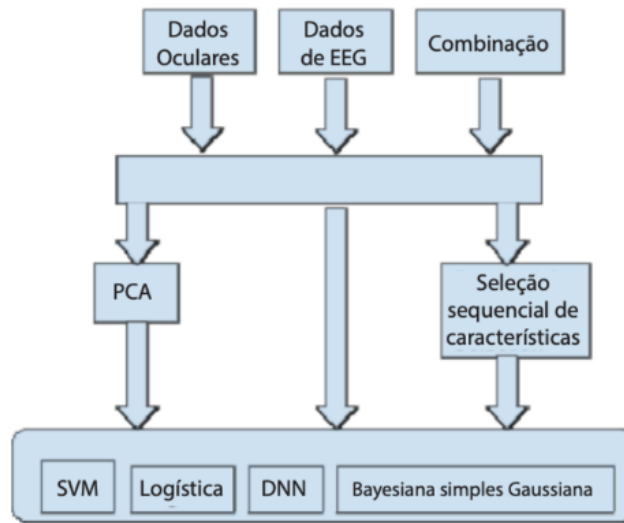
**Figura 5.2.** Acurácia por Método de Fusão de Modalidade e Modalidade Única em Algoritmo Supervisionado. Fonte: Lu et. al. (2015)

### 5.3 EQUIPAMENTOS COMERCIAIS NA PESQUISA

O uso do MindWave Mobile II foi recentemente empregado para o controle de cadeira de rodas (Abuzaher e Al-Azzeh, 2021; Permana et al., 2019), controle de mão robótica e robô móvel (Purnamasari et al., 2019; Rusanu et al., 2019; Ruşanu et al., 2021) e predição de personalidade (Bhardwaj et al., 2021).

Outro estudo com uso de eletrodo único como fonte de dados eletrofisiológicos foi o trabalho de Quesada-Tabares et al. (2017), onde foi demonstrado que o uso de EEG comercial e com eletrodo único também possui um importante poder classificatório quando aplicado em algoritmos. Em seu estudo, sete participantes observaram imagens selecionadas do *International Affective Picture System* (IAPS) pertencentes a três grupos com diferentes valores de valência e excitabilidade. O teste de Análise de Variância aplicado indicou uma diferença estatisticamente significativa entre os sets de imagens. Um segundo teste foi conduzido pela aplicação de um algoritmo de classificação no estilo árvore de decisão, chegando a uma acurácia média entre os sete participantes de **80.71%**.

Bos (2021) também explora o uso do Mindwave no contexto escolar para medir a atenção dos alunos. Em seu estudo, o nível de atenção com alunos assistindo a um vídeo educacional sem e outro com interações (fazendo pergunta aos alunos) é explorado e a distribuição percentual das diferentes bandas de frequência são comparadas entre os grupos. Foi observado uma relativa diminuição banda de frequência de onda beta para o grupo que não assistiu ao vídeo interativo, o que foi relacionado a um processamento cognitivo reduzido e menor atenção.



**Figura 5.3.** União de dados de EEG e ET. Fonte: Thapaliya et al. (2019)

## 5.4 CONSIDERAÇÕES FINAIS

Datasets multimodais tendem a performar melhor em algoritmos classificatórios que datasets unimodais. A forma de processamento dos dados também pode ter impactos na performance classificatórias dos algoritmos. Equipamentos comerciais já foram previamente utilizados em estudos de algoritmos classificatórios. É esperado que um método de tratamento eficiente reflita em uma maior acurácia dos algoritmos treinados no dataset.




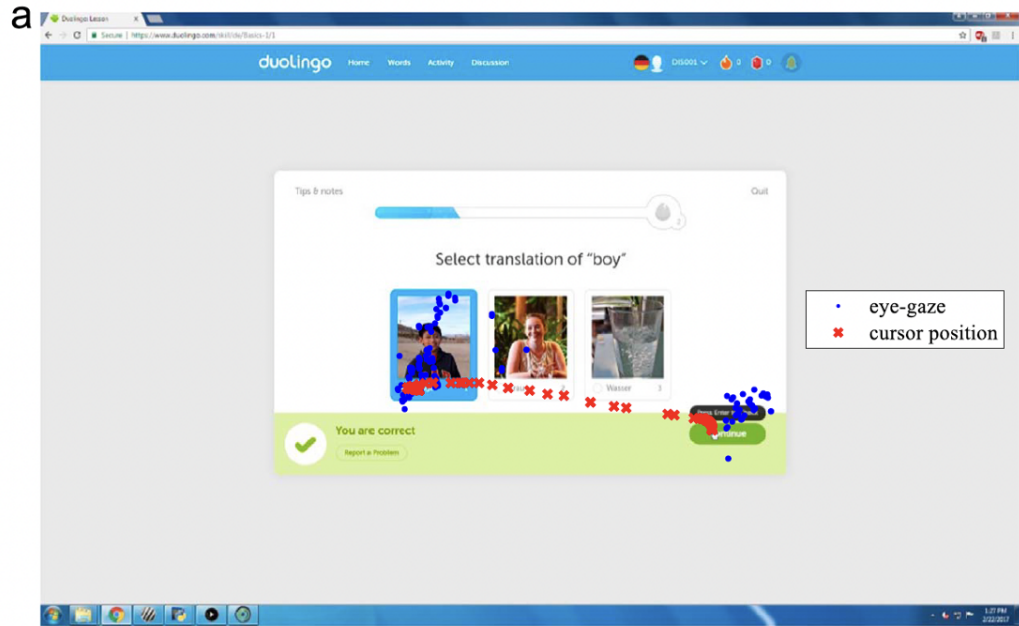
## 6 SINCRONIZAÇÃO

Pode ser desafiador realizar a sincronização de equipamentos de forma custo-eficiente e prática. Algumas propostas já foram exploradas a respeito, como o uso de piscadas e código temporal para garantir a sincronização de EEG e ET (Bækgaard et al. 2015, Notaro et al. 2018). Outra solução conta com o disparo de pulsos para os equipamentos de coleta fisiológica (Baccino e Manunta, 2005) e posterior sincronização. Todos os métodos citados necessitam de um sinal comum entre os equipamentos, seja a **piscada**, o **tempo de coleta** ou o **envio de sinal externo**.

### 6.1 SINCRONIZAÇÃO COM TIMECODE

Notaro et al. (2018) fez uma integração de equipamentos de coleta fisiológica e comportamental de baixo custo, através do equipamento OpenBCI para captura de EEG; GP3 para ET e dados de movimentação do mouse em tela. Os dados foram coletados enquanto os participantes realizavam atividades em um site de línguas. Os dados de EEG foram coletados em frequência de 250Hz e dados de ET e deslocamento do mouse foram gravados em 60 Hz. Em sua pesquisa, Norato et al. faz uso do código temporal, ou *timecode*, para sincronizar as diferentes modalidades.

O driver do fabricante do equipamento comercial de EEG utilizado permite alteração da latência da coleta de dados, que foi modificada do valor padrão de 16 milissegundos para 1 milissegundo, afim de aumentar a precisão do equipamento. A granularidade do *timecode* foi de milissegundos (HH:MM:SS:MsMsMs), informação posteriormente utilizada para montar uma base de dados onde é possível identificar ondas cerebrais e coordenada do foco ocular em tela (figura 6.1). A calibração do GP3 e coleta de dados de ET foi realizada através de código desenvolvido em Python, enquanto a coleta de EEG é realizada por software próprio do OpenBCI e posteriormente unida em código em MATLAB, onde os dados são sincronizados para poder gerar imagens como a do exemplo abaixo.



**Figura 6.1.** Dados de EEG, ET (eye gaze) e posição de cursor (cursor position) 2 segundos antes da resposta de um participante em atividades de um site de línguas. Fonte: Notaro et al. (2018).

## 6.2 SINCRONIZAÇÃO COM PISCADAS

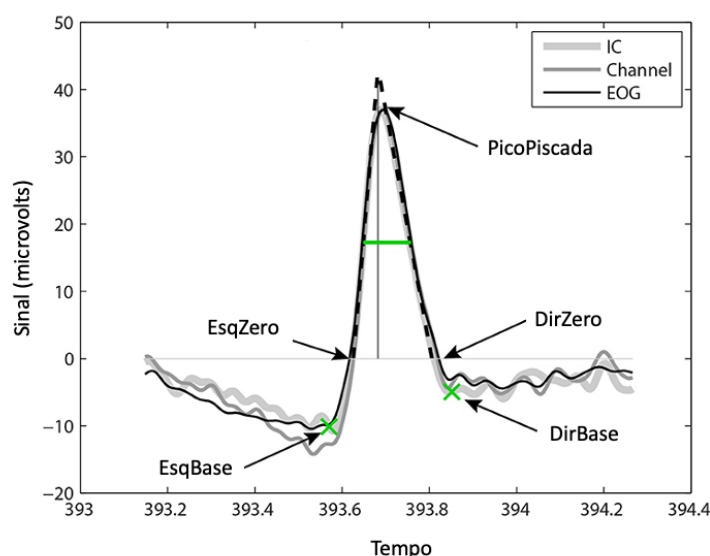
Piscadas duram cerca de 200 milissegundos em média e podem indicar estados de alerta (Caffier, 2013). Piscadas também aparecem em dados de EEG de forma característica, podendo alcançar uma amplitude de sinal acima de 200 microvolts em eletrodos próximos a órbita ocular (Hoffmann e Falkenstein, 2008). Assim sendo, é possível realizar uma sincronização por piscadas ao se detectar o movimento em ambos os equipamentos de coleta. No caso do EEG, as piscadas são comumente descartadas como artefatos indesejáveis. Já no estudo de Bækgaard et al. (2015), elas são a assinatura de sincronização entre os equipamentos de coleta de EEG e ET em função de sua onda característica (geralmente muitos milivolts acima do sinal do EEG), e de também ser detectada através dos equipamentos de rastreamento ocular.

### 6.2.1 Identificação no Sinal do EEG

A piscada envolve ativação muscular, e o dipolo ocular também influencia na captura de alterações de voltagem em eletrodos próximos aos olhos (Croft e Barry, 2000). Seu reflexo no EEG pode ser facilmente identificado pois tende a ter uma amplitude e forma de sinal característicos. A amplitude de uma atividade de piscada no sinal de EEG tem uma média de 200 microvolts (Hoffmann et al., 2008). Esta característica permite que o poder elétrico somado de eletrodos de interesse possam auxiliar na determinação de uma probabilidade do evento capturado ser uma piscada. No estudo de Bækgaard et al. (2015), as assinaturas de piscadas foram alinhadas entre as modalidades de EEG e ET para garantir a sincronização, e o começo da atividade de piscada (com o fechamento das pálpebras) foi eleito como o ponto de referencia da assinatura.

Para se detectar a piscada através de um sinal, é possível tentar realizar o método de *Independent Component Analysis*, ou análise de componente independente, mas as características do sinal de piscada também permite outras abordagens, como a identificação por função de probabilidade.

EEG-Blinks é uma *toolbox* feita para MATLAB que possibilita a coleta de piscadas em dados de EEG, que funciona primeiramente extraindo possíveis sinais de piscadas do sinal de EEG, calculando pontos de interesse (figura 6.1) nos sinais potenciais sinais de piscadas, rejeitando sinais com baixo SNR, e calculando o melhor sinal de piscada para ser utilizado. A partir disso, ele calcula as propriedades do sinal de piscada e seus índices (Blinker, 2022).



**Figura 6.2.** Assinatura de piscada em microvolts. Fonte: Blinker (2022)

### 6.2.2 Identificação no Sinal de ET

Como o equipamento de rastreamento procura encontrar sinais da movimentação ocular, ele também detecta a ausência desse sinal. No estudo de Bækgaard et al. (2015), uma perda de até 500 milissegundos foi considerada como indicador da ocorrência de uma piscada. No equipamento de coleta de ET GP3, o fabricante oferece uma forma de identificar a existência de uma piscada. Ela ocorre através da propriedade Blinking Validation Flag, ou BKID, onde qualquer valor diferente de 0 indica ocorrência de piscada durante o timeframe. A extração de piscada através do BKID foi utilizada no estudo de Seha et al. (2019), onde o blink rate foi validado e sincronizado com o vídeo do próprio equipamento (que indica quando houve piscada através da ausência da imagem dos olhos do usuário).

## 6.3 CALCULAR A SINCRONIZAÇÃO

Existem diferentes métodos para cálculo de sincronização entre séries temporais. A forma mais simples é por **correlação de Pearson**, que mede como dois sinais mudam ao longo do tempo em valores que vão de -1 a 1; com -1 indicando uma correlação perfeita e negativa, 1 uma correlação perfeita e 0, sem correlação. É importante notar que anomalias vão impactar significativamente a correlação, e que os dados assumem que a variância é homogênea.

Outro método de sincronização entre séries temporais é o ***lag cross-correlation***, onde é possível identificar qual sinal vem primeiro. A correlação é calculada através da mudança gradual de um vetor de série temporal e subsequente cálculo de correlação. A correlação cruzada procura calcular a similaridade entre dois sinais com a aplicação de um *delay* em apenas um dos sinais.

Um exemplo de seu uso é no trabalho de Com dois sinais diferentes em EEG e ET, Bækgaard et al. (2015) opta por correlacionar as funções de probabilidade do evento observado em ambos os equipamentos, ser uma piscada. Para correlacionar assinaturas diferentes, as probabilidades de ocorrência de um evento (piscada) em duas séries temporais são convertidas em uma mesma frequência amostral (Bækgaard et al., 2014). A similaridade entre sinais é medida na amplitude do sinal da correlação. A correlação cruzada é definida como:

$$(f * g) = f(-t) * g(t), \quad (6.1)$$

onde  $*$  significa convolução e  $f(-t)$  é o conjugado complexo de  $f(t)$ .

## **7 CONCLUSÃO**

## **LISTA DE REFERÊNCIAS**

## APÊNDICE A

### EXEMPLO DE APÊNDICE

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

## APÊNDICE B

### OUTRO EXEMPLO DE APÊNDICE

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.



### EXEMPLO DE ANEXO

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.

### OUTRO EXEMPLO DE ANEXO

Se você desejar, pode incluir ao final um ou mais apêndices, e um ou mais anexos. Caso não queira, é só remover todo o conteúdo começando na linha marcada por “% Início do Apêndice”, até a linha anterior a “\end{document}”.